

0715 Deep Residual Learning for Image Recognition 리뷰

1. Introduction — 문제의식

- 배치 정규화 덕분에 vanishing/exploding gradient 문제는 해결되어 깊은 네트워크도 수렴은 함.
- But, 새로운 문제 발견: **깊이가 늘어날수록 오히려 training error가 커지는 현상 (degradation problem).**
- 중요한 점: 이는 overfitting이 아님. Overfitting이면 test error만 나빠져야 하는데, **training error 자체**가 나빠짐.
 - 만약 추가된 layer들이 identity mapping(입력을 그대로 출력)만 하면, 깊은 모델의 training error가 얇은 모델보다 나쁠 이유가 없는데 SGD가 이런 solution조차 못 찾음.

2. 해결 아이디어 — Residual Learning

- 레이어가 목표 함수 $H(x)$ 를 직접 학습하는 대신, $F(x) := H(x) - x$ (residual)를 학습하게 함 → 원래 함수는 $F(x) + x$ 로 재구성.
- identity mapping이 최적이라면, 그걸 여러 비선형 layer로 처음부터 만들어내는 것보다 **$F(x)$ 를 0으로 만드는 게 훨씬 쉬움.**
- 구현: **shortcut connection**으로 입력을 몇 layer 건너뛰어 출력에 더함 (element-wise addition). 추가 파라미터·연산 없음 → 기존 SGD로 그대로 학습 가능.

3. Highway Network과 차이 (Related Work)

- Highway Network도 shortcut을 쓰지만, **gate function**(데이터 의존, 파라미터 있음)으로 얼마나 통과시킬지 조절함.
- ResNet의 shortcut은 gate 없이 **항상 열려 있는 identity 연결**. 이 차이 때문에 Highway는 100층 이상에서 성능 향상을 못 보여줬지만 ResNet은 봄.

4. 수식화

- 기본 블록: $y = F(x, \{W_i\}) + x$
- 입출력 차원이 다르면(채널 수 변화): $y = F(x, \{W_i\}) + W_s x$ ($W_s = 1 \times 1$ conv로 차원 맞춤)
- Shortcut 자체는 파라미터·연산량 추가 없음 → plain net과 residual net을 완전히 동일한 조건(파라미터 수, 깊이)에서 공정 비교 가능.

5. 네트워크 구조

- **Plain network:** VGG 철학(3×3 필터, feature map 절반 되면 필터 수 2배) 따름. 34-layer가 VGG-19보다 연산량 훨씬 적음(18%).

- **Residual network:** plain net에 shortcut 추가. 차원 늘어날 때 (A) zero-padding 또는 (B) projection 사용.
- **Bottleneck 구조** (50/101/152층용): 2-layer 대신 $1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$ 3-layer 스택. 처음 1×1 이 차원 축소, 마지막 1×1 이 복원 → 연산량 절약. 이 구조에선 identity shortcut이 특히 중요(projection 쓰면 연산량 2배로 폭증).

6. 실험

ImageNet Classification

- Plain net: 34층이 18층보다 error 높음 → degradation 재확인. BN으로 gradient는 정상인데도 발생 → 저자들은 "깊은 plain net의 수렴 속도 자체가 지수적으로 느려지는 것" 추정.
- ResNet: 34층이 18층보다 좋음(반대 현상) → degradation 해결, 깊이에서 오는 이득 실제로 얻음.
- Identity vs Projection shortcut 비교(A/B/C) → 차이 작음 → **결론: projection이 필수는 아님**, 효율을 위해 옵션 B 채택.
- 152-layer 단일 모델(top-5 4.49%)이 기존 앙상블들보다 좋음. 6개 모델 앙상블 → **3.57%** → **ILSVRC 2015 1위**.

CIFAR-10

- 같은 degradation 패턴 재현(특정 데이터셋 문제가 아님을 확인).
- 110-layer: 초기 lr 0.1이 너무 커서 0.01로 워밍업 후 0.1로 전환 → 6.43% error.
- Layer response 분석: ResNet의 residual 출력이 plain보다 작고, 깊을수록 더 작음 → "residual은 대체로 0에 가깝다"는 가설 뒷받침.
- **1202-layer:** training error는 거의 0인데 test error는 110층보다 나쁨 → 이건 degradation이 아니라 **작은 데이터셋 대비 모델이 너무 커서 생긴 overfitting**(정규화 안 썼기 때문).

Object Detection (PASCAL VOC / COCO)

- Faster R-CNN에서 VGG-16 → ResNet-101 교체만으로 COCO mAP@[.5,.95] 21.2% → 27.2% (28% 향상) — 순전히 더 나은 representation 덕분.
- ResNet 기반으로 ImageNet detection/localization, COCO detection/segmentation 등 여러 트랙 1위 (appendix에 세부 기법: box refinement, global context, multi-scale testing).