

Deep Residual Learning for Image Recognition (ResNet)

서론

연구 배경

합성곱 신경망에서 네트워크의 **깊이(depth)**는 표현 학습 능력을 결정하는 중요한 요소다. 일반적으로 앞쪽 층은 경계선이나 질감처럼 단순한 특징을 학습하고, 뒤쪽 층으로 갈수록 객체의 부분이나 전체 형태와 같은 더 추상적인 특징을 학습한다. 따라서 층을 많이 쌓을수록 네트워크가 더 풍부한 특징을 학습하여 성능이 좋아질 것이라고 기대할 수 있다.

실제로 AlexNet 이후 VGGNet과 GoogLeNet 등은 네트워크를 더 깊게 구성하면서 ImageNet 이미지 분류 성능을 향상시켰다. 이러한 흐름에서 자연스럽게 다음과 같은 질문이 등장한다.

┃ 더 좋은 신경망을 만들기 위해서는 기존 네트워크에 층을 계속 추가하기만 하면 되는가?

하지만 깊은 네트워크를 학습하는 일은 단순히 층을 쌓는 것만으로 해결되지 않았다. 초기의 가장 큰 문제는 역전파 과정에서 gradient가 지나치게 작아지거나 커지는 **기울기 소실 및 폭발(vanishing/exploding gradient)**이었다. 이후 적절한 가중치 초기화와 Batch Normalization이 도입되면서 수십 개 층으로 이루어진 네트워크도 학습을 시작할 수 있게 되었다.

그럼에도 네트워크가 일정 수준 이상 깊어지면 또 다른 문제가 나타났다. 깊이를 늘릴수록 성능이 좋아지는 것이 아니라 정확도가 포화된 뒤 오히려 빠르게 나빠진 것이다. 논문은 이 현상을 **degradation problem**이라고 부른다.

Degradation Problem

Degradation problem은 일반적인 overfitting과 구분해야 한다. Overfitting에서는 모델이 학습 데이터에 지나치게 잘 맞기 때문에 training error는 낮아지는 반면 validation error가 증가한다. 하지만 degradation problem에서는 더 깊은 모델의 **training error 자체가 더 높아진다**.

논문의 CIFAR-10 실험에서는 56층의 plain network가 20층의 plain network보다 더 높은 training error와 test error를 보였다. 즉, 더 많은 층과 더 높은 표현력을 가진 모델이

학습 데이터조차 제대로 설명하지 못했다. 이는 모델의 표현력이 부족해서가 아니라, 좋은 해가 존재함에도 optimizer가 그 해를 찾기 어려워졌다는 것을 의미한다.




그림 1. CIFAR-10에서 20층과 56층 plain network의 training error와 test error. 더 깊은 56층 네트워크의 training error가 오히려 더 높게 나타나며 degradation problem을 보여준다.

여기에는 중요한 논리적 근거가 있다. 잘 학습된 얇은 네트워크에 몇 개의 층을 추가한다고 생각해 보자. 새로 추가한 층들이 입력을 그대로 출력하는 **항등함수(identity mapping)**를 수행한다면, 깊어진 네트워크는 기존의 얇은 네트워크와 동일한 출력을 만들 수 있다.

따라서 이론적으로 더 깊은 모델의 해 공간에는 적어도 얇은 모델과 같은 성능을 내는 해가 존재한다. 그런데도 실제로 더 깊은 plain network의 training error가 높다는 것은, 기존 학습 방법이 여러 비선형 층을 이용하여 항등함수에 가까운 해를 찾는 것조차 어려워할 수 있음을 보여준다.

논문의 목적과 핵심 기여

이 논문은 degradation problem을 해결하기 위해 **잔차 학습(residual learning)**이라는 새로운 학습 구조를 제안한다. 핵심은 각 층이 원하는 전체 변환을 처음부터 직접 학습하도록 하는 대신, 입력으로부터 필요한 변화량만 학습하도록 문제를 재구성하는 것이다.

논문의 주요 기여는 다음과 같이 정리할 수 있다.

- 깊은 plain network에서 발생하는 degradation problem을 실험적으로 명확하게 제시했다.
- 전체 함수가 아니라 입력과 출력 사이의 차이인 residual function을 학습하는 구조를 제안했다.
- 별도의 학습 파라미터가 필요하지 않은 identity shortcut을 사용했다.
- ImageNet에서 최대 152층의 네트워크를 성공적으로 학습했다.
- CIFAR-10에서는 100층을 넘는 네트워크와 1,000층 이상의 네트워크까지 학습했다.

- 이미지 분류뿐 아니라 객체 탐지와 세그멘테이션에서도 residual representation의 효과를 확인했다.

본론

Residual Learning의 핵심 아이디어

여러 층이 학습해야 하는 원하는 변환을 ($H(x)$), 해당 층들의 입력을 (x)라고 하자. 기존의 plain network는 여러 층이 ($H(x)$)를 직접 학습하도록 설계된다.

ResNet은 이 문제를 다르게 바라본다. 여러 층이 전체 변환을 직접 학습하는 대신, 원하는 출력과 입력의 차이인 ($F(x)$)만 학습하게 한다. 결과적으로 원하는 출력은 다음과 같이 표현된다.

$$H(x) = F(x) + x$$

여기서 ($F(x)$)가 합성곱 층들이 학습하는 **잔차 함수(residual function)**이고, 입력 (x)는 별도의 shortcut connection을 통해 그대로 전달된다.

이 구조를 직관적으로 설명하면, ResNet의 각 블록은 입력을 완전히 새로운 표현으로 바꾸는 것이 아니라 다음과 같이 동작한다.

기존 표현은 유지하면서, 현재 단계에서 필요한 수정 사항만 추가한다.

예를 들어 어떤 블록에서 입력을 거의 바꿀 필요가 없다면 원하는 변환은 항등함수에 가깝다. Plain network는 여러 비선형 층을 조합해 입력을 그대로 출력하는 함수를 직접 찾아야 한다. 반면 ResNet에서는 residual branch의 출력이 0에 가까워지기만 하면 블록 전체가 자연스럽게 항등함수에 가까워진다.

실제 최적의 변환이 완전한 항등함수일 가능성은 낮다. 하지만 원하는 출력이 입력에서 크게 달라지지 않는다면, 전체 함수를 처음부터 만드는 것보다 입력을 기준으로 작은 변화량을 찾는 것이 더 쉬울 수 있다. 이것이 residual learning의 핵심적인 최적화 직관이다.




그림 2. Residual learning의 기본 블록. 입력 (x)는 두 개의 weight layer를 거치는 residual branch와 identity shortcut으로 나뉘며, 두 경로의 출력이 element-wise addition으로 결합된다.

Shortcut Connection

Residual learning은 입력을 뒤쪽 출력에 직접 더해 주는 **shortcut connection**을 통해 구현된다. 입력과 residual branch의 출력 차원이 같다면 shortcut은 입력을 그대로 전달하는 identity mapping으로 동작한다.

Identity shortcut의 장점은 다음과 같다.

- 추가로 학습할 파라미터가 없다.
- element-wise addition을 제외하면 추가 연산량이 거의 없다.
- 입력 정보가 뒤쪽 층까지 직접 전달될 수 있다.
- 기존의 SGD와 역전파 방식을 그대로 사용할 수 있다.

이 점은 실험의 공정성 측면에서도 중요하다. 논문은 plain network와 residual network가 거의 동일한 깊이, 너비, 파라미터 수와 계산량을 갖도록 구성했다. 따라서 성능 차이를 단순히 ResNet이 더 많은 파라미터를 사용한 결과로 해석하기 어렵다.

한편 네트워크가 다음 stage로 넘어갈 때는 feature map의 공간 크기가 줄어들고 채널 수가 증가한다. 이 경우에는 shortcut으로 전달되는 입력과 residual branch 출력의 크기가 달라 그대로 더할 수 없다.

논문에서는 이를 해결하기 위해 두 가지 방법을 사용했다.

- 부족한 채널에 0을 채우는 zero-padding
- (1×1) convolution으로 차원을 맞추는 projection shortcut

실험 결과 모든 shortcut에 projection을 적용하지 않아도 degradation problem을 해결할 수 있었다. Projection을 많이 적용하면 성능이 약간 향상되기도 했지만, 그 차이는 크지 않았고 추가 파라미터와 계산량이 필요했다. 따라서 이후의 깊은 모델에서는 차원이 변하는 위치에만 projection을 적용하고, 나머지 구간에서는 파라미터가 없는 identity shortcut을 사용했다.

기존에도 shortcut과 비슷한 연결 방식은 존재했다. 특히 비슷한 시기에 제안된 Highway Network는 학습 가능한 gate를 이용해 shortcut의 정보 전달량을 조절했다. 반면 ResNet의 identity shortcut은 별도의 gate나 파라미터 없이 입력을 항상 전달하며, 각 블록이 명시적으로 residual function을 학습한다는 점에서 차이가 있다.

ResNet의 네트워크 구조

Basic Block

ResNet-18과 ResNet-34의 basic block은 두 개의 (3x3) convolution으로 구성된다. 첫 번째 convolution 뒤에는 Batch Normalization과 ReLU를 적용하고, 두 번째 convolution 뒤에는 Batch Normalization만 적용한다. 이후 residual branch의 출력에 shortcut으로 전달된 입력을 더한 뒤 최종 ReLU를 적용한다.

Basic block은 구조가 단순하고 이해하기 쉽지만, 네트워크를 50층, 100층 이상으로 확장하면 (3x3) convolution의 연산량이 크게 증가한다.

Bottleneck Block

ResNet-50, ResNet-101, ResNet-152는 계산 효율을 위해 **bottleneck block**을 사용한다. Bottleneck block은 다음 세 종류의 convolution으로 구성된다.

- 첫 번째 (1x1) convolution: 채널 수 감소
- (3x3) convolution: 낮아진 채널 차원에서 특징 추출
- 마지막 (1x1) convolution: 채널 수 복원

(1x1) convolution을 통해 계산량이 큰 (3x3) convolution의 입력과 출력 채널 수를 줄이므로, 네트워크를 매우 깊게 만들면서도 연산량을 통제할 수 있다.




그림 3. 왼쪽은 ResNet-34에 사용되는 basic block이고, 오른쪽은 ResNet-50·101·152에 사용되는 bottleneck block이다. Bottleneck block은 (1x1) convolution으로 채널 수를 줄이고 복원하여 연산량을 감소시킨다.

이러한 설계 덕분에 ResNet-152는 VGGNet보다 훨씬 깊으면서도 계산량은 오히려 더 작다. 논문에서 ResNet-152의 연산량은 약 11.3 billion FLOPs인 반면, VGG-16과 VGG-19는 각각 약 15.3 billion과 19.6 billion FLOPs를 사용한다.

즉, ResNet의 성과는 shortcut을 이용해 깊이를 늘린 것뿐 아니라 bottleneck 구조를 이용하여 **깊이와 계산 효율을 함께 확보했다는 점**에도 있다.

실험 설정

논문은 residual learning의 효과를 검증하기 위해 ImageNet과 CIFAR-10에서 plain network와 ResNet을 비교했다.

ImageNet 실험에서는 1,000개 클래스에 해당하는 약 128만 장의 학습 이미지와 5만 장의 validation 이미지를 사용했다. 모델은 처음부터 학습되었으며, 각 convolution 뒤와 activation 앞에 Batch Normalization을 적용했다.

주요 학습 설정은 다음과 같다.

- Optimizer: SGD
- Mini-batch size: 256
- Initial learning rate: 0.1
- Momentum: 0.9
- Weight decay: 0.0001
- Dropout은 사용하지 않음

중요한 점은 plain network와 ResNet에 동일한 학습 조건을 적용했다는 것이다. 따라서 실험은 shortcut connection과 residual formulation이 실제로 최적화를 개선했는지를 비교하도록 설계되었다.

ImageNet 실험 결과

Plain Network와 ResNet의 비교

논문은 먼저 18층과 34층의 plain network 및 ResNet을 비교했다.

모델	Top-1 error
Plain-18	27.94%
Plain-34	28.54%
ResNet-18	27.88%
ResNet-34	25.03%

Plain network에서는 34층 모델이 18층 모델보다 더 높은 error를 기록했다. 더 깊은 모델이 더 많은 층과 높은 표현력을 가지고 있음에도 학습이 오히려 어려워진 것이다.

반면 ResNet에서는 결과가 반대로 나타났다. ResNet-34는 ResNet-18보다 약 2.85%p 낮은 Top-1 error를 기록했고, 같은 깊이의 Plain-34보다 약 3.51%p 낮은 error를 보였다.

또한 18층 모델에서는 plain network와 ResNet의 최종 성능 차이가 크지 않았지만, ResNet이 학습 초기에 더 빠르게 수렴했다. 이는 비교적 얇은 네트워크에서도 residual

learning이 최적화를 쉽게 만들 수 있음을 보여준다.




그림 4의 왼쪽을 보면 Plain-34의 training error가 학습 과정 전반에서 Plain-18보다 높다. 반면 오른쪽에서는 ResNet-34가 ResNet-18보다 낮은 training error와 validation error를 보인다. 이 결과는 residual learning이 degradation problem을 실질적으로 완화했다는 가장 직접적인 증거다.

논문은 plain network의 학습 실패가 단순한 기울기 소실 때문은 아니라고 설명한다. 모든 모델에 Batch Normalization을 적용했으며, forward signal의 분산과 backward gradient의 크기도 정상적인 범위에 있었다. 그럼에도 깊은 plain network의 training error가 높았기 때문에, 문제의 핵심은 gradient가 완전히 사라지는 현상보다는 **깊은 모델의 최적화 자체가 어려워지는 것**에 가깝다.

더 깊은 ResNet의 성능

Bottleneck block을 사용하여 네트워크를 50층, 101층, 152층으로 확장한 결과, 깊이가 증가할수록 성능이 계속 향상되었다.

모델	Top-1 error	Top-5 error
ResNet-34	21.84%	5.71%
ResNet-50	20.74%	5.25%
ResNet-101	19.87%	4.60%
ResNet-152	19.38%	4.49%

ResNet-152 단일 모델은 ImageNet validation set에서 4.49%의 Top-5 error를 기록했다. 서로 다른 깊이의 ResNet 6개를 결합한 ensemble은 ImageNet test set에서

3.57%의 Top-5 error를 달성했고, ILSVRC 2015 classification 부문에서 1위를 차지했다.

이 결과에서 중요한 점은 단순히 152층 모델의 성능이 높았다는 사실만이 아니다. 기존 plain network에서는 깊이가 증가할수록 최적화 문제가 심해졌지만, ResNet에서는 34층에서 50층, 101층, 152층으로 깊이를 늘릴 때 성능 향상을 지속적으로 얻을 수 있었다.

CIFAR-10 실험과 1,000층 이상의 네트워크

논문은 residual learning의 효과가 ImageNet에만 나타나는 현상이 아님을 확인하기 위해 CIFAR-10에서도 실험을 진행했다.

모델	파라미터 수	Test error
ResNet-20	0.27M	8.75%
ResNet-56	0.85M	6.97%
ResNet-110	1.7M	6.43%
ResNet-1202	19.4M	7.93%

Plain network는 깊이가 증가할수록 training error가 높아졌지만, ResNet은 20층에서 110층까지 깊어질수록 test error가 감소했다. ResNet-110은 1.7M개의 비교적 적은 파라미터만으로 6.43%의 test error를 기록했다.

논문은 더 나아가 1,202층 ResNet도 학습했다. 이는 residual learning을 이용하면 1,000층 이상의 네트워크도 optimizer가 training data에 맞출 수 있음을 보여준다.

그러나 ResNet-1202의 test error는 7.93%로 ResNet-110보다 오히려 높았다. 두 모델의 training error는 비슷하게 매우 낮았기 때문에, 이는 degradation problem이 아니라 overfitting의 결과로 해석된다. CIFAR-10은 상대적으로 작은 데이터셋이므로 19.4M개의 파라미터를 가진 1,202층 모델은 지나치게 클 수 있다.

이 실험은 논문의 결론을 **“네트워크는 깊을수록 무조건 좋다”**로 이해해서는 안 된다는 점을 보여준다.

더 정확한 해석은 다음과 같다.

Residual learning은 네트워크를 깊게 만들 때 발생하는 최적화 장벽을 크게 낮추지만, 모델의 복잡도와 데이터 규모 사이의 불균형에서 발생하는 overfitting까지 자동으로 해결하지는 않는다.

논문은 각 층의 출력 크기도 분석했다. ResNet의 residual response는 plain network의 출력보다 대체로 작았으며, 네트워크가 깊어질수록 각 층이 입력 신호를 수정하는 정도도 작아지는 경향을 보였다. 이는 깊은 ResNet이 각 층에서 표현을 크게 바꾸기보다, 여러 블록에 걸쳐 조금씩 수정한다는 residual learning의 직관을 뒷받침한다.

객체 탐지로의 확장

논문은 ImageNet 분류에서 학습한 ResNet의 특징이 다른 computer vision task에서도 유효한지 확인하기 위해 Faster R-CNN의 backbone을 VGG-16에서 ResNet-101로 교체했다.

PASCAL VOC 실험 결과는 다음과 같다.

Backbone	VOC 2007 mAP	VOC 2012 mAP
VGG-16	73.2%	70.4%
ResNet-101	76.4%	73.8%

MS COCO 실험 결과는 다음과 같다.

Backbone	mAP@0.5	mAP@[.5, .95]
VGG-16	41.5%	21.2%
ResNet-101	48.4%	27.2%

두 모델에는 동일한 Faster R-CNN 설정이 사용되었고 backbone만 변경되었다. 따라서 성능 차이는 ResNet이 학습한 feature representation의 품질에서 비롯된 것으로 해석할 수 있다.

특히 COCO의 표준 평가 지표인 mAP@[.5, .95]가 21.2%에서 27.2%로 6.0%p 상승했으며, 이는 약 28%의 상대적 향상이다. mAP@.5뿐 아니라 높은 IoU threshold를 포함하는 지표에서도 성능이 크게 향상되었다는 점에서, ResNet의 깊은 표현이 객체의 분류뿐 아니라 정확한 위치 추정에도 도움이 되었음을 알 수 있다.

ResNet은 이를 바탕으로 ILSVRC 및 COCO 2015 대회에서 ImageNet detection, ImageNet localization, COCO detection, COCO segmentation 부문에서도 1위를 차지했다. 이는 residual learning이 이미지 분류만을 위한 기법이 아니라 다양한 시각 인식 문제에 적용할 수 있는 일반적인 설계 원리임을 보여준다.

논문에 대한 평가

장점

이 논문의 가장 큰 장점은 문제 정의와 해결 방법이 모두 명확하다는 점이다. 저자들은 깊은 네트워크의 성능이 나빠지는 현상을 단순히 “gradient가 사라진다”라고 설명하지 않고, 더 깊은 모델의 training error가 높아지는 degradation problem으로 구체화했다.

또한 그 해결 방법이 매우 단순하다. 기존 표현을 shortcut으로 보존하고, 여러 층은 필요한 변화량만 학습하게 한다. Identity shortcut은 별도의 파라미터와 연산량을 거의 요구하지 않으면서 깊은 네트워크의 최적화를 크게 개선했다.

실험 설계도 설득력이 있다. Plain network와 ResNet의 깊이, 너비, 파라미터 수, 연산량을 가능한 동일하게 통제했고, ImageNet과 CIFAR-10에서 일관된 결과를 확인했다. 또한 분류뿐 아니라 객체 탐지에서도 성능 향상을 보여 residual representation의 일반성을 입증했다.

ResNet은 shortcut connection을 처음 제안한 모델은 아니지만, 파라미터가 없는 identity shortcut과 residual learning을 결합하여 skip connection을 현대 딥러닝의 핵심 설계 원리로 확산시켰다는 의의가 있다.

한계

반면 deep plain network의 최적화가 정확히 왜 어려워지는지에 대한 이론적 설명은 충분하지 않다. 논문은 Batch Normalization을 적용한 모델에서 gradient가 정상적으로 전달됨에도 degradation problem이 나타난다는 사실을 보여주지만, 그 근본적인 원인을 엄밀하게 규명하지는 않는다.

또한 residual learning이 모든 문제를 해결하는 것은 아니다. ResNet-1202의 결과에서 볼 수 있듯이 최적화가 가능하더라도 모델이 데이터셋에 비해 지나치게 크면 overfitting이 발생할 수 있다.

마지막으로 매우 깊은 ResNet의 성공은 shortcut connection만의 효과라기보다 Batch Normalization, 적절한 초기화, 학습률 조절 등의 기법이 함께 사용된 결과로 보는 것이 적절하다. 논문은 plain network에도 같은 조건을 적용하여 residual learning의 효과를 공정하게 비교했지만, 실제 학습의 안정성은 여러 요소가 결합되어 만들어진다.

결론

「Deep Residual Learning for Image Recognition」은 깊은 신경망에서 발생하는 degradation problem을 residual learning을 통해 해결한 논문이다.

기존의 plain network는 여러 층이 원하는 변환 전체를 직접 학습하도록 구성되었다. 반면 ResNet은 입력을 identity shortcut으로 보존하고, 합성곱 층들은 입력으로부터 필요한 변화량만 학습하게 한다. 이러한 구조는 항등함수에 가까운 변환을 쉽게 표현할 수 있도록 하며, 깊은 모델의 최적화를 훨씬 수월하게 만든다.

실험에서도 plain network는 깊이가 증가할 때 training error가 높아졌지만, ResNet은 18층에서 34층, 50층, 101층, 152층으로 깊어질수록 성능이 지속적으로 향상되었다. ImageNet에서는 152층 모델을 성공적으로 학습하여 당시 최고 수준의 성능을 기록했고, CIFAR-10에서는 1,000층 이상의 네트워크도 학습할 수 있음을 보였다. 또한 객체 탐지에서도 VGG 기반 모델보다 높은 성능을 기록하며 residual representation의 일반성을 입증했다.

개인적으로 이 논문에서 가장 인상적인 점은 복잡한 새로운 연산을 추가하기보다 **네트워크가 학습해야 하는 문제의 형태를 바꾸었다는 점**이다. 전체 함수를 처음부터 학습하는 대신 identity mapping을 기준으로 제공하고, 그로부터의 차이만 학습하게 함으로써 최적화 문제를 단순화했다.

이는 좋은 딥러닝 모델을 설계할 때 단순히 층이나 파라미터 수를 늘리는 것만으로는 충분하지 않으며, optimizer가 좋은 해를 쉽게 찾을 수 있도록 학습 문제를 구성하는 것이 중요하다는 사실을 보여준다. ResNet은 이러한 관점을 대표하는 모델이며, 이후의 computer vision과 딥러닝 모델 설계에 큰 영향을 미친 중요한 연구라고 평가할 수 있다.