


1주차_논문과제_23기_정준호

Deep Residual Learning for Image Recognition (23기 정준호)

1. Introduction



1.1. 심층 신경망의 깊이와 한계

- Deep Convolutional Neural Networks에서 깊이는 다양한 시각 인식 과제에서 매우 핵심적인 역할을 수행합니다.
- ImageNet 데이터셋의 최근 성과들을 보면, 16층 VGG에서 30층 수준의 매우 깊은모델들이 주류를 이루고 있습니다.
- 하지만 깊이의 중요성에도 불구하고, 네트워크의 레이어를 무작정 더 쌓는 것만으로 학습이 더 잘 될 것인가라는 질문에는 커다란 장애물이 존재했습니다.

1.2. 최적화의 난제: 기울기 소실 및 성능 저하

- 기울기 소실/폭발: 초창기에는 이 문제로 인해 네트워크가 수렴조차 하지 못하는 경우가 많았습니다.
- 하지만 정규화된 초기화 기법과 배치 정규화 같은 중간 정규화 계층이 도입되면서, 수십 층의 네트워크도 확률적 경사 하강법(SGD)을 통해 수렴을 시작할 수 있게 되었습니다.
- 성능 저하 현상의 대두: 깊은 네트워크가 수렴할 수 있게 되자 새로운 문제가 부상했습니다. 네트워크의 깊이가 깊어질수록 정확도가 포화 상태에 도달하고, 이내 급격히 성능이 저하되는 현상입니다.

- 이 성능 저하 현상은 과적합 때문에 발생하는 것이 아닙니다. 적절히 깊은 모델에 새로운 레이어를 추가하여 더 깊은 모델을 만들면, 오히려 학습 오차가 더 커지는 것이 실험을 통해 확인되었습니다.
-

2. Related Work

2.1. Residual Representations

- 이미지 인식 분야에서 VLAD나 Fisher Vector(VLAD의 확률적 버전) 알고리즘들은 사전 을 참조하여 잔차 벡터로 인코딩을 수행하는 방식이며, 이미지 검색 및 분류에 강력한 성능 을 발휘합니다.
- 컴퓨터 그래픽스 분야에서 편미분 방정식을 풀기 위해 널리 사용되는 Multigrid 방법이나 계층적 기저 전처리역시 잔차의 본질을 활용해 시스템을 재구성함으로써 수렴 속도를 극적 으로 높이는 기법들입니다.

2.2. Shortcut Connections


- 다층 퍼셉트론훈련 초기부터 네트워크 입력과 출력을 연결하는 선형 레이어를 추가하는 실 천적 연구가 존재했습니다.
 - Highway networks는 게이트 함수를 활용한 단축 연결을 제시했습니다.
 - 그러나 Highway networks의 게이트는 파라미터를 가지고 데이터에 의존하는 반면, ResNet의 단축 연결은 파라미터가 없고 항상 열려 있는 항등(identity) 연결이라는 점에서 근본적으로 다릅니다.
-

3. Deep Residual Learning

3.1. 잔차 함수 공식화

- 기존 네트워크는 쌓여진 레이어들이 미지의 최적 매핑 함수 $\mathcal{H}(x)$ 를 직접 근사하도록 학습 시켰습니다.
- ResNet은 레이어들이 잔차 함수(residual function)인 $\mathcal{F}(x) := \mathcal{H}(x) - x$ 를 학습하 도록 명시적으로 수식을 바꿉니다.
- 따라서 원래 학습하려던 최적의 맵핑은 $\mathcal{F}(x) + x$ 의 형태로 재구성됩니다.

- 만약 덧붙여진 레이어들의 최적 함수가 항등 사상(identity mapping)에 가깝다면, 신경망이 여러 비선형 레이어를 거쳐 항등 사상을 처음부터 모사하는 것보다 잔차 $\mathcal{F}(x)$ 를 0으로 맞추는 작업이 훨씬 최적화하기 쉽습니다.



3.2. Identity Mapping by Shortcuts

- 연산 $\mathcal{F}(x) + x$ 는 피드포워드 신경망에서 shortcut connections과 element-wise addition를 통해 완벽히 구현됩니다.
- 기본 빌딩 블록의 수식: $y = \mathcal{F}(x, \{W_i\}) + x$
- 이 단축 연결은 추가적인 파라미터나 연산 복잡도를 유발하지 않습니다.
- 만약 입력과 출력의 채널 크기가 다를 경우, 차원을 맞추기 위해 선형 투영 행렬 W_s 를 곱합니다.
- $y = \mathcal{F}(x, \{W_i\}) + W_s x$

4. Architectures & Implementation

4.1. 네트워크 구조 비교

- Plain Network (기준 모델):** VGG 네트워크의 설계 철학을 따릅니다.
 - 대부분의 합성곱 레이어는 3×3 필터를 갖습니다.
 - 동일한 출력 특징 맵 크기를 가지면 동일한 필터 수를 유지하고, 특징 맵 크기가 절반이 되면 시간 복잡도를 보존하기 위해 필터 수를 2배로 늘립니다.
 - 풀링(pooling) 대신 보폭(stride) 2를 가지는 합성곱 레이어를 통해 직접 다운샘플링(downsampling)을 수행합니다.

- 34-layer Plain 모델은 3.6 billion FLOPs를 가지며, VGG-19(19.6 billion FLOPs) 연산량의 18%에 불과합니다.
- **Residual Network:** Plain 네트워크 구조를 뼈대로 삼고, 매 3×3 필터 쌍마다 단축 연결을 추가하여 34-layer ResNet을 완성했습니다. 차원이 증가할 때는 보폭(stride)을 2로 주어 처리합니다.

4.2. Deeper Bottleneck Architectures

- 50, 101, 152층의 매우 깊은 모델을 위해 학습 시간과 연산 비용을 고려하여 빌딩 블록을 병목(bottleneck) 디자인으로 변경했습니다.
- 2개의 레이어 대신 1×1 , 3×3 , 1×1 합성곱으로 구성된 3-layer 스택을 사용합니다.
- 처음의 1×1 레이어가 차원을 축소하고, 마지막 1×1 레이어가 차원을 복원합니다.
- 깊이가 무려 152층에 달하는 152-layer ResNet조차 11.3 billion FLOPs의 연산량을 기록하여, 기존 VGG-16/19(15.3/19.6 billion FLOPs)보다 더 낮은 복잡도를 가집니다.

4.3. Implementation Details

- **데이터 증강:** 이미지의 짧은 변을 [256, 480] 범위에서 무작위 샘플링하여 스케일 증강을 수행하고, 224×224 크기로 무작위 크롭(crop) 및 수평 뒤집기를 적용한 후 픽셀당 평균을 뺍니다.
- **정규화:** 매 합성곱 레이어 직후, 그리고 활성화(activation) 함수 이전에 배치 정규화를 적용합니다.
- **최적화 (Optimizer):** SGD를 사용하며, 미니 배치(mini-batch) 크기는 256입니다.
- **하이퍼파라미터:** 초기 학습률(learning rate) 0.1로 시작하여 에러가 정체될 때마다 10으로 나눕니다. 최대 60×10^4 이터레이션까지 학습합니다. 가중치 감소(weight decay)는 0.0001, 모멘텀(momentum)은 0.9이며 드롭아웃(dropout)은 사용하지 않습니다.
- **테스트:** 표준 10-crop 테스트를 적용하며, 최고 성능을 위해 완전 합성곱(fully-convolutional) 형태로 다양한 스케일({224, 256, 384, 480, 640})에서 스코어를 평균 냅니다.

5. Experiments

5.1. ImageNet Classification 성능


1000개의 클래스를 가지는 ImageNet 2012 데이터셋에서 평가했습니다 (학습 1.28M, 검증 50k, 테스트 100k).

- **Plain Network의 성능 저하:** 34-layer Plain 모델이 18-layer Plain 모델보다 학습 오차 및 검증 오차가 모두 높게 나타났습니다. 배치 정규화를 사용해 기울기가 건강한 norm을 유지했음에도 수렴률(convergence rates)이 기하급수적으로 낮아진 것이 원인으로 추정됩니다.
- **ResNet의 성능 극복:** 반면, 34-layer ResNet은 18-layer ResNet보다 에러를 2.8% 낮추었으며, 동급의 34-layer Plain 대비 Top-1 에러를 3.5%나 감소시켰습니다. 얇은 18층 네트워크에서도 ResNet이 훨씬 더 빠른 초기 수렴을 보였습니다.
- **단축 연결 옵션 실험:**
 - (A) 제로 패딩 (추가 파라미터 0).
 - (B) 차원 증가시에만 투영(projection) 적용.
 - (C) 모든 단축 연결에 투영 적용.
 - C가 B보다 마진은 작지만 앞섰고, B가 A보다 약간 앞섰습니다. 하지만 병목 구조에서의 연산량 폭발을 막기 위해 C는 사용하지 않기로 결론 내렸습니다.
- **단일 및 앙상블 모델 성과:** 152-layer ResNet 단일 모델의 Top-5 검증 에러는 4.49%였습니다. 깊이가 다른 6개 모델을 앙상블한 결과 3.57%의 Top-5 에러를 달성하여 ILSVRC 2015 1위를 거머쥐었습니다.

5.2. CIFAR-10 데이터셋 및 극한 깊이 탐구

- 32×32 해상도의 CIFAR-10 이미지로 실험을 진행했습니다.
- 20, 32, 44, 56층 네트워크 실험 결과, ImageNet과 마찬가지로 Plain은 성능이 저하되고 ResNet은 정확도가 향상되는 패턴이 동일하게 나타났습니다.
- **레이어 응답 분석 (Layer Responses):** 각 레이어의 출력값에 대한 표준 편차(std)를 분석한 결과, ResNet은 Plain 모델에 비해 전반적인 응답 강도가 낮았습니다. 깊이가 깊어질수록 레이어 하나가 신호를 변경하는 폭이 줄어들었습니다.
- **110-layer ResNet:** 초기 학습률 0.1이 수렴하기엔 커서, 0.01로 약 400회 반복하며 워업한 뒤 다시 0.1로 올려 학습했습니다. 결과적으로 6.43%의 매우 뛰어난 에러율을 기록했습니다.

- **1202-layer 탐구:** 무려 1202층에 달하는 모델도 최적화 난관 없이 0.1% 미만의 학습 오차를 보이며 수렴했습니다. 그러나 이 데이터셋 규모 대비 19.4M의 파라미터는 너무 커서 과적합이 발생했고, 테스트 에러는 7.93%를 기록했습니다.



6. Object Detection & Localization

ResNet의 극강의 표현력은 단순히 이미지를 분류하는 것에 그치지 않고, 다양한 시각 과제로 완벽하게 확장되었습니다.

6.1. PASCAL VOC 및 MS COCO 객체 탐지

- Faster R-CNN을 베이스라인으로 삼아 기존의 VGG-16을 ResNet-101로 교체했습니다.
- **특징 맵 공유 (NoC; Networks on Conv feature maps):** VGG-16처럼 이미지 전체를 통과시키는 구조를 만들기 위해, 보폭(stride) 누적이 16이 되는 레이어들(conv1 ~ conv4_x, 총 91개 층)을 공유 특징 맵 추출기로 사용했습니다..
- **메모리 절약:** 메모리 소비를 줄이기 위해 ImageNet에서 사전 학습된 배치 정규화의 평균과 분산 통계량을 고정시킨 상태로 파인튜닝을 진행했습니다.
- **PASCAL VOC 성능:** VOC 2007/2012 테스트에서 VGG-16 모델 대비 mAP를 3% 이상 향상시켰습니다.
- **MS COCO 성능:** COCO 표준 지표인 mAP@[.5, .95]에서 21.2%를 27.2%로 6.0% 포인트 상승시키며, 상대적으로 28%의 성능 개선을 달성했습니다.

6.2. COCO 대회 1위를 향한 추가 기법들

- **박스 미세 조정 (Box refinement):** 최종 예측된 회귀 박스 위치에서 다시 특징을 풀링하여 점수와 박스 위치를 한 번 더 갱신합니다. NMS(Non-maximum suppression) 임계값을 0.3으로 둔 뒤 박스 보팅(box voting)을 적용해 mAP를 약 2포인트 높였습니다.
- **전역 문맥 정보 (Global context):** Fast R-CNN 스텝에서 전체 이미지의 바운딩 박스를 RoI로 삼는 전역 SPP(Spatial Pyramid Pooling)를 통해 추출된 전역 특징을 연결하여 mAP@.5를 약 1포인트 높였습니다.
- **다중 스케일 테스트 (Multi-scale testing):** 피라미드 이미지 스케일 {200, 400, 600, 800, 1000}에서 추출한 특징을 maxout으로 병합하여 평가 시의 성능을 2포인트 넘게 올렸습니다.
- 이를 종합한 앙상블 모델은 COCO 테스트셋에서 59.0% (mAP@.5) 및 37.4% (mAP@[.5, .95])를 달성하며 **COCO 2015 탐지 부문 1위**를 차지했습니다.

6.3. ImageNet Localization 및 Detection 성과

- **지역화 (Localization):** 클래스별 회귀(PCR; per-class regression) 전략을 사용했습니다. RPN을 카테고리 무관 방식에서 클래스 종속 방식으로 변형하여, 1000차원의 분류 층과 1000×4 차원의 바운딩 박스 회귀 층으로 구성했습니다.
- R-CNN을 결합하여 예측된 상위 200개 프로포절을 대상으로 점수를 갱신한 앙상블 모델은 9.0%의 Top-5 위치 추정 에러를 기록하며 ILSVRC 2014 대비 64% 상대 에러 감소율로 ILSVRC 2015 1위를 차지했습니다.
- **ImageNet 탐지:** DET 데이터셋에서 모델 3개를 앙상블하여 62.1% mAP를 달성, 2위를 8.5포인트 격차로 크게 따돌리며 1위를 차지했습니다.