

NMT

Neural Machine Translation by Jointly Learning to Align and Translate

(Bahdanau, Cho, Bengio, ICLR 2015)

Logical Flow

[고정 길이 벡터 병목]

- [긴 문장에서 성능 저하 문제]
- **[디코더가 직접 정렬을 탐색]**
- [BiRNN 인코더 + 어텐션 디코더]
- [BLEU 및 정성적 정렬 검증]

1 Abstract

이 논문은 기존 신경망 기반 neural machine translation(NMT)이 **문장 전체를 하나의 고정 길이 벡터로 압축**하는 인코더-디코더 구조를 사용한다는 점에 주목합니다. 저자들은 이 **고정 길이 벡터가 성능 향상의 bottleneck**이라고 conjecture하며, 디코더가 번역할 단어를 생성할 때마다 **소스 문장의 관련 부분을 자동으로 (soft-)탐색**하도록 확장한 모델을 제안합니다. 이 방식은 명시적인 hard segment 없이 **alignment과 translation을 동시에 학습**합니다. 영어-프랑스어 번역 과제에서 기존 phrase 기반 통계 기계번역 시스템과 견줄 만한 성능을 보였으며, 정성적 분석 결과 모델이 찾아낸 (soft-)정렬이 사람의 직관과 부합함을 보였습니다.

2 Problem Definition (Research Gap)

기존 NMT 접근법(RNN Encoder-Decoder, Cho et al. 2014a / seq2seq, Sutskever et al. 2014)은 인코더가 가변 길이의 소스 문장을 하나의 **fixed-length context vector**  로 압축하고, 디코더는 오직  만을 보고 전체 번역을 생성하는 구조였습니다.

이 구조의 문제는, 문장이 길어질수록 그 안의 모든 정보(단어 순서, 세부 의미, 긴 의존관계 등)를 하나의 고정된 크기 벡터에 담아야 한다는 점입니다. 저자들은 Cho 등(2014b)이 기본 인코더-디코더의 **성능이 입력 문장 길이가 길어질수록 급격히 저하됨을 보였다는 선행 연구**를 인용하며, 이것이 실제로 관찰된 현상임을 근거로 듭니다.


실제 번역 대상 문장은 훈련 코퍼스보다 길 수 있고, 특히 학술/뉴스 텍스트에서는 30~50단어 이상의 문장이 흔합니다. 고정 벡터 압축 방식은 이런 긴 문장에서 정보 손실을 필연적으로 야기합니다.

따라서 저자들은 "고정 길이 벡터라는 구조적 제약을 없애고, **디코더가 각 타깃 단어를 생성할 때마다 필요한 소스 정보만 선택적으로 참조**하게 할 수 있는가?"라는 연구 질문을 정의함

니다. 이 논문에서는 이 gap이 "conjecture"로 표현되어 있으며, 이는 완전히 증명된 이론적 결과라기보다는 관찰된 현상에 기반한 가설로 제시된 것임에 유의할 필요가 있습니다.

3 Core Idea

핵심은 "하나의 벡터에 모든 정보를 압축할 필요가 없다"는 것입니다. 대신 인코더가 소스 문장을 **벡터들의 시퀀스**(각 단어에 대응하는 annotation)로 인코딩해두고, 디코더가 매 스텝마다 이 시퀀스 중 어느 부분에 "주의(*attention*)를 기울일지"를 학습하여 결정하게 합니다.



기존 방법과의 차이점은 명확합니다: 기존 인코더-디코더는 context vector c 가 모든 타겟 단어 생성에 대해 fixed 되어 있었지만, 이 논문은 타겟 단어 i 마다 다른 **context vector c_i** 를 계산합니다. 이 c_i 는 소스 annotation들의 가중합이며, **가중치(α_i^j)**는 "지금 생성하려는 타겟 단어와 소스의 j 번째 위치가 얼마나 관련있는가"를 학습된 신경망이 매번 계산합니다.

저자들이 이 아이디어가 문제를 해결할 것이라고 판단한 근거는, 정렬을 hard(이산적)가 아니라 soft(연속적)하게 만듦으로써, 정렬 자체도 번역 목적함수와 역전파로 end-to-end 학습이 가능해진다는 점입니다. 즉 정렬 결정 과정 자체가 **latent variable**로 취급되지 않고 **전체 시스템에 통합**됩니다.

4 Detailed Method

Core Idea를 구현하기 위한 아키텍처는 크게 두 부분으로 구성됩니다:

(A) 인코더: BiRNN — Core Idea의 벡터 시퀀스

- 기존 단방향 RNN은 h_j 가 x_j 이전 단어들의 정보만 담습니다. 하지만 번역에서는 한 단어의 의미가 앞뒤 문맥 모두에 의존합니다.
- 이를 위해 forward RNN(앞에서 뒤로 읽음)과 backward RNN(뒤에서 앞으로 읽음)을 각각 수행한 뒤, 각 위치 j 에서 **두 방향의 hidden state를 concatenate 한 annotation** $h_j = [\rightarrow h_j; \leftarrow h_j]$ 를 만듭니다.
- 결과적으로 h_j 는 j 번째 단어 주변을 중심으로 하되 문장 전체 맥락 정보도 포함하는 벡터가 되며, 이것이 디코더가 "참조할 수 있는" **벡터 시퀀스** 역할을 합니다.

(B) 디코더: alignment model — Core Idea의 "선택적 주의"

1. 디코더의 이전 은닉상태 s_{i-1} 과 각 소스 annotation h_j 를 입력으로 하는 작은 feedforward 신경망이 **alignment** 점수 $e_i^j = a(s_{i-1}, h_j)$ 를 계산합니다.
2. 이 점수들을 **softmax** 로 정규화해 가중치 α_i^j 를 얻습니다. α_i^j 는 "타겟 단어 i 가 소스 단어 j 에서 번역되었을 확률"로 해석할 수 있습니다.
3. context vector는 $c_i = \sum_j \alpha_i^j h_j$ 로 계산됩니다 — 이는 design choice 로써, 계산 비용을 줄이기 위해 alignment model을 단순한 단일층 MLP로 제한한 것입니다.
4. 디코더의 은닉상태 s_i 는 이전 상태 s_{i-1} , 이전 타겟 단어 y_{i-1} , 그리고 계산된 c_i 를 입력 받는 GRU gated hidden unit으로 갱신됩니다.
5. 마지막으로 y_i 의 확률은 s_i, y_{i-1}, c_i 를 입력으로 하는 **maxout** 기반 output layer에서 계산됩니다.

주목할 점: 만약 c_i 를 매번 다시 계산하지 않고 항상 마지막 forward hidden state로 고정하면, 이 모델은 그대로 기존 RNN Encoder-Decoder로 환원됩니다. 즉, 이 논문의 구조는 기존 모델을 특수 케이스로 포함하는 일반화된 프레임워크입니다.

5 Experiment

Research Gap이 "긴 문장에서의 성능 저하"였으므로, 실험은 이를 직접 검증하도록 설계되었습니다.


- 데이터셋: WMT'14 영어-프랑스어 병렬 코퍼스(총 850M 단어 중 348M 단어로 축소)
- Baseline: **동일한 학습 절차와 데이터셋**으로 훈련된 **RNNencdec** (Cho et al. 2014a) — 이는 Problem Definition에서 지정한 "고정 길이 벡터" 구조를 사용하는 모델이므로, 제안 모델(**RNNsearch**)과의 차이가 오직 "정렬 메커니즘 유무"에서 온다는 것을 비교로 보여주기 위한 선택입니다.

- 문장 길이를 30단어/50단어로 제한한 두 세트로 각각 훈련(RNNencdec-30/50 , RNNsearch-30/50)한 것도 길이에 따른 강건성을 비교하기 위한 설계입니다.

주요 결과:

Model	All	No UNK ^o
RNNencdec-30	13.93	24.19
RNNsearch-30	21.50	31.44
RNNencdec-50	17.82	26.71
RNNsearch-50	26.75	34.16
RNNsearch-50*	28.45	36.15
Moses	33.30	35.63


- 모든 경우에서 RNNsearch 가 기존 RNNencdec 보다 우수한 성능을 보였습니다. 특히 알려지지 않은 단어가 없는 문장만 고려했을 때(No UNK) RNNsearch 의 성능은 기존 phrase 기반 번역 시스템(Moses)만큼 높았다는 점이 강조되는데, Moses 는 더 많은 단 일언어 코퍼스(418M 단어)를 추가로 사용했다는 점에서 의미가 있습니다.



- 문장 길이에 따른 BLEU 점수 그래프(Fig. 2)에서 RNNencdec 는 문장이 길어질수록 성능이 감소했지만, RNNsearch-30 과 RNNsearch-50 은 길이에 훨씬 강건했고, 특히 RNNsearch-50 은 50단어 이상에서도 성능 저하가 거의 없었습니다.

결과가 Core Idea를 증명하는 방식: 길이별 강건성 실험 결과는 "고정 벡터 압축이 병목"이라는 최초 가설을 직접 지지합니다 — 정렬 메커니즘으로 고정 길이 압축이 없는 모델만이 긴 문장에서 성능을 유지했기 때문입니다.

정성적 검증:



- **Alignment 히트맵(Fig. 3):** 영어-프랑스어 간 어순이 다른 경우(형용사-명사 도치 등)에도 모델이 올바르게 비연속적 정렬을 찾아냄을 보여, "정렬이 단순 대각선이 아니라 의미 있는 패턴을 학습했다"는 주장을 뒷받침합니다.

As an example, consider this source sentence from the test set:

An admitting privilege is the right of a doctor to admit a patient to a hospital or a medical centre to carry out a diagnosis or a procedure, based on his status as a health care worker at a hospital.

The RNNencdec-50 translated this sentence into:

Un privilège d'admission est le droit d'un médecin de reconnaître un patient à l'hôpital ou un centre médical pour effectuer un diagnostic ou de prendre un diagnostic en fonction de son état de santé.

On the other hand, the RNNsearch-50 generated the following correct translation, preserving the whole meaning of the input sentence without omitting any details:

Un privilège d'admission est le droit d'un médecin d'admettre un patient à un hôpital ou un centre médical pour effectuer un diagnostic ou une procédure, selon son statut de travailleur des soins de santé à l'hôpital.

Source	An admitting privilege is the right of a doctor to admit a patient to a hospital or a medical centre to carry out a diagnosis or a procedure, based on his status as a health care worker at a hospital.
Reference	Le privilège d'admission est le droit d'un médecin, en vertu de son statut de membre soignant d'un hôpital, d'admettre un patient dans un hôpital ou un centre médical afin d'y délivrer un diagnostic ou un traitement.
RNNenc-50	Un privilège d'admission est le droit d'un médecin de reconnaître un patient à l'hôpital ou un centre médical d'un diagnostic ou de prendre un diagnostic en fonction de son état de santé.
RNNsearch-50	Un privilège d'admission est le droit d'un médecin d'admettre un patient à un hôpital ou un centre médical pour effectuer un diagnostic ou une procédure, selon son statut de travailleur des soins de santé à l'hôpital.
Google Translate	Un privilège d'admission est le droit d'un médecin d'admettre un patient dans un hôpital ou un centre médical pour effectuer un diagnostic ou une procédure, fondée sur sa situation en tant que travailleur de soins de santé dans un hôpital.
Source	This kind of experience is part of Disney's efforts to "extend the lifetime of its series and build new relationships with audiences via digital platforms that are becoming ever more important," he added.
Reference	Ce type d'expérience entre dans le cadre des efforts de Disney pour "étendre la durée de vie de ses séries et construire de nouvelles relations avec son public grâce à des plateformes numériques qui sont de plus en plus importantes", a-t-il ajouté.
RNNenc-50	Ce type d'expérience fait partie des initiatives de Disney pour "prolonger la durée de vie de ses nouvelles et de développer des liens avec les lecteurs numériques qui deviennent plus complexes.
RNNsearch-50	Ce genre d'expérience fait partie des efforts de Disney pour "prolonger la durée de vie de ses séries et créer de nouvelles relations avec des publics via des plateformes numériques de plus en plus importantes", a-t-il ajouté.
Google Translate	Ce genre d'expérience fait partie des efforts de Disney à "étendre la durée de vie de sa série et construire de nouvelles relations avec le public par le biais des plates-formes numériques qui deviennent de plus en plus importantes", a-t-il ajouté.
Source	In a press conference on Thursday, Mr Blair stated that there was nothing in this video that might constitute a "reasonable motive" that could lead to criminal charges being brought against the mayor.
Reference	En conférence de presse, jeudi, M. Blair a affirmé qu'il n'y avait rien dans cette vidéo qui puisse constituer des "motifs raisonnables" pouvant mener au dépôt d'une accusation criminelle contre le maire.
RNNenc-50	Lors de la conférence de presse de jeudi, M. Blair a dit qu'il n'y avait rien dans cette vidéo qui pourrait constituer une "motivation raisonnable" pouvant entraîner des accusations criminelles portées contre le maire.
RNNsearch-50	Lors d'une conférence de presse jeudi, M. Blair a déclaré qu'il n'y avait rien dans cette vidéo qui pourrait constituer un "motif raisonnable" qui pourrait conduire à des accusations criminelles contre le maire.
Google Translate	Lors d'une conférence de presse jeudi, M. Blair a déclaré qu'il n'y avait rien dans cette vidéo qui pourrait constituer un "motif raisonnable" qui pourrait mener à des accusations criminelles portées contre le maire.

- 긴 문장 번역 사례(Table 3): RNNencdec 는 30단어 지점부터 원문 의미를 이탈하는 반면 RNNsearch 는 전체 의미를 보존 — 이는 정량적 BLEU 추세를 사람이 읽을 수 있는 형태로 확인시켜주는 보완적 증거입니다.

저자가 언급한 한계: 향후 과제로 rare word 또는 unknown word 처리 개선이 필요하다고 명시되어 있습니다. 또한 저자들은 이 정렬 메커니즘이 소스-타겟 모든 쌍에 대해 계산되어야 하므로, 번역처럼 문장 길이가 15~40 단어 수준일 때는 문제없지만 더 긴 시퀀스를 다루는 다른 task에는 적용 범위가 제한될 수 있음을 지적합니다.

💡 한 줄 정리

고정 길이 벡터라는 구조적 병목을 제거하고 디코더가 매 스텝 소스 문장 전체에 대해 학습된 소프트 정렬로 "선택적으로 주의를 기울이게" 함으로써, 이 논문은 이후 *Transformer's self-attention*으로 이어지는 **attention 메커니즘의 원형을 제시합니다.**