

VIT | AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE

저자

- Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov(Google Research, Brain Team)

링크

- <https://arxiv.org/pdf/2010.11929>

1. Introduction

- NLP에서는 대규모 pre-train → fine-tune이 표준이며, 모델·데이터를 키워도 성능 포화가 안 보임
- CV에서 self-attention 시도들은 특수한 attention 패턴 때문에 하드웨어 가속기에서 확장 실패
- 근본 병목: self-attention은 토큰 수에 대해 $O(N^2)$. 224×224 픽셀을 토큰으로 쓰면 attention 행렬이 25억 개 → 불가능
- 해결책: 픽셀이 아니라 패치를 토큰으로 삼는다. 16×16 패치 → 토큰 196개, NLP 문장 길이 수준으로 감소
- 설계 원칙: 표준 Transformer를 최대한 그대로 사용. NLP 구현·최적화 자산을 그대로 재사용하기 위함
- 결과: ImageNet만으로 학습하면 ResNet보다 몇 %p 낮음 → 저자 해석은 inductive bias 부족
- 그러나 14M~300M 규모로 키우면 역전

2. Related Work

- NLP: Transformer(2017) 이후 BERT(MLM), GPT(LM)가 대규모 pre-train 패러다임 확립 → ViT의 [CLS] 토큰과 전체 구조는 BERT를 이미지로 옮긴 것
 - CV의 self-attention 근사들: local self-attention, Sparse Transformer, axial attention → 성능은 유망했으나 구현 복잡도로 확장 실패
 - 가장 가까운 선행 연구: Cordonnier et al. (2020) — 2×2 패치에 full self-attention. 발상이 거의 동일
 - ViT의 차별점: ① 16×16 패치로 중간 해상도 처리 가능 ② 대규모 pre-training으로 SOTA CNN을 실제로 능가함을 입증
 - 즉 이 논문의 기여는 아이디어의 독창성보다 스케일에서의 실증
 - iGPT: 픽셀 단위 생성 모델, 해상도 32×32로 축소, ImageNet 72%
 - 대규모 데이터 전이학습: BiT (ImageNet-21k, JFT-300M) → ViT는 이 흐름에서 백본만 바꾼 실험
-

3. Method

- 원본 Transformer를 최대한 그대로 따름. 의도적 단순함의 이점은 NLP 구현체를 즉시 재사용 가능하다는 것

3.1 Vision Transformer (ViT)

패치 임베딩

- 이미지를 $P \times P$ 패치로 분할 → 패치 수 $N = HW/P^2$
- 각 패치를 P^2C 차원으로 flatten → 학습 가능한 선형 사영으로 D 차원 매핑
- 224×224, 패치 16 기준: 14×14 = 196개 패치, 각 768차원 → 768차원 임베딩
- 구현은 kernel=stride= P 인 conv 한 번. 수용 영역이 겹치지 않으므로 flatten+linear과 동일

[CLS] 토큰

- BERT처럼 학습 가능한 토큰을 시퀀스 맨 앞에 붙임

- 이미지 정보는 없지만 self-attention을 거치며 모든 패치 정보를 집약
- 마지막 층의 이 토큰 = 이미지 표현. Head는 pre-train 시 MLP, fine-tune 시 단일 Linear

Position Embedding

- self-attention은 permutation invariant → 위치 정보를 명시적으로 주입해야 함
- 1D learnable 위치 임베딩을 패치 임베딩에 더함
- 2D-aware 위치 임베딩도 실험했으나 성능 향상 없음

Transformer Encoder

- 각 블록 = MSA + MLP, 각 앞에 LayerNorm, 뒤에 residual
- 원본과의 차이: Pre-LN 구조 (residual 경로가 identity로 뚫려 있어 깊은 모델 학습이 안정적)
- Attention: $\text{softmax}(QK^T/\sqrt{d})V$. $\sqrt{d}$ 로 나누는 이유는 내적 분산이 차원에 비례해 커져 softmax가 포화되는 것을 막기 위함
- Multi-head는 여러 부분 공간에서 병렬 수행 → head마다 다른 관계 학습 가능
- MLP는 GELU 2층, 토큰마다 독립 적용 → 토큰 간 정보 교환은 오직 MSA에서만 일어남

모델 변형

- Base(12층, 768차원, 86M) / Large(24층, 1024차원, 307M) / Huge(32층, 1280차원, 632M)
- 표기법 ViT-L/16 = Large + 16×16 패치
- 패치가 작을수록 토큰 수가 늘어 연산량↑ 성능↑. 즉 /16이 /32보다 무겁고 강함

Inductive bias (논문에서 가장 중요한 이론적 진술)

- CNN은 locality, 2D 이웃 구조, translation equivariance가 모든 층에 구조적으로 새겨져 있음
- ViT는 MLP 층만 local하고, self-attention은 처음부터 global
- 2D 구조가 쓰이는 지점은 딱 두 곳: ① 패치로 자를 때 ② fine-tune 시 위치 임베딩 보간할 때
- 초기 위치 임베딩은 2D 위치 정보를 전혀 갖지 않음 → 모든 공간 관계는 데이터로부터 학습해야 함

- 4장 전체가 사실상 "이 빈 공간을 무엇으로 채우는가"에 대한 답 찾기. 답은 데이터

Hybrid Architecture

- 원본 이미지 대신 CNN feature map에서 패치를 추출하는 변형
- feature map이 이미 축소되어 있으므로 패치 크기가 1x1이 될 수도 있음
- CNN의 도움이 실제로 얼마나 필요한지 측정하는 대조군 역할

3.2 Fine-tuning and Higher Resolution

- Pre-train된 head 제거 후 zero-init 선형층을 새로 붙임
- 높은 해상도로 fine-tune하면 유리하나, 패치 크기를 유지하면 패치 개수가 늘어나 사전학습된 위치 임베딩과 개수가 안 맞음
- 해결: 원본 이미지에서의 위치에 따라 2D interpolation
- 저자 강조: 패치 추출과 이 해상도 조정이 2D 구조 편향이 수동 주입되는 유일한 지점

4. Experiments

4.1 Setup

- Pre-train 데이터: ImageNet-1k(1.3M) / ImageNet-21k(14M) / JFT-300M(303M, 비공개)
- 전이 평가: ImageNet, ImageNet-Real, CIFAR-10/100, Pets, Flowers, VTAB(19 tasks, 과제당 1000장)
- 신뢰성 확보를 위해 하위 과제 테스트셋과 겹치는 이미지는 사전학습 데이터에서 제거
- 비교 CNN은 BiT (BN → GN, standardized conv 적용한 ResNet)
- 디테일: pre-train에 Adam이 SGD보다 나았음. ResNet에 대해서도 그러함 → CNN 통념과 어긋나는 관찰

4.2 Comparison to State of the Art

- ViT-H/14 (JFT): ImageNet 88.55%, Real 90.72%, CIFAR-100 94.55%, VTAB 77.63%
- BiT-L 87.54%, Noisy Student 88.4% → 정확도 차이는 1%p 미만으로 작음

- 진짜 메시지는 연산량: ViT-H/14는 2.5k TPuv3-core-days, BiT-L은 9.9k, Noisy Student는 12.3k
- ViT-L/16은 BiT-L과 대등한 성능을 0.68k, 약 1/15 연산으로 달성
- 이 절의 주장은 "더 정확하다"가 아니라 "훨씬 싸게 같은 곳에 도달한다"

4.3 Pre-training Data Requirements

실험 1 — 데이터셋 크기별 ImageNet 전이

- ImageNet-1k: 큰 ViT가 작은 ViT보다도 못함. 정규화를 걸어도 ResNet에 한참 뒤짐
- ImageNet-21k: 거의 동률
- JFT-300M: 모든 크기의 ViT가 ResNet을 능가, 모델이 클수록 이득이 커짐

실험 2 — JFT 부분집합(9M/30M/90M/300M), 하이퍼파라미터 고정

- 데이터 양만 변수로 남긴 더 통제된 실험
- 작은 데이터에서는 ViT가 더 과적합, 큰 데이터에서는 ViT가 앞서며 격차가 계속 벌어짐

해석

- CNN의 inductive bias는 데이터가 적을 때의 지름길(shortcut). "인접 픽셀이 관련 깊다"를 배울 필요 없이 시작하게 해줌
- 데이터가 충분하면 패턴을 직접 배우는 편이 낫다. 하드코딩된 가정은 표현력의 상한을 만들기 때문
- 언어 특화 구조를 버리고 Transformer로 통일된 NLP의 서사와 정확히 같은 모양

4.4 Scaling Study

- 동일 연산 예산에서 ViT / ResNet / Hybrid 비교
- ① ViT는 같은 성능에 2~4배 적은 연산으로 도달
- ② Hybrid는 작은 연산 구간에서만 우세, 모델이 커지면 격차 소멸 → CNN feature가 궁극적으로 불필요하다는 근거
- ③ ViT는 실험 범위 내에서 포화되지 않음 → 이후 ViT-22B(2023)로 이어짐

4.5 Inspecting Vision Transformer

핵심 질문: 구조로 강제하지 않았는데, ViT는 결국 CNN이 하는 일을 스스로 배웠는가?

① Patch embedding 필터 시각화

- 학습된 필터의 주성분이 Gabor 유사 에지·색상 검출기 형태
- CNN 첫 conv 층과 매우 유사 → 강제하지 않아도 같은 저수준 표현에 도달

② Position embedding 유사도

- 각 패치는 자기 자신과 가장 유사, 같은 행/열과 높은 유사도, 멀수록 낮음
- 1D로 초기화했는데 2D 공간 구조를 스스로 학습 → 2D 위치 임베딩이 성능 향상을 못 준 이유가 설명됨 (이미 배웠으니 알려줄 게 없었음)

③ Mean Attention Distance

- attention 가중치 기반 평균 통합 거리 = CNN의 receptive field에 대응
- 가장 낮은 층에서 이미 일부 head가 이미지 전체를 봄. 동시에 같은 층의 다른 head는 아주 좁은 영역만 봄
- 깊어질수록 거리 증가, 깊은 층에서는 거의 모든 head가 global
- 의미1: CNN은 receptive field가 층을 쌓아야만 커지므로 첫 층이 전체를 볼 방법이 없음. ViT는 처음부터 가능
- 의미2: local head도 함께 존재 → ViT는 CNN처럼 행동할 능력을 갖되 강제당하지 않음. 이 유연성이 우위의 원천
- 보조 증거: Hybrid에서는 얇은 층의 local head가 사라짐. CNN이 이미 그 역할을 했기 때문

④ Attention map

- 출력 토큰 → 입력 공간 추적 시 의미론적으로 중요한 영역에 집중
- 이후 DINO가 이 성질을 self-supervised로 극단까지 밀어붙임

4.6 Self-supervision

- BERT의 MLM을 모방한 masked patch prediction (패치 50% 손상 → 평균 색상 3-bit 예측)
- ViT-B/16이 ImageNet 79.9%. from-scratch 대비 +2%p, 그러나 지도 pre-train 대비 4%p
- 대조 학습 기반 방법은 future work로 남김

- 여기서 비워둔 자리를 2년 뒤 MAE, BEiT가 채우며 현재 비전 자기지도 학습의 주류가 됨
-

5. Conclusion

- 초기 패치 추출을 제외하면 이미지 특화 inductive bias를 전혀 도입하지 않음
- 이미지를 패치 시퀀스로 해석하고 NLP 표준 Transformer로 처리
- 단순하지만 확장 가능한 이 전략이 대규모 pre-training과 결합했을 때 놀랍도록 잘 작동
- 남은 과제 3가지
 - detection, segmentation 등 다른 CV 과제로의 적용
 - self-supervised pre-training 방법 탐구
 - 추가 스케일링 (아직 포화되지 않았으므로)