



An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale (ViT)

Logical Flow

[CNN bias의 한계] → (Inductive bias 없이도 이미지 인식이 가능한가?)

→ [문제 정의: 순수 Transformer의 이미지 적용] → (NLP처럼 *pre-train - fine-tuning* 패러다임을 적용)

→ [Core Idea: 이미지를 패치 시퀀스로 취급]

→ [Method: 패치 임베딩 + 표준 Transformer 인코더]

→ (스케일 가설 검증을 위해) → [Experiment: 데이터 규모별 성능 비교]

1 Abstract

Transformer 아키텍처가 NLP의 표준이 되었지만 Computer Vision에서의 적용은 제한적이었다는 문제의식에서 출발합니다. 기존 비전 연구들은 Attention을 CNN과 결합하거나 CNN의 일부 구성 요소를 대체하는 데 그쳤는데, 저자들은 이런 CNN dependency가 필수적이지 않으며, 이미지 패치 시퀀스에 직접 적용한 순수 Transformer만으로도 이미지 분류 과제에서 우수한 성능을 낼 수 있음을 보입니다. 핵심 결과는 대량의 데이터로 사전학습한 후 ImageNet, CIFAR-100, VTAB 등 다양한 벤치마크로 전이했을 때, ViT(Vision Transformer)가 최신 CNN 대비 훨씬 적은 연산 자원으로도 우수한 성능을 달성한다는 것입니다.

One-line argument: "이미지 고유의 *inductive bias*는 필수가 아니다 — 데이터 규모가 충분하면 Transformer 만으로 CNN의 *locality-translation invariance* 가정을 대체할 수 있다."

2 Problem Definition (Research Gap)

Prior works의 한계: NLP에서 Transformer 기반 대규모 pre-train(BERT, GPT)이 표준이 되어 파라미터 규모가 100B 이상 모델도 performance saturation 없이 확장되고 있었습니다. 반면 비전 분야에서는 여전히 CNN 계열 구조(ResNet 등)가 지배적이었고, 어텐션을 도입한 시도들도 이미지 특화된 패턴 — Ex. 국소 이웃에만 어텐션 적용, 축 방향 어텐션 등 — 을 써야 했기에 효율적인 스케일링이 어려웠습니다.

왜 문제인가: NLP에서 Transformer + 대규모 pre-train이 성과를 낸 것과 달리, 비전에서는 "Transformer를 최소한의 수정만으로 적용"한 시도가 부족했습니다. 만약 비전에서도 이것이 가능하다면, CNN이 갖는 *locality-translation invariance* 같은 *designed-intended bias* 없이도 우수한 표현을 학습할 수 있다는 강력한 시사점을 얻을 수 있습니다.

질문 도출: 따라서 저자들은 "Transformer를 이미지 패치 시퀀스에 최소한의 수정으로 적용했을 때, 대규모 pre-train을 거치면 CNN의 *inductive bias* 없이도 경쟁력 있는 성능을 낼 수 있는가?"라는 질문을 던집니다.

reference

related prior work인 *Cordonnier et al. (2020)*이 2×2 패치에 self-attention을 적용했으나, 2×2의 작은 패치 크기로 인해 해상도 이미지에만 적용 가능했다는 한계가 있었고, 이 논문은 중간 해상도 이미지까지 다루면서 대규모 사전학습의 효과를 보인다는 점에서 확장됩니다.

3 Core Idea

이미지를 "1D 시퀀스"로 변환하지 않고, **이미지를 고정 크기 패치들로 자른 뒤, 각 패치를 NLP의 "word)토큰" 취급**하자는 것입니다. 논문 제목 "16x16 Words"가 이를 함축합니다 — 16×16 픽셀 패치 하나가 곧 하나의 "단어"가 됩니다.


NLP에서 문장을 단어들의 시퀀스로 나누어 Transformer에 넣듯이, ViT는 이미지를 패치들의 시퀀스로 나누어 넣습니다. Attention 메커니즘이 단어 간 관계를 학습하듯, 패치 간 공간적 관계를 학습합니다.

기존 방법과의 차이: CNN은 Convolution filter를 통해 "가까운 픽셀끼리 관련 있다 (*locality*)", "같은 패턴은 이미지 어디에 있든 동일하게 인식되어야 한다(*translation invariance*)"는 가정을 아키텍처 설계에 반영합니다. ViT는 이런 가정을 패치 자르기와, *fine-tuning* 시 해상도 변화에 따른 위치 임베딩을 제외하면 아키텍처에 개입하지 않습니다. 즉 공간 구조에 대한 이해를 처음부터 데이터로부터 학습해야 합니다.

저자들은 NLP에서 Transformer의 스케일링 성공(*inductive bias*가 적더라도 **데이터와 연산이 충분**하면 성능이 향상됨)이 비전에도 적용될 것이라 가정했습니다. 다만 이 가정에는 조건이 붙습니다 — 중간 규모 데이터셋에서 정규화 없이 학습하면 비슷한 크기의 ResNet 보다 낮은 성능을 보이는데, 이는 Transformer가 *locality-translation invariance* 같은 CNN *inductive bias*가 없어 불충분한 데이터로 학습할 때 일반화가 되지 않기 때문일 수 있다고 인정합니다. 즉 이 논문은 "**데이터가 충분히 크면(1400만~3억 장)** *inductive bias*의 부재를 압도한다"는 것이며, 이는 실험으로 검증되어야 할 가설로 제시됩니다.


4 Detailed Method

Core Idea(패치=단어)를 실제로 구현하는 절차는 다음과 같습니다.



① 이미지 → 패치 시퀀스 변환

입력 이미지 $\mathbf{x} \in \mathbb{R}^{H \times W \times C}$ 를 $N = \frac{HW}{P^2}$ 개의 $P \times P$ 크기 flatten 패치 $\mathbf{x}_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$ 로 자릅니다. 예를 들어 ViT-L/16은 "Large" 모델에 16×16 패치 크기를 쓴다는 뜻이며, 패치가 작을수록 시퀀스 길이 N 이 늘어나 연산 비용이 커집니다.



② 패치 임베딩 + 클래스 토큰 + 위치 임베딩

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{\text{pos}}, \quad \mathbf{E} \in \mathbb{R}^{(P^2 \cdot C) \times D}, \mathbf{E}_{\text{pos}} \in \mathbb{R}^{(N+1) \times D} \quad (1)$$


각 패치를 학습 가능한 선형 투영으로 D 차원 벡터로 매핑합니다(Eq.1). BERT의 *[class]*

토큰과 유사하게, 임베딩된 패치 시퀀스 앞에 학습 가능한 임베딩을 추가하며, 이 토큰의 Transformer 인코더 출력이 이미지 전체 표현으로 사용됩니다. Transformer는 순서에 무관하므로, 패치 임베딩에 위치 정보를 유지하기 위해 **학습 가능한 1D 위치 임베딩**을 더합니다.

③ 표준 Transformer 인코더 통과

인코더는 Multi-head Self-Attention과 MLP 블록이 교대로 쌓인 구조이며, 각 블록 앞에는 LayerNorm이, 각 블록 뒤에는 residual connection이 적용됩니다. MLP는 GELU 비선형성을 가진 2개 층으로 구성됩니다.

이 부분은 Transformer(Vaswani et al., 2017)와 거의 동일하게 유지하여, NLP에서 이미 검증된 효율적 구현을 그대로 재사용합니다 — 이는 "최소한의 수정"이라는 설계 철학을 그대로 반영한 선택입니다.



④ 분류 헤드

클래스 토큰의 최종 출력에 *pre-train*에는 1 hidden layer MLP, *fine-tuning*에는 단일 linear layer로 구성된 분류 헤드를 부착합니다.

⑤ fine-tuning 시 고해상도 처리

패치 크기는 고정한 채 이미지 해상도만 높여 시퀀스 길이를 늘립니다. 이 경우 *pre-trained* 위치 임베딩의 의미가 없어질 수 있으므로, 원본 이미지 내 위치에 따라 위치 임베딩을 2D 보간합니다. 저자들은 해당 방법론이 **ViT에 직접 2D 구조 정보를 주입하는 유일한 부분**임을 명시합니다.

* 하이브리드 아키텍처 (for ablation)

원본 이미지 패치 대신 CNN의 feature map에서 패치를 추출하는 방식도 실험합니다. Attention은 CNN에서 1×1 크기 패치를 써서 feature map의 공간 차원을 flatten하는 것과 동일해집니다. 이는 "Transformer"와 "CNN+Transformer"을 비교하기 위한 역할을 합니다.

5 Experiment


실험 설계

Problem Definition에서 제기한 질문("데이터 규모가 *inductive bias*의 부재를 얼마나 보완하는가")에 직접 답하기 위해, 저자들은 *ImageNet*(130만 장), *ImageNet-21k*(1,400만 장), *JFT*(3억 장)라는 규모가 다른 세 데이터셋으로 *pre-train*하고 여러 벤치마크에서 성능을 평가하는 실험을 설계합니다. 이는 "단일 데이터셋에서의 최고 성능"이 아니라 **"데이터 규모에 따른 성능 곡선"**을 보기 위한 의도적 설계입니다.



Baseline 선정 역시 Research Gap과 직결됩니다: 대규모 *ResNet* 기반 *Big Transfer*(*BiT*)와, *ImageNet*과 *JFT-300M*에서 *semi-supervised learning*으로 훈련된 *Noisy Student*입니다. 즉 "CNN SOTA"와 비교하여 "CNN *inductive bias* 없이도 이긴다"는 주장을 검증하려는 것입니다.

주요 결과


	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet Real	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k



- SOTA 비교:** JFT-300M으로 사전학습한 ViT-L/16이 같은 데이터셋으로 학습한 BiT-L보다 모든 과제에서 앞서면서도 적은 연산 자원을 사용했고, ViT-H/14는 ImageNet, CIFAR-100, VTAB에서 향상되었습니다.




- 데이터 규모 의존성:** ImageNet처럼 작은 데이터셋으로 *pre-train*하면 ViT-Large가 ViT-Base보다 성능이 떨어지지만, ImageNet-21k에서는 비슷해지고, JFT-300M에서는 큰 모델의 이점이 드러납니다. BiT CNN은 ImageNet에서는 ViT를 능가하지만 큰 데이터셋에서는 ViT가 역전합니다. 이는 Core Idea의 가설("데이터가 충분하면 *inductive bias* 부재를 극복한다")을 증명하는 결과입니다.



3. **성능 대비 연산 비용:** ViT는 *ResNet* 대비 동일 성능에 도달하는 데 약 2~4배 적은 연산을 사용하며, 하이브리드 모델은 작은 연산 예산에서는 ViT보다 약간 우세하지만 모델이 커질수록 그 차이가 사라집니다. 저자들은 이에 대해 convolution의 locality 처리가 어느 크기에서든 ViT를 도울 것이라 예상할 수 있기 때문입니다 — 논문이 스스로 직관에 반하는 결과임을 인정하는 지점입니다.

Ablation



- **내부 표현 분석(4.5절):** 학습된 위치 임베딩이 이미지 내 거리를 유사도로 인코딩하며 (가까운 패치일수록 임베딩이 유사), 행-열 구조까지 학습한다는 점을 확인했습니다. 이는 직접 설계한 2D 인식 위치 임베딩이 효과가 없었던 이유를 설명합니다.
- **어텐션 거리 분석:** 일부 헤드는 하위 레이어에서부터 이미지 대부분에 attention하여 전역적 정보 통합이 사용됨을 보였고, 다른 헤드는 낮은 레이어에서 국소적 attention을 유지했습니다. 이런 국소적 attention 패턴은 *ResNet*을 먼저 적용하는 하이브리드 모델에서는 약했는데, 이는 초기 colvolution 레이어와 유사한 역할을 ViT의 일부 헤드가 대신 학습한다고 해석할 수 있습니다.

Limitation

Pre-train(masked patch prediction)으로는 ViT-B/16이 79.9%를 달성하지만, supervised learning보다는 여전히 4%포인트 낮습니다. 또한 저자들은 *detection·segmentation* 등 다른 비전 과제로의 확장이 과제임을 명시적으로 밝힙니다.



Summary

"이미지 고유의 *inductive bias*는 필수 조건이 아니며, 충분히 큰 데이터가 있다면 표준 Transformer가 그 편향을 데이터로부터 스스로 학습해 CNN을 능가할 수 있다."