

An Image Is Worth 16×16 Words: Transformers for Image Recognition at Scale

논문: <https://arxiv.org/abs/2010.11929>

Abstract

- 기존 computer vision에서는 CNN이 중심이었고, attention은 주로 CNN과 함께 사용되었다.
- 이 논문은 이미지를 여러 patch로 나눈 뒤, 각 patch를 NLP의 token처럼 처리하는 Vision Transformer(ViT)를 제안한다.
- ViT는 convolution 없이 표준 Transformer encoder만으로 image classification을 수행한다.
- 작은 데이터셋에서는 CNN보다 성능이 낮지만, 대규모 데이터로 pre-training하면 CNN과 비슷하거나 더 높은 성능을 보였다.
- 큰 데이터에서 학습한 뒤 작은 downstream dataset으로 transfer하는 방식이 특히 효과적이었다.

1. Introduction

Transformer는 NLP에서 대규모 pre-training과 fine-tuning을 통해 높은 성능을 보였다.

반면 computer vision에서는 다음 inductive bias를 가진 CNN이 주로 사용되었다.

- Locality: 가까운 pixel을 우선적으로 처리
- Translation equivariance: 물체의 위치가 이동해도 비슷한 feature 추출
- 2차원 이미지 구조 활용

ViT는 이러한 CNN 구조를 거의 사용하지 않고, 이미지를 patch sequence로 변환한 뒤 표준 Transformer에 입력한다.


핵심 결과:

- 데이터가 적을 때는 CNN의 inductive bias가 유리하다.

- 데이터가 충분히 많으면 ViT가 필요한 image pattern을 데이터로부터 직접 학습할 수 있다.
- 대규모 pre-training 이후 여러 image classification dataset으로 transfer했을 때 높은 성능을 보였다.

2. Vision Transformer

Vision Transformer 구조



2.1 Image Patch

입력 이미지의 크기를 다음과 같이 나타낸다.

$$x \in \mathbb{R}^{H \times W \times C}$$

- H, W: 이미지의 높이와 너비
- C: channel 수

이미지를 $P \times P$ 크기의 patch로 나누고 각 patch를 1차원 vector로 펼친다.

$$x_p \in \mathbb{R}^{N \times (P^2 C)}$$

Patch의 개수는 다음과 같다.

$$N = \frac{HW}{P^2}$$

예를 들어 224×224 이미지를 16×16 patch로 나누면 다음과 같다.

$$N = \frac{224 \times 224}{16^2} = 196$$

즉 196개의 image patch가 Transformer의 token 역할을 한다.

2.2 Patch Embedding

각 patch는 flatten한 뒤 학습 가능한 linear projection을 통해 D차원 vector로 변환된다.

$$x_p^i E$$

- x_p^i : i번째 flattened patch
- E : 학습 가능한 projection matrix
- D : Transformer의 hidden dimension

이 과정은 NLP에서 token을 embedding vector로 변환하는 것과 유사하다.

2.3 Class Token과 Position Embedding

Patch sequence 앞에 학습 가능한 class token을 추가한다.

$$z_0 = [x_{\text{class}}; x_p^1 E; x_p^2 E; \dots; x_p^N E] + E_{\text{pos}}$$

- x_{class} : 이미지 전체를 대표하는 학습 가능한 class token
- E_{pos} : 학습 가능한 position embedding

Transformer encoder를 모두 통과한 뒤 class token의 최종 representation을 image classification에 사용한다.

Position embedding은 각 patch가 이미지에서 어느 위치에 있었는지를 알려준다.

3. Transformer Encoder

ViT는 original Transformer의 encoder 구조를 사용한다.

각 encoder block:

1. Multi-Head Self-Attention
2. MLP Block

ViT는 Layer Normalization을 sub-layer보다 먼저 적용하는 Pre-LN 구조이다.

Self-Attention block:

$$z'_l = \text{MSA}(\text{LN}(z_{l-1})) + z_{l-1}$$

MLP block:

$$z_l = \text{MLP}(\text{LN}(z'_l)) + z'_l$$

최종 image representation:

$$y = \text{LN}(z_L^0)$$

- z_L^0 : 마지막 encoder layer에서 나온 class token
- MLP는 두 개의 linear layer와 GELU activation으로 구성된다.
- 각 block에는 residual connection이 적용된다.

Self-attention을 통해 각 patch는 이미지의 다른 모든 patch를 직접 참고할 수 있다.

4. ViT와 CNN의 차이

CNN

CNN은 구조적으로 다음 특성을 가진다.

- 가까운 pixel을 먼저 결합한다.
- 이미지의 2차원 이웃 관계를 직접 활용한다.
- 낮은 layer에서는 local feature, 깊은 layer에서는 global feature를 학습한다.

ViT

ViT는 image-specific inductive bias가 적다.

- Patch를 나누는 초기 단계 외에는 convolution을 사용하지 않는다.
- Self-attention은 처음부터 모든 patch 사이의 global relation을 계산할 수 있다.
- 이미지의 locality와 2차원 구조를 대부분 학습 데이터에서 직접 배워야 한다.

따라서 다음 차이가 나타난다.

- 데이터가 적을 때: CNN이 일반적으로 유리
- 데이터가 많을 때: ViT의 확장성과 표현력이 유리

5. Fine-Tuning

ViT는 큰 데이터셋에서 pre-training한 뒤 작은 downstream dataset에 fine-tuning한다.



Fine-tuning할 때는 기존 classification head를 제거하고, 새로운 class 수에 맞는 linear layer를 연결한다.


더 높은 해상도로 fine-tuning하면 patch 개수가 증가한다.

Patch size는 유지하므로 sequence length가 길어지며, 기존 position embedding의 크기가 맞지 않게 된다.

논문에서는 pre-trained position embedding을 2차원 interpolation하여 새로운 해상도에 맞게 조정한다.

6. Experiments





Pre-training 데이터 크기와 성능 비교

6.1 데이터 크기의 영향

- ImageNet과 같은 비교적 작은 데이터로 학습하면 ViT는 비슷한 크기의 ResNet보다 성능이 낮았다.
- ViT는 CNN보다 image-specific inductive bias가 적어 작은 데이터에서 overfitting하기 쉽다.
- ImageNet-21k와 JFT-300M처럼 데이터가 커질수록 ViT의 성능이 빠르게 향상되었다.
- 큰 ViT model의 장점도 대규모 dataset에서 더 뚜렷하게 나타났다.

즉 ViT의 핵심은 단순히 Transformer를 이미지에 적용한 것이 아니라, 대규모 pre-training과 결합했다는 점이다.

6.2 CNN과의 비교

JFT-300M으로 pre-training한 ViT-H/14는 다음 성능을 기록했다.

- ImageNet: 88.55%
- CIFAR-100: 94.55%
- VTAB 19개 task 평균: 77.63%

ViT는 비슷한 성능의 ResNet보다 적은 pre-training compute를 사용하는 경향을 보였다.

논문의 controlled scaling experiment에서는 동일한 성능을 달성할 때 ViT가 대략 2~4배 적은 compute를 사용했다.

6.3 Patch Size

ViT-L/16에서 16은 patch size가 16×16이라는 뜻이다.

Patch size가 작아지면 다음과 같은 변화가 발생한다.

- Patch 수 증가
- Sequence length 증가
- 더 세밀한 이미지 정보 유지
- Self-attention 계산량 증가


Patch 개수는 patch size의 제곱에 반비례한다.

$$N = \frac{HW}{P^2}$$

따라서 patch size를 절반으로 줄이면 patch 수는 4배가 된다.

6.4 ViT 내부 표현

ViT의 embedding과 attention 분석



논문의 분석 결과:

- 초기 linear projection은 patch 내부의 edge와 texture와 비슷한 pattern을 학습했다.
- 학습된 position embedding은 가까운 patch끼리 비슷한 값을 가지며 이미지의 행·열 구조를 반영했다.
- 낮은 layer에서도 일부 attention head는 이미지 전체를 넓게 참고했다.
- 다른 head는 가까운 영역에 집중하여 CNN의 local receptive field와 유사한 역할을 수행했다.

- Network가 깊어질수록 대부분의 head가 더 넓은 영역을 참고했다.
-

7. Self-Supervision

논문은 BERT의 masked language modeling과 비슷하게 일부 patch를 가리고 복원하는 self-supervised 학습도 시험했다.

- Self-supervised ViT-B/16: ImageNet 79.9%
- 처음부터 supervised training한 것보다 약 2% 높았다.
- 대규모 supervised pre-training보다는 약 4% 낮았다.

가능성은 확인했지만, 논문의 주요 결과는 대규모 supervised pre-training에 기반한다.

8. Conclusion

- ViT는 이미지를 patch sequence로 바꾸고 표준 Transformer encoder로 처리한다.
- 작은 데이터에서는 CNN보다 불리하지만, 대규모 pre-training을 사용하면 높은 성능을 보인다.
- 이 논문은 CNN 없이도 Transformer가 image classification의 backbone으로 사용될 수 있음을 보여주었다.