

# AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE (ViT)

## 서론

### 연구 배경

Transformer는 self-attention을 기반으로 입력 요소 사이의 관계를 학습하는 구조로, 자연어 처리 분야에서 큰 성공을 거두었다. 특히 대규모 말뭉치에서 모델을 사전학습한 뒤, 상대적으로 작은 데이터셋의 세부 과제에 fine-tuning하는 방식이 자연어 처리의 일반적인 학습 방법으로 자리 잡았다.

반면 컴퓨터 비전 분야에서는 CNN이 오랫동안 중심적인 구조로 사용되었다. CNN은 작은 영역을 처리하는 convolution filter를 이미지 전체에 반복적으로 적용함으로써 지역적인 패턴을 효과적으로 포착한다. 또한 인접한 픽셀 사이의 관계와 위치 변화에 대한 특성이 모델 구조에 포함되어 있기 때문에, 비교적 적은 데이터로도 이미지의 공간적 구조를 효율적으로 학습할 수 있다.

기존에도 이미지에 self-attention을 적용하려는 연구가 있었지만, 대부분 CNN과 attention을 결합하거나 이미지에 맞게 attention의 범위를 제한하는 방식을 사용했다. 이미지의 모든 픽셀을 각각 하나의 토큰으로 취급하면 self-attention의 계산량이 픽셀 수의 제곱에 비례하여 증가하기 때문이다. 이로 인해 기존 연구에서는 attention을 가까운 영역에만 적용하거나, 이미지의 특정 축을 따라 계산하는 등 이미지 전용 구조가 필요했다.

이 논문은 이와 달리 다음과 같은 질문에서 출발한다.

이미지에 특화된 복잡한 구조나 CNN을 사용하지 않고, 자연어 처리에서 사용하던 표준 Transformer를 이미지 분류에 직접 적용할 수 있는가?

저자들은 이미지를 픽셀 단위가 아니라 일정한 크기의 패치로 나누고, 각 패치를 자연어의 단어와 같은 하나의 토큰으로 처리하는 Vision Transformer(ViT)를 제안한다.

### 논문의 핵심 주장

이 논문의 핵심은 단순히 Transformer를 이미지에 적용했다는 데 있지 않다. ViT는 CNN보다 이미지에 특화된 귀납적 편향이 적기 때문에 데이터가 충분하지 않을 때에는 비슷한 크

기의 CNN보다 낮은 성능을 보인다. 그러나 ImageNet-21k나 JFT-300M처럼 대규모 데이터셋으로 사전학습한 뒤 작은 이미지 분류 데이터셋에 전이하면, 기존 CNN 기반 모델과 비슷하거나 더 높은 성능을 달성한다.

따라서 논문의 핵심 주장은 "Transformer가 항상 CNN보다 우수하다"가 아니라, 충분한 규모의 데이터와 연산 자원이 주어진다면 ViT가 CNN에 구조적으로 포함된 이미지 특성을 데이터로부터 직접 학습할 수 있다는 것이다. 이는 CNN의 강한 귀납적 편향과 Transformer의 높은 확장성 사이의 관계를 보여준다는 점에서 의미가 있다.

## 본론

### 이미지를 패치 시퀀스로 변환하는 방법

표준 Transformer는 단어와 같은 1차원 토큰 시퀀스를 입력으로 받는다. 따라서 ViT를 이미지에 적용하려면 먼저 2차원 이미지를 Transformer가 처리할 수 있는 토큰 시퀀스로 변환해야 한다.

입력 이미지를 다음과 같이 두자.

$$\mathbf{x} \in \mathbb{R}^{H \times W \times C}$$

여기서  $H$ 와  $W$ 는 이미지의 높이와 너비이고,  $C$ 는 채널 수이다. ViT는 이 이미지를  $P \times P$  크기의 겹치지 않는 패치로 나눈다. 이때 생성되는 패치의 수  $N$ 은 다음과 같다.

$$N = \frac{HW}{P^2}$$

각 패치는  $P \times P \times C$  형태를 가지며, 이를 하나의 벡터로 펼치면 길이가  $P^2C$ 인 벡터가 된다. 이후 학습 가능한 선형 변환을 적용하여 모든 패치를 Transformer가 사용하는  $D$ 차원의 벡터로 변환한다. 이렇게 얻은 벡터를 **patch embedding**이라고 한다.

예를 들어  $224 \times 224$  이미지를  $16 \times 16$  패치로 나누면 가로와 세로에 각각 14개의 패치가 만들어지므로, 전체 이미지는 196개의 패치 토큰으로 표현된다. 논문 제목의 "16x16 Words"는 바로 이처럼  $16 \times 16$  크기의 이미지 패치를 자연어의 단어처럼 처리한다는 의미를 담고 있다.

### Classification token과 position embedding


ViT는 패치 토큰만으로 구성된 시퀀스의 맨 앞에 학습 가능한 **classification token**을 추가한다. 논문에서는 이를  $\mathbf{x}_{\text{class}}$ 로 표현한다. 이 토큰은 BERT의 **[CLS]** 토큰과 유사한 역할을 하며, Transformer encoder를 통과하면서 전체 이미지의 정보를 종합한다.

패치들을 단순한 시퀀스로 변환하면 각 패치가 원래 이미지에서 어느 위치에 있었는지 알 수 없게 된다. 이를 보완하기 위해 각 토큰에 학습 가능한 **position embedding**을 더한다. 최종 입력 시퀀스는 다음과 같이 표현된다.

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{\text{pos}}$$

여기서  $\mathbf{E}$ 는 펼쳐진 패치를  $D$ 차원으로 변환하는 선형 투영 행렬이며,  $\mathbf{E}_{\text{pos}}$ 는 각 토큰의 위치를 나타내는 position embedding이다.

논문에서는 이미지의 2차원 구조를 명시적으로 반영한 복잡한 position embedding이 아니라, 표준적인 학습 가능한 1차원 position embedding을 사용한다. 그럼에도 모델이 학습 과정에서 패치 사이의 2차원 위치 관계를 스스로 학습한다는 점은 이후의 내부 표현 분석에서 확인된다.



ViT 전체 구조 개요(패치 분할 → 선형 투영 → position embedding → Transformer encoder → MLP head).

## Transformer encoder와 이미지 분류

패치 토큰, classification token, position embedding으로 구성된 입력은 표준 Transformer encoder에 전달된다. 각 encoder block은 multi-head self-attention과 MLP block으로 구성된다.

Multi-head self-attention은 각 패치가 다른 모든 패치와 어떤 관련이 있는지를 계산한다. CNN이 작은 지역에서부터 정보를 결합하는 것과 달리, ViT의 패치 토큰은 첫 번째 계층부

터 이미지 전체의 다른 패치들을 참고할 수 있다. 여러 개의 attention head는 서로 다른 관계를 동시에 학습하며, 일부 head는 가까운 영역에 집중하고 다른 head는 멀리 떨어진 영역까지 폭넓게 참고할 수 있다.

Self-attention의 출력은 residual connection을 통해 기존 표현과 더해진다. 이후 두 개의 선형 계층과 GELU 활성화 함수로 구성된 MLP block을 통과하며, 이 과정에도 residual connection이 적용된다. Layer Normalization은 각 attention 및 MLP block의 앞에 배치된다.

마지막 Transformer 계층을 통과한 classification token의 표현에 Layer Normalization을 적용하여 이미지 전체의 표현을 얻는다.

$$\mathbf{y} = \text{LN}(\mathbf{z}_L^0)$$

이 표현은 classification head에 전달되어 최종 이미지의 클래스를 예측하는 데 사용된다. 사전학습 단계에서는 하나의 은닉층을 포함한 MLP head를 사용하고, fine-tuning 단계에서는 하나의 선형 계층을 사용한다.

## CNN과 ViT의 귀납적 편향 차이

CNN에는 이미지의 구조에 적합한 여러 귀납적 편향이 포함되어 있다. Convolution filter는 가까운 픽셀이나 특징만을 처리하기 때문에 **locality**를 가지며, 동일한 filter를 이미지 전체에 반복적으로 사용함으로써 위치가 달라져도 같은 특징을 감지할 수 있다(**translation equivariance**). 또한 이미지가 2차원 공간에서 구성된다는 사실이 모든 계층에 구조적으로 반영된다.

반면 ViT에서는 이러한 편향이 훨씬 약하게 나타난다. 논문의 표현을 빌리면, ViT에서 지역성과 translation equivariance를 갖는 것은 MLP 계층뿐이며, self-attention 계층은 기본적으로 모든 패치 사이의 관계를 전역적으로 계산한다. 이미지의 2차원 구조는 이미지를 패치로 나누는 초기 단계와 fine-tuning 과정에서 position embedding을 보간하는 단계에서만 제한적으로 사용된다. 따라서 어떤 패치가 서로 가까운지, 또는 같은 행과 열에 있는지를 모델이 학습 과정에서 직접 알아내야 한다.

이러한 차이는 ViT의 장점이면서 동시에 약점이다. 데이터가 부족할 때에는 CNN에 포함된 귀납적 편향이 효율적인 학습을 돕기 때문에 CNN의 일반화 성능이 더 높다. 반면 데이터가 충분히 크다면 ViT는 특정한 이미지 구조에 덜 제한된 상태에서 필요한 패턴을 데이터로부터 유연하게 학습할 수 있다.

## Hybrid architecture와 fine-tuning

논문에서는 순수한 ViT뿐만 아니라 CNN과 Transformer를 결합한 hybrid architecture도 실험한다. Hybrid architecture에서는 원본 이미지 패치 대신 ResNet에서 추출한

feature map을 Transformer의 입력으로 사용한다. CNN이 먼저 이미지의 지역적 특징을 추출하고, Transformer가 이 특징들 사이의 전역적인 관계를 학습하는 구조이다.

ViT는 먼저 대규모 데이터셋에서 사전학습한 뒤, 상대적으로 작은 downstream dataset에서 fine-tuning한다. Fine-tuning할 때는 사전학습에 사용한 prediction head를 제거하고, downstream task의 클래스 수에 맞는 새로운 classification head를 연결한다.

Fine-tuning에서는 사전학습보다 높은 해상도의 이미지를 사용하는 것이 유리할 수 있다. 패치 크기를 유지한 상태에서 이미지 해상도를 높이면 패치의 수와 입력 시퀀스의 길이가 증가한다. 이 경우 기존 position embedding의 크기가 새로운 패치 배열과 맞지 않으므로, 논문에서는 사전학습된 position embedding에 2차원 보간을 적용하여 새로운 해상도에 맞춘다.

## 실험 데이터와 모델 구성

저자들은 데이터 규모가 ViT와 CNN의 성능에 어떤 영향을 미치는지 확인하기 위해 크기가 서로 다른 세 개의 데이터셋을 사전학습에 사용한다.

- ImageNet: 약 130만 개의 이미지와 1,000개의 클래스
- ImageNet-21k: 약 1,400만 개의 이미지와 21,000개의 클래스
- JFT-300M: 약 3억 300만 개의 이미지와 18,000개의 클래스

사전학습된 모델은 ImageNet, ImageNet-Real, CIFAR-10, CIFAR-100, Oxford-IIIT Pets, Oxford Flowers-102 및 VTAB에 전이하여 평가한다. VTAB은 자연 이미지, 의료, 위성 이미지와 같은 전문 이미지, 위치 및 기하학적 구조를 이해해야 하는 이미지 등 서로 다른 19개의 분류 과제로 구성되어 있다.

ViT의 모델 크기는 BERT의 구성을 바탕으로 Base, Large, Huge로 구분한다.

| 모델        | Transformer 계층 수 | Hidden size | Attention head 수 | 파라미터 수 |
|-----------|------------------|-------------|------------------|--------|
| ViT-Base  | 12               | 768         | 12               | 86M    |
| ViT-Large | 24               | 1,024       | 16               | 307M   |
| ViT-Huge  | 32               | 1,280       | 16               | 632M   |

모델 이름 뒤의 숫자는 입력 패치의 크기를 의미한다. 예를 들어 ViT-L/16은 Large 모델에  $16 \times 16$  크기의 패치를 사용한 모델이고, ViT-H/14는 Huge 모델에  $14 \times 14$  크기의 패치를 사용한 모델이다. 패치가 작아질수록 토큰의 수가 증가하므로 더 세밀한 정보를 사용할 수 있지만, self-attention의 계산량도 함께 증가한다.

모든 모델의 사전학습에는 Adam optimizer, 4,096의 batch size, 0.1의 weight decay를 사용한다. Fine-tuning에서는 momentum을 적용한 SGD와 512의 batch size를 사용

한다. 비교 대상으로는 Group Normalization과 standardized convolution을 적용한 ResNet 기반의 BiT 모델과 CNN-Transformer hybrid model을 사용한다.

## 기존 모델과의 성능 비교

JFT-300M으로 사전학습한 ViT-L/16은 동일한 데이터로 사전학습한 ResNet 기반 BiT-L보다 논문에서 평가한 모든 downstream task에서 높은 성능을 기록했다. 더 큰 ViT-H/14는 ImageNet에서 88.55%, ImageNet-Real에서 90.72%, CIFAR-100에서 94.55%, VTAB 19개 과제 평균에서 77.63%의 정확도를 기록했다.

사전학습에 사용된 연산량에서도 차이가 나타났다. ViT-H/14는 약 2,500 TPuv3-core-days를 사용한 반면, BiT-L은 약 9,900 TPuv3-core-days를 사용했다. ViT-L/16은 ViT-H/14보다 작은 모델이면서도 BiT-L을 모든 과제에서 능가했고, 약 680 TPuv3-core-days만을 사용했다.


다만 이러한 비교 결과가 오직 모델 구조의 차이에서만 발생했다고 단정하기는 어렵다. 학습 일정, optimizer, weight decay 등의 설정도 사전학습 효율에 영향을 줄 수 있기 때문이다. 논문에서도 이 점을 언급하고 있으며, 이후 별도의 scaling study에서 모델별 성능과 연산량의 관계를 보다 통제된 조건에서 비교한다.

## 데이터 규모와 귀납적 편향의 관계

ViT의 성능을 이해하기 위해 가장 중요하게 살펴봐야 할 부분은 사전학습 데이터의 규모에 따른 변화이다.

ImageNet처럼 상대적으로 작은 데이터셋으로 사전학습하면 ViT-Large는 더 작은 ViT-Base보다 오히려 낮은 성능을 보인다. 모델의 크기가 커졌지만 학습할 데이터가 충분하지 않아 과적합이 심해졌기 때문이다. 이 조건에서는 CNN 기반 BiT가 ViT보다 높은 성능을 기록한다.


ImageNet-21k로 데이터 규모를 늘리면 ViT-Large와 ViT-Base의 성능 차이가 줄어든다. JFT-300M으로 사전학습했을 때에는 큰 ViT 모델의 장점이 뚜렷해지고, ViT가 CNN 기반 모델의 성능을 넘어선다. 즉, 모델을 크게 만드는 것만으로 성능이 향상되는 것이 아니라, 큰 모델이 충분한 데이터와 함께 사용될 때 확장성의 장점이 나타난다.



사전학습 데이터셋(ImageNet / ImageNet-21k / JFT-300M) 규모에 따른 ImageNet 전이 성능. 작은 데이터에서는 큰 ViT가 BiT보다 낮지만, 데이터가 커질수록 역전된다.

저자들은 JFT-300M에서 각각 900만, 3,000만, 9,000만 개의 이미지를 추출한 부분집합도 사용하여 데이터 규모의 영향을 추가로 분석했다. 이 실험에서는 연산 비용을 줄이기 위해 fine-tuning 대신 few-shot linear accuracy를 지표로 사용한다. 적은 데이터에서는 비슷한 연산량을 사용하는 ResNet이 ViT보다 높은 성능을 기록했지만, 데이터 규모가 커질수록 ResNet의 성능 향상은 비교적 일찍 둔화되었다. 반면 ViT는 데이터가 증가하면서 계속 성능이 향상되었고, 충분히 큰 데이터에서는 ResNet을 넘어섰다.

이 결과는 데이터가 부족한 상황에서는 CNN의 locality와 translation equivariance가 효과적인 사전 지식으로 작용하지만, 데이터가 충분한 상황에서는 이러한 구조를 고정하지 않고 필요한 공간적 관계를 학습하는 ViT가 더 유리할 수 있음을 보여준다.




JFT 부분집합(9M~300M) 크기에 따른 ImageNet linear 5-shot 성능. ResNet은 일찍 포화되고 ViT는 데이터가 커질수록 계속 향상된다.

## 모델 확장성과 연산 효율

저자들은 JFT-300M을 사용하여 ViT, ResNet, hybrid model의 전이 성능과 사전학습 연산량 사이의 관계를 비교했다. 데이터 규모를 충분히 크게 고정한 상태에서 여러 크기의 모델을 학습함으로써 각 구조의 scaling 특성을 분석한 것이다.

실험 결과 ViT는 동일한 수준의 성능에 도달하는 데 ResNet보다 평균적으로 약 2~4배 적은 사전학습 연산량을 사용했다. 작은 모델과 적은 연산량에서는 CNN의 지역적 특징 추출을 활용하는 hybrid model이 순수 ViT보다 약간 높은 성능을 보였다. 그러나 모델과 연산량이 커지면서 두 모델 사이의 차이는 거의 사라졌다.

또한 논문에서 실험한 범위 안에서는 ViT의 성능이 명확하게 포화되는 현상이 나타나지 않았다. 이는 더 큰 모델과 더 많은 데이터가 주어진다면 ViT의 성능이 추가로 향상될 가능성이 있음을 보여준다.




사전학습 연산량(exaFLOPs) 대비 전이 성능. 같은 연산량에서 ViT가 ResNet을 앞섰고, hybrid의 이점은 큰 모델에서 사라진다.

## ViT가 학습한 이미지 표현

저자들은 ViT가 CNN과 같은 구조 없이 이미지의 공간적 특성을 실제로 학습하는지 확인하기 위해 모델의 내부 표현을 분석한다.


먼저 초기 patch embedding에 사용되는 선형 투영 행렬의 주성분을 시각화했다. 그 결과 패치 내부의 세부적인 구조를 표현할 수 있는 기저 패턴들이 학습된 것을 확인할 수 있었다. 이는 초기 patch embedding이 단순히 픽셀을 압축하는 것이 아니라, 패치 내부의 시각적 특징을 표현하는 역할을 수행한다는 것을 보여준다.

학습된 position embedding 사이의 유사도를 분석한 결과, 원래 이미지에서 가까운 패치일수록 비슷한 position embedding을 갖는 경향이 나타났다. 같은 행이나 열에 위치한 패치 사이에서도 규칙적인 구조가 관찰되었다. ViT에는 학습 초기에 이미지의 2차원 위치 관계가 명시적으로 주어지지 않지만, 학습 과정에서 패치들의 2차원 배치를 스스로 복원한 것이다.



patch embedding 선형 투영 행렬의 주성분 필터, position embedding 사이의 코사인 유사도. 가까운 패치, 같은 행/열의 패치가 유사한 embedding을 갖는다.


Attention distance를 분석한 결과, 낮은 계층의 일부 attention head는 가까운 패치에 집중했다. 이는 CNN의 초기 convolution layer가 지역적인 특징을 추출하는 것과 유사한 역할로 볼 수 있다. 반면 다른 attention head는 첫 번째 계층부터 이미지의 넓은 영역을 참고했다. 이를 통해 ViT가 낮은 계층에서도 지역적 정보와 전역적 정보를 함께 처리할 수 있다는 점을 확인할 수 있다. 네트워크가 깊어질수록 평균적인 attention distance는 증가했다.



head별, 계층별 평균 attention distance(CNN의 receptive field에 대응). 낮은 계층에서는 head마다 편차가 크고, 깊어질수록 모든 head의 attention distance가 증가한다.

또한 최종 classification token은 이미지 분류에 의미 있는 객체 영역을 중심으로 정보를 종합하는 모습을 보였다. 즉 모델이 배경보다 분류에 실제로 관련 있는 영역에 attention을

집중한다는 것을 확인할 수 있다.



출력 토큰에서 입력 공간으로의 attention map 예시. 모델이 분류에 의미 있는 객체 영역에 집중함을 보여준다.

## Self-supervised learning

자연어 처리에서 Transformer의 성공에는 대규모 self-supervised pre-training이 중요한 역할을 했다. 이에 저자들은 BERT의 masked language modeling과 유사하게 이미지의 일부 패치를 가린 뒤 이를 예측하는 **masked patch prediction** 방식도 실험했다.

Self-supervised pre-training을 적용한 ViT-B/16은 ImageNet에서 79.9%의 정확도를 기록했다. 이는 사전학습 없이 처음부터 supervised training한 경우보다 약 2%p 높은 결과였지만, supervised pre-training을 적용한 경우보다는 약 4%p 낮았다.

따라서 이 실험은 이미지에서도 Transformer 기반 self-supervised learning이 가능하다는 점을 보여주지만, 논문에서 사용한 초기 방식만으로 대규모 supervised pre-training을 대체할 수 있음을 의미하지는 않는다. 저자들도 이를 예비적인 실험으로 제시하며, contrastive learning을 포함한 더 발전된 self-supervised learning을 향후 연구 과제로 남긴다.

## 결론

### 연구의 의의

이 논문의 가장 중요한 기여는 이미지를 고정된 크기의 패치 시퀀스로 변환하는 단순한 방법만으로 표준 Transformer를 이미지 분류에 적용할 수 있음을 보여준 것이다. 기존의 복잡한 이미지 전용 attention 구조나 CNN backbone에 의존하지 않고도, 대규모 사전학습이 주어지면 순수 Transformer가 높은 성능을 낼 수 있음을 실험적으로 입증했다.

또한 CNN과 ViT의 차이를 단순한 성능 비교가 아니라 데이터 규모와 귀납적 편향의 관계를 통해 설명했다는 점에서 의미가 있다. CNN의 귀납적 편향은 데이터가 부족한 상황에서 효과적인 사전 지식으로 작용하지만, 충분한 데이터가 주어진 상황에서는 오히려 구조적 제약이 적은 ViT가 더 큰 모델과 데이터를 효과적으로 활용할 수 있다.

ViT는 자연어 처리에서 일반적으로 사용되던 대규모 사전학습과 downstream fine-tuning 방식을 컴퓨터 비전에서도 효과적으로 적용할 수 있음을 보여주었다. 따라서 이 논문은 Transformer가 자연어뿐 아니라 이미지에서도 범용적인 표현 학습 구조로 사용될 수 있다는 가능성을 제시했다.

## 한계점

ViT의 높은 성능은 대규모 사전학습 데이터에 크게 의존한다. ImageNet 수준의 데이터에서는 큰 ViT 모델이 CNN보다 낮은 성능을 보였으며, 가장 높은 성능은 약 3억 개의 이미지를 포함한 JFT-300M을 사용했을 때 나타났다. 따라서 데이터와 연산 자원이 제한된 환경에서는 논문에서 제시한 ViT의 장점을 그대로 얻기 어렵다.

특히 JFT-300M은 공개 데이터셋이 아니므로, 가장 중요한 실험 결과를 일반적인 연구 환경에서 완전히 재현하기 어렵다는 한계가 있다. ViT가 ResNet보다 연산 효율적인 성능-연산량 관계를 보였더라도, ViT-H/14의 사전학습에 사용된 절대적인 연산량은 여전히 매우 크다.

또한 논문의 실험은 이미지 분류에 집중되어 있다. 저자들은 object detection과 segmentation 같은 다른 컴퓨터 비전 과제로 ViT를 확장하는 것을 향후 과제로 제시한다. Self-supervised learning 역시 가능성은 확인했지만 supervised pre-training과의 성능 차이가 남아 있어, 보다 효과적인 사전학습 방법이 필요하다.

패치 크기가 작아지거나 이미지 해상도가 높아지면 토큰 수가 증가하고, self-attention의 계산량도 토큰 수의 제곱에 비례하여 커진다. 따라서 높은 해상도의 이미지를 효율적으로 처리하는 문제 역시 ViT 구조에서 고려해야 할 부분이다.

## 종합 평가

Vision Transformer의 핵심은 단순히 CNN을 Transformer로 교체한 데 있지 않다. 이 논문은 모델 구조에 강한 이미지 사전 지식을 넣는 방법과, 더 많은 데이터로 필요한 구조를 직접 학습하게 하는 방법 사이의 관계를 보여준다.

작은 데이터에서는 CNN의 귀납적 편향이 분명한 장점을 가지지만, 데이터와 모델 규모가 커질수록 ViT의 유연성과 확장성이 드러난다. 결국 이 논문이 보여준 가장 중요한 결과는

Transformer가 이미지에서도 작동한다는 사실 자체보다, 충분한 규모의 학습이 주어질 때 이미지에 특화된 강한 귀납적 편향 없이도 경쟁력 있는 시각 표현을 학습할 수 있다는 점이다.