

3주차_논문과제_23기_정준호

An Image Is Worth 16×16 Words: Transformers for Image Recognition at Scale

1. Introduction

1.1. NLP의 Transformer와 컴퓨터 비전의 현실

- Self-attention 기반 구조, 특히 Transformer는 NLP에서 표준으로 자리 잡았으며, 대규모 코퍼스에 사전학습한 뒤 과제별 데이터로 미세조정하는 방식이 지배적입니다.
- Transformer의 계산 효율성과 확장성 덕분에 1000억 개가 넘는 파라미터 규모의 모델까지 학습이 가능해졌고, 모델과 데이터가 커져도 성능이 포화되는 조짐은 아직 보이지 않습니다.
- 반면 컴퓨터 비전에서는 여전히 합성곱 구조가 지배적입니다. CNN에 self-attention을 결합하거나 합성곱을 아예 대체하려는 시도가 있었지만, 특수한 attention 패턴을 사용하기 때문에 최신 하드웨어 가속기에서 효과적으로 확장되지 못했습니다.
- 그 결과 대규모 이미지 인식에서는 여전히 ResNet 계열이 최고 성능을 유지하고 있었습니다.

1.2. 논문의 제안

- 본 논문은 이미지에 표준 Transformer를 **최소한의 변경만 가해** 그대로 적용합니다. 이미지를 패치로 자르고, 각 패치의 선형 임베딩 시퀀스를 Transformer의 입력으로 넣습니다.
- 즉 이미지 패치를 NLP의 토큰(단어)과 완전히 동일하게 취급하며, 이미지 분류를 지도학습 방식으로 학습합니다.
- **중간 규모 데이터의 한계:** 강한 정규화 없이 ImageNet 정도의 데이터로만 학습하면, 비슷한 크기의 ResNet보다 몇 퍼센트포인트 낮은 정확도에 그칩니다. Transformer에는 translation equivariance나 locality 같은 CNN 고유의 inductive bias가 없기 때문에 데이터가 부족하면 일반화가 잘 되지 않습니다.
- **대규모 데이터에서의 반전:** 1400만~3억 장 규모로 학습하면 상황이 뒤집힙니다. 저자들은 이를 "대규모 학습이 inductive bias를 이긴다"고 표현합니다.
- ImageNet-21k나 JFT-300M으로 사전학습한 Vision Transformer(ViT)는 ImageNet 88.55%, ImageNet-Real 90.72%, CIFAR-100 94.55%, VTAB 19개 과제 77.63%

를 기록했습니다.


2. Related Work

2.1. 이미지에 Transformer를 적용하려는 시도

- Self-attention을 이미지에 그대로 적용하면 모든 픽셀이 다른 모든 픽셀을 참조해야 하므로 픽셀 수에 대해 제곱 비용이 들어 현실적인 입력 크기로 확장할 수 없습니다.
- 이를 우회하기 위해 query 픽셀 주변의 국소 이웃에만 attention을 적용하거나, Sparse Transformer처럼 전역 self-attention을 근사하거나, 축 방향으로만 attention을 적용하는 방식 등이 제안되었습니다.
- 이런 특수 attention 구조들은 좋은 결과를 보였지만, 하드웨어 가속기에서 효율적으로 구현하려면 복잡한 엔지니어링이 필요했습니다.
- **가장 가까운 선행 연구:** Cordonnier et al.(2020)은 2×2 패치를 추출해 full self-attention을 적용했습니다. ViT와 매우 유사하지만, 패치가 2×2 로 너무 작아 저해상도 이미지에만 쓸 수 있었습니다. 본 논문은 대규모 사전학습을 통해 순수 Transformer가 최고 수준의 CNN과 경쟁하거나 능가할 수 있음을 보인 점에서 한 걸음 더 나아갑니다.
- **iGPT:** 해상도와 색 공간을 줄인 뒤 픽셀에 Transformer를 적용해 비지도 생성 모델로 학습한 연구로, ImageNet에서 최대 72% 정확도를 기록했습니다.

2.2. 대규모 데이터셋 기반 이미지 인식

- 표준 ImageNet보다 큰 규모에서 이미지 인식을 탐구하는 연구 흐름이 있으며, 추가 데이터를 활용해 벤치마크 최고 성능을 갱신해 왔습니다.
- 특히 CNN 성능이 데이터셋 크기에 따라 어떻게 확장되는지를 연구하거나, ImageNet-21k와 JFT-300M 같은 대규모 데이터에서의 전이학습을 실증적으로 탐구한 연구들이 있습니다.
- 본 논문도 같은 두 데이터셋에 집중하되, ResNet 대신 Transformer를 학습한다는 점이 다릅니다.



3. Method

3.1. Vision Transformer (ViT)

- **설계 원칙:** 원본 Transformer를 최대한 그대로 따릅니다. 이렇게 하면 이미 확장성이 검증된 NLP Transformer 구조와 그 효율적인 구현체를 거의 그대로 가져다 쓸 수 있다는 장점이 있습니다.
- **패치 분할:** 2D 이미지 $x \in \mathbb{R}^{(H \times W \times C)}$ 를 flatten된 2D 패치 시퀀스 $x_p \in \mathbb{R}^{(N \times (P^2 \cdot C))}$ 로 재구성합니다. (P, P)는 패치 해상도이며, 패치 개수 $N = HW/P^2$ 가 곧 Transformer의 입력 시퀀스 길이가 됩니다.
- **Patch Embedding:** 모든 층에서 일정한 잠재 벡터 크기 D 를 사용하므로, 패치를 flatten한 뒤 학습 가능한 선형 투영으로 D 차원에 사상합니다. 이 출력을 patch embedding이라 부릅니다.
- **[class] 토큰:** BERT의 [class] 토큰과 마찬가지로 학습 가능한 임베딩을 시퀀스 앞에 붙이고, Transformer 인코더 출력에서의 그 상태를 이미지 표현 y 로 사용합니다. 사전학습 시에는 은닉층 하나짜리 MLP, 미세조정 시에는 단일 선형 층을 분류 헤드로 붙입니다.
- **Position Embedding:** 위치 정보를 유지하기 위해 patch embedding에 더해집니다. 표준적인 **학습형 1D position embedding**을 사용했는데, 더 정교한 2D 인식 방식을 써도

유의미한 성능 향상이 없었기 때문입니다.

- **인코더 구조:** Multi-head Self-Attention(MSA)과 MLP 블록이 번갈아 쌓입니다. 모든 블록 **앞**에 LayerNorm(pre-norm)을 적용하고 **뒤**에 잔차 연결을 둡니다. MLP는 GELU 비선형성을 갖는 두 개의 층으로 구성됩니다.

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{\text{pos}}, \quad \mathbf{E} \in \mathbb{R}^{(P^2 \cdot C) \times D}, \mathbf{E}_{\text{pos}} \in \mathbb{R}^{(N+1) \times D} \quad (1)$$

$$\mathbf{z}'_\ell = \text{MSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1}, \quad \ell = 1 \dots L \quad (2)$$

$$\mathbf{z}_\ell = \text{MLP}(\text{LN}(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell, \quad \ell = 1 \dots L \quad (3)$$

$$\mathbf{y} = \text{LN}(\mathbf{z}_L^0) \quad (4)$$

- **원본 Transformer와의 차이:** 인코더만 사용하고, LayerNorm 위치가 pre-norm이며, ReLU 대신 GELU를, 사인 함수 대신 학습형 position embedding을 사용합니다.

3.2. Inductive Bias

- ViT는 CNN보다 이미지 고유의 inductive bias가 훨씬 적습니다. CNN은 locality, 2차원 이웃 구조, translation equivariance가 모든 층에 내장되어 있습니다.
- ViT에서는 MLP 층만 국소적이고 translation equivariant하며, self-attention 층은 전역적입니다.
- 2차원 이웃 구조는 아주 제한적으로만 사용됩니다. 모델 초입에서 이미지를 패치로 자를 때, 그리고 미세조정 시 해상도가 달라진 position embedding을 조정할 때뿐입니다.
- 그 외에는 초기화 시점의 position embedding이 패치의 2D 위치에 대한 정보를 전혀 갖고 있지 않으며, 패치 사이의 모든 공간 관계를 밑바닥부터 학습해야 합니다.

3.3. Hybrid Architecture

- 원본 이미지 패치 대신 **CNN feature map**에서 추출한 패치에 임베딩 투영 E를 적용하는 방식도 가능합니다.
- 특수한 경우로 패치 크기를 1×1로 두면, feature map의 공간 차원을 단순히 flatten한 뒤 Transformer 차원으로 투영하는 것과 같아집니다.
- classification 토큰과 position embedding은 동일하게 추가됩니다.

3.4. Fine-tuning and Higher Resolution

- 일반적으로 대규모 데이터에 사전학습한 뒤 더 작은 downstream 과제로 미세조정합니다. 이때 사전학습된 예측 헤드를 제거하고, 0으로 초기화된 $D \times K$ 피드포워드 층을 새로 붙입니다(K 는 downstream 클래스 수).
- 사전학습보다 **높은 해상도**로 미세조정하는 것이 유리한 경우가 많습니다. 이때 패치 크기는 그대로 두므로 유효 시퀀스 길이가 길어집니다.
- ViT는 임의 길이의 시퀀스를 처리할 수 있지만 사전학습된 position embedding이 더는 의미를 갖지 못하므로, 원본 이미지 내 위치에 따라 **2D 보간**을 수행합니다.
- 이 해상도 조정과 패치 추출이야말로 ViT에 2D 구조에 대한 inductive bias가 수동으로 주입되는 유일한 지점입니다.

4. Experiments

4.1. Setup

- **사전학습 데이터셋:** ImageNet(1k 클래스, 130만 장), ImageNet-21k(21k 클래스, 1400만 장), JFT(18k 클래스, 3억 300만 장)를 사용했으며, downstream 테스트셋 기준으로 중복 제거를 수행했습니다.
- **평가 과제:** ImageNet(원본 및 ReaL 라벨), CIFAR-10/100, Oxford-IIIT Pets, Oxford Flowers-102, 그리고 과제당 1000개의 학습 예제만 사용하는 19개 과제 VTAB 스위트를 사용했습니다. VTAB은 Natural, Specialized(의료·위성), Structured(기하학적 이해) 세 그룹으로 나뉩니다.
- **모델 변형:** BERT의 설정을 따라 Base / Large를 가져오고 더 큰 Huge를 추가했습니다.
 - **ViT-Base:** 12층, $D = 768$, MLP 3072, 헤드 12개, 86M 파라미터
 - **ViT-Large:** 24층, $D = 1024$, MLP 4096, 헤드 16개, 307M 파라미터
 - **ViT-Huge:** 32층, $D = 1280$, MLP 5120, 헤드 16개, 632M 파라미터
- **표기법:** ViT-L/16은 패치 크기 16×16 을 쓰는 Large 모델을 뜻합니다. 시퀀스 길이는 패치 크기의 제공에 반비례하므로, **패치가 작을수록 연산량이 큼니다.**
- **베이스라인:** Batch Norm을 Group Norm으로 바꾸고 standardized convolution을 적용한 ResNet(BiT)을 사용했습니다.
- **학습 설정:** Adam($\beta_1 = 0.9$, $\beta_2 = 0.999$), 배치 크기 4096, weight decay 0.1, 선형 warmup과 decay를 사용했습니다. 미세조정은 momentum 0.9의 SGD, 배치 512, 대체

로 384 해상도로 수행했습니다.

- **평가 지표:** 미세조정 정확도를 주로 보고하되, 비용이 큰 경우에는 정규화 최소제곱 회귀로 닫힌 해를 구하는 few-shot linear 정확도를 사용했습니다.

4.2. Comparison to State of the Art

- 비교 대상은 대형 ResNet 기반 전이학습인 **BiT-L**과, 준지도 학습 기반 EfficientNet인 **Noisy Student**입니다. 사전학습 비용은 TPuv3-core-days로 측정했습니다.
- **공개 데이터만으로도:** ImageNet-21k로 사전학습한 ViT-L/16도 대부분의 과제에서 좋은 성능을 보였고, 표준 클라우드 TPuv3 8코어로 약 30일이면 학습할 수 있습니다.
- **VTAB 세부 분석:** ViT-H/14는 Natural과 Structured 그룹에서 BiT-R152×4 등 기존 방법을 앞섰고, Specialized 그룹에서는 상위 두 모델이 비슷했습니다.
- 다만 저자들은 사전학습 효율이 구조뿐 아니라 학습 스케줄, 옵티마이저, weight decay 등에도 영향을 받는다는 점을 명시합니다.

4.3. Pre-training Data Requirements

- **실험 1 — 데이터셋 크기별 사전학습:** ImageNet → ImageNet-21k → JFT-300M 순으로 키우며 ImageNet에 미세조정했습니다.
 - 가장 작은 ImageNet만 사용하면 (적절한 정규화를 적용해도) **ViT-Large가 ViT-Base보다 오히려 못합니다.**
 - ImageNet-21k에서는 두 모델의 성능이 비슷해집니다.
 - JFT-300M에 이르러서야 큰 모델의 이점이 온전히 드러납니다.
 - BiT CNN은 ImageNet 사전학습에서는 ViT를 앞서지만, 데이터가 커지면 ViT가 역전합니다.
- **실험 2 — JFT 부분집합:** 9M, 30M, 90M, 전체 300M을 추가 정규화 없이 동일 하이퍼파라미터로 학습해 모델의 본질적 성질을 평가했습니다.
 - ViT는 비슷한 연산량의 ResNet보다 **작은 데이터에서 더 심하게 과적합**됩니다. 예를 들어 ViT-B/32는 9M에서는 ResNet50보다 크게 뒤지지만 90M 이상에서는 앞섭니다.
- **해석:** 합성곱의 inductive bias는 데이터가 적을 때 유용하지만, 데이터가 충분하면 관련 패턴을 데이터에서 직접 배우는 것으로 충분하며 오히려 더 낮습니다.

4.4. Scaling Study

- JFT-300M 전이 성능을 기준으로 ResNet 7종, ViT 6종, 하이브리드 5종을 통제된 조건에서 비교했습니다.
- **첫째, ViT가 ResNet을 성능/연산 트레이드오프에서 압도합니다.** 동일 성능에 도달하는 데 약 2~4배 적은 연산량을 사용합니다.
- **둘째, 하이브리드는 작은 연산 예산에서 ViT보다 약간 낮지만 모델이 커지면 그 차이가 사라집니다.** 합성곱의 국소 특징 처리가 어떤 크기에서든 도움이 될 것이라 기대할 수 있다는 점에서 다소 의외의 결과입니다.
- **셋째, ViT는 실험한 범위 안에서 성능이 포화되지 않았습니다.** 향후 추가 확장을 시도할 동기가 됩니다.

4.5. 주요 Ablation

- **Transformer shape:** 깊이를 키우는 것이 가장 큰 개선을 주지만 16층 이후로는 수확 체감이 나타납니다. 너비 확장은 변화가 가장 작았고, 패치 크기를 줄여 시퀀스 길이를 늘리는 것은 파라미터 증가 없이 견고한 개선을 보였습니다.
- **Class token vs GAP:** 처음에는 GAP + 선형 분류기가 매우 나빴지만, 원인은 토큰이나 GAP 자체가 아니라 **적절한 학습률이 달랐기 때문**이었습니다. 학습률을 맞추면 두 방식은 비슷하게 동작합니다.
- **Positional embedding:** position embedding이 없는 경우와 있는 경우의 차이는 크지만, 1D / 2D / 상대 위치 방식 간의 차이는 거의 없습니다. 픽셀이 아닌 **패치 단위로** 동작하기 때문에 공간 차원이 이미 작아(예: 14×14) 어떤 방식으로든 학습이 쉽다는 해석입니다.

5. Inspecting Vision Transformer

5.1. 임베딩 필터와 위치 임베딩


- 첫 층의 선형 투영이 학습한 필터의 주성분을 보면, 각 패치 내부의 미세 구조를 저차원으로 표현하기에 적절한 **기저 함수와 유사한 형태**를 띕니다.
- 학습된 position embedding은 이미지 내 **거리를 유사도로 인코딩**합니다. 가까운 패치일수록 position embedding이 서로 비슷하고, 같은 행/열에 속한 패치끼리도 유사한 구조가 나타납니다. 큰 격자에서는 사인 형태의 구조가 보이기도 합니다.

- position embedding이 스스로 2D 이미지 위상을 학습한다는 사실은, 사람이 설계한 2D 인식 임베딩이 왜 추가 개선을 주지 못했는지를 설명합니다.

5.2. Attention Distance

- Self-attention은 최하위 층에서도 이미지 전체의 정보를 통합할 수 있는데, 모델이 이 능력을 실제로 쓰는지 확인하기 위해 attention 가중치에 기반한 평균 거리(**attention distance**)를 계산했습니다. 이는 CNN의 receptive field 크기에 대응하는 개념입니다.
- 일부 헤드는 **가장 낮은 층에서부터 이미지 대부분을 참조**하며, 전역 정보 통합 능력이 실제로 활용되고 있음을 보여줍니다.
- 반면 다른 헤드들은 낮은 층에서 일관되게 좁은 범위만 봅니다. 이런 국소적 attention은 ResNet을 앞단에 두는 하이브리드에서는 덜 두드러지는데, 이는 해당 헤드가 CNN의 초기 합성곱 층과 비슷한 역할을 한다는 것을 시사합니다.
- 깊이가 깊어질수록 모든 헤드의 attention distance가 커지며, 전체적으로 모델은 분류에 **의미적으로 관련된 영역**에 주목합니다.
- Attention map은 Attention Rollout 기법으로, 모든 헤드의 가중치를 평균한 뒤 층별 가중치 행렬을 재귀적으로 곱해 계산했습니다.

6. Self-Supervision



- Transformer의 NLP에서의 성공은 확장성뿐 아니라 대규모 **자기지도 사전학습**에도 크게 기인하므로, BERT의 masked language modeling을 모방한 **masked patch prediction**을 예비 실험했습니다.
- 패치 임베딩의 50%를 손상시키되, 그중 80%는 학습 가능한 [mask] 임베딩으로, 10%는 다른 패치 임베딩으로 교체하고, 10%는 그대로 둡니다. 그리고 손상된 패치의 3-bit 평균

색상(총 512색)을 예측합니다.

- 그 결과 ViT-B/16이 ImageNet에서 **79.9%**를 기록했습니다. 밑바닥부터 학습하는 것보다 2%p 향상된 수치이지만, 지도 사전학습에는 여전히 4%p 뒤집니다.
 - 다만 이 방식은 JFT 같은 초대규모 데이터나 아주 긴 사전학습을 요구하지 않았습니다. 10만 스텝 이후로는 수확 체감이 나타났고, ImageNet으로 사전학습해도 비슷한 이득을 얻었습니다.
 - Contrastive 사전학습은 후속 연구로 남겨두었습니다.
-

7. Conclusion

- 이미지 인식에 Transformer를 **직접** 적용하는 방법을 탐구했으며, 비전에 self-attention을 쓴 기존 연구들과 달리 초기 패치 추출 단계를 제외하면 이미지 고유의 inductive bias를 구조에 넣지 않았습니다.
 - 이미지를 패치의 시퀀스로 해석하고 NLP에서 쓰이는 표준 Transformer 인코더로 처리하는 단순하면서도 확장 가능한 전략이, **대규모 데이터 사전학습과 결합될 때 놀랍도록 잘 작동**한다는 것을 보였습니다.
 - 그 결과 ViT는 많은 이미지 분류 데이터셋에서 기존 최고 성능에 필적하거나 이를 능가하면서 지도 사전학습 비용은 상대적으로 저렴합니다.
 - **남은 과제:** (1) 탐지, 분할 등 다른 비전 과제로의 확장, (2) 자기지도 사전학습 방법의 지속적 탐구(현재는 지도 사전학습과의 격차가 큼), (3) ViT의 추가적인 규모 확장입니다.
-