

Deep Residual Learning for Image Recognition (ResNet) 리뷰

저자: Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun (Microsoft Research)
발표: CVPR 2016 (arXiv 2015.12) / ILSVRC 2015 1위

1. 문제 정의

1.1 Degradation Problem

네트워크가 깊어질수록 성능이 좋아질 것이라는 직관과 달리, 실제로는 일정 깊이 이상에서 **training error 자체가 증가**하는 현상이 관찰된다. 이는 overfitting이 아니다 — 56-layer plain net이 20-layer plain net보다 training/test error 모두 높다 (Fig. 1).

핵심 통찰: 만약 추가된 레이어들이 identity mapping만 학습해도, 깊은 모델은 얇은 모델보다 training error가 나빠질 이유가 없어야 한다. 하지만 SGD 옵티마이저가 identity mapping조차 잘 근사하지 못한다는 것이 문제의 본질.

1.2 기존 vanishing gradient 설명의 반박

저자들은 이 문제가 vanishing/exploding gradient 때문이 아니라고 주장한다. BN을 사용하면 forward/backward signal의 norm이 건강하게 유지됨을 확인했음에도 degradation이 발생하기 때문. → **최적화(optimization) 자체의 난이도** 문제로 규정.

2. 핵심 아이디어: Residual Learning

2.1 재구성

기존: 레이어가 목표 매핑 $\mathcal{H}(x)$ 를 직접 학습

제안: 레이어가 잔차(residual) $\mathcal{F}(x) := \mathcal{H}(x) - x$ 를 학습하도록 재구성

$$y = \mathcal{F}(x, \{W_i\}) + x$$

- Identity mapping이 최적이라면, $\mathcal{F}(x) \rightarrow 0$ 으로 만드는 것이 identity를 직접 근사하는 것보다 쉽다는 가설

- Shortcut connection은 **파라미터도, 연산량도 추가하지 않음** (element-wise addition만 발생)

2.2 차원 불일치 시 처리

입출력 채널 수가 다를 경우 두 가지 옵션:

- **Option A:** zero-padding shortcut (파라미터 없음)
- **Option B:** 1×1 conv projection $W_s x$ (파라미터 추가)

실험 결과(Table 3): $A < B < C$ (모든 shortcut을 projection) 순으로 성능이 오르지만 차이가 미미 → **identity shortcut만으로도 충분**하다는 결론. Bottleneck 구조에서는 projection이 오히려 연산량을 2배로 늘리므로 identity가 필수적.

3. 아키텍처

3.1 Basic Block vs Bottleneck Block

구분	구성	사용 위치
Basic block	3×3 conv $\times 2$	ResNet-18, 34
Bottleneck block	$1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1$ conv	ResNet-50, 101, 152

Bottleneck은 1×1 conv로 채널을 줄였다가(reduce) 3×3 conv를 거친 뒤 다시 늘리는(restore) 구조로, 동일 시간 복잡도 대비 더 깊은 네트워크 구성이 가능.

3.2 34-layer ResNet 설계 철학

VGG의 설계 규칙 계승: (i) 같은 output feature map 크기에서는 필터 수 동일, (ii) feature map 크기가 절반이 되면 필터 수는 2배. Downsampling은 stride 2 conv로 수행 (pooling layer 대신).

결과적으로 34-layer ResNet은 VGG-19 대비 FLOPs가 **18%**에 불과 (3.6B vs 19.6B).

4. 주요 실험 결과

4.1 ImageNet: Plain vs ResNet

	Plain (top-1 err)	ResNet (top-1 err)
18-layer	27.94	27.88
34-layer	28.54	25.03

- Plain net: 34-layer가 18-layer보다 더 나쁨 (degradation 확인)

- ResNet: 34-layer가 18-layer보다 **2.8%p 개선** — degradation 문제 해소
- 18-layer 비교 시 정확도는 비슷하지만, ResNet이 **수렴 속도가 더 빠름**

4.2 깊이에 따른 성능 (Table 4)

method	top-1 err.	top-5 err.
VGG [41] (ILSVRC'14)	-	8.43 [†]
GoogLeNet [44] (ILSVRC'14)	-	7.89
VGG [41] (v5)	24.4	7.1
PRReLU-net [13]	21.59	5.71
BN-inception [16]	21.99	5.81
ResNet-34 B	21.84	5.71
ResNet-34 C	21.53	5.60
ResNet-50	20.74	5.25
ResNet-101	19.87	4.60
ResNet-152	19.38	4.49

Table 4. Error rates (%) of **single-model** results on the ImageNet validation set (except [†] reported on the test set).

ResNet-50/101/152로 갈수록 top-5 error가 지속적으로 감소 (6.71% → 6.05% → 5.71%), degradation 없이 깊이의 이점을 그대로 흡수.

4.3 CIFAR-10: 1000+ layer 실험

- 110-layer ResNet: 6.43% test error, 파라미터 수는 오히려 FitNet/Highway보다 적음
- **1202-layer** ResNet: training error < 0.1%까지 도달 (최적화 자체는 성공) — 하지만 test error(7.93%)는 110-layer보다 나쁨 → **overfitting**으로 해석 (소규모 데이터 셋에 비해 모델이 과도하게 큼)

이 결과가 중요한 이유: "최적화 가능"과 "일반화 성능"은 별개 문제임을 명확히 보여줌. Residual learning은 전자를 해결했을 뿐, 후자는 여전히 regularization의 몫.

4.4 Downstream task 전이 성능

- PASCAL VOC 2007 detection: VGG-16 대비 mAP +3.2%p

- COCO detection: mAP@[.5,.95] **28% relative improvement** — 순수하게 backbone 교체(VGG-16 → ResNet-101)만으로 얻은 성능
- ILSVRC 2015: classification, detection, localization / COCO 2015: detection, segmentation 전부 1위

5. 분석: 왜 작동하는가 (Fig. 7)




Figure 7. Standard deviations (std) of layer responses on CIFAR-10. The responses are the outputs of each 3×3 layer, after BN and before nonlinearity. **Top:** the layers are shown in their original order. **Bottom:** the responses are ranked in descending order.

각 3×3 layer output의 표준편차(std)를 측정한 결과, ResNet의 레이어 응답이 plain net 보다 전반적으로 작음. 이는 residual function이 실제로 0에 가깝게 학습된다는 저자들의 가설을 뒷받침. 더 깊은 ResNet일수록(20 → 56 → 110) 개별 레이어의 응답 크기가 더 작아지는 경향 — 레이어 하나하나가 signal을 “덜” 수정한다는 의미.

6. 비판적으로 볼 지점 / 논문 자체가 인정하는 한계

- 왜 **optimization**이 쉬워지는지에 대한 이론적 증명은 없음. 논문은 실험적 증거 (empirical evidence)만 제시하고, 명시적으로 “이유는 future work”라고 밝힘 (Sec. 4.1 plain net 부분).

- Identity vs projection shortcut의 성능 차이가 작다는 것 자체가, 저자들의 "residual reformulation이 핵심"이라는 주장에 대한 간접 증거이긴 하지만 완전한 인과 규명은 아님.
 - 1202-layer 실험의 실패(overfitting)는 "깊이가 무조건 좋다"는 단순 해석을 스스로 반박하는 대목 — 이후 연구(Wide ResNet, DenseNet 등)에서 본격적으로 다뤄짐.
 - BN에 크게 의존하는 구조이기 때문에, BN 없이 이 결과가 재현되는지는 이 논문만으로는 알 수 없음.
-

7. 한 줄 요약

Residual connection은 파라미터·연산량 증가 없이 identity mapping을 default hypothesis로 만들어, 극단적으로 깊은 네트워크에서도 SGD가 최적화에 실패하지 않도록 만든 재구성(reformulation)이다.