



Deep Residual Learning for Image Recognition (팀 과제)

He et al., 2015

0. Abstract

Background

- Deep network → 풍부한 feature representation
- 문제: **network가 깊어질수록 optimization이 어려워짐**

Proposal: Residual Learning

- 기존: 원하는 mapping $H(x)$ 직접 학습
- 제안: residual function 학습

$$F(x) = H(x) - x$$

$$H(x) = F(x) + x$$

- **Residual function $F(x)$ 학습**
- **Shortcut connection**으로 입력 x 직접 전달

Results

- ImageNet: 최대 **152-layer ResNet**
 - VGG 대비 약 8배 깊음
 - VGG보다 낮은 computational complexity
- Ensemble → **3.57% top-5 error**
- ILSVRC 2015 classification 1위

- CIFAR-10: 100 / 1000+ layer network 학습·분석

| **핵심:** Residual learning을 통해 매우 깊은 network의 optimization을 용이하게 함.

1. Introduction

1.1 Importance of Depth

- CNN의 layer 증가 → low-level → mid-level → high-level feature 학습
- **Depth 증가 → representation 수준·복잡성 증가**
- VGG, GoogLeNet 등 당시 높은 성능의 모델 → very deep architecture 활용

핵심 질문

| **Is learning better networks as easy as stacking more layers?**

→ 단순한 layer 추가만으로 성능이 계속 향상되는가?

1.2 기존 Deep Network의 문제

Vanishing / Exploding Gradient

- Network가 깊어질수록 gradient가 지나치게 작아지거나 커지는 문제
- 주요 해결법
 - normalized initialization
 - Batch Normalization

→ 수십 개 layer의 network도 학습 시작 가능

Degradation Problem

- Network depth 증가
 - accuracy saturation
 - 이후 accuracy degradation
- 단순한 **overfitting** 문제가 아님
- validation error뿐 아니라 **training error**도 증가

Figure 1: CIFAR-10 Plain Network

Model	결과
20-layer	낮은 training/test error
56-layer	더 높은 training/test error

→ 더 깊은 모델의 optimization이 오히려 어려움

1.3 왜 Degradation이 이상한가?

- Shallow network에 추가한 layer가 모두 identity mapping이면 기존 기능 유지 가능

$$H(x) = x$$

- 따라서 이론적으로:

$$Training Error_{deep} \leq Training Error_{shallow}$$

- 실제 결과:

$$Training Error_{deep} > Training Error_{shallow}$$

해석

- Deep network의 표현력 부족 ✖
- Optimizer가 여러 nonlinear layer를 효과적으로 최적화하지 못함 ○

1.4 Residual Learning

기존 방식

$$x \rightarrow H(x)$$

- Layer가 $H(x)$ 직접 학습

Residual 방식

$$F(x) = H(x) - x$$

$$H(x) = F(x) + x$$

- Layer $\rightarrow F(x)$ 학습
- Shortcut $\rightarrow x$ 직접 전달

핵심 아이디어

- Identity mapping이 최적일 경우
 - Plain Network: $H(x) = x$ 직접 학습
 - ResNet: $F(x) = 0$ 만 학습
- $\rightarrow$ Identity mapping을 기준으로 필요한 변화만 학습

1.5 Shortcut Connection

$$y = F(x) + x$$

특징

- 하나 이상의 layer를 건너뛴
- 입력 x 를 직접 뒤쪽으로 전달
- Residual output $F(x)$ 와 element-wise addition

장점

- 추가 parameter 없음
 - 추가 computational cost 거의 없음
 - 기존 SGD + backpropagation 그대로 사용 가능
-

2. Related Work

2.1 Residual Representations

- Residual 개념의 기존 활용
 - VLAD
 - Fisher Vector
 - Vector Quantization
 - Multigrid

- Hierarchical basis preconditioning

공통 아이디어

- Original solution 직접 계산보다 **reference와의 residual 계산**이 optimization에 유리할 수 있음
- 문제의 **reformulation / preconditioning**이 optimization을 쉽게 만들 수 있다는 선행 연구

2.2 Shortcut Connections

- 기존 shortcut 관련 연구
 - MLP input → output linear connection
 - Auxiliary classifier
 - Inception shortcut branch
 - Highway Network

Highway Network vs ResNet

Highway Network	ResNet
Gating function 사용	Identity shortcut
Gate에 parameter 존재	Parameter 없음
Shortcut이 닫힐 수 있음	항상 정보 전달
Non-residual function 가능	항상 residual function 학습

ResNet의 특징

- 구조가 단순함
- parameter-free identity shortcut
- 극도로 깊은 network에서 효과 확인

3. Deep Residual Learning

3.1 Residual Learning

목표 mapping

$$H(x)$$

기존

- $H(x)$ 직접 학습

ResNet

$$F(x) = H(x) - x$$

$$H(x) = F(x) + x$$

Motivation

- Identity mapping이 최적이라면:

$$H(x) = x$$

$$F(x) = H(x) - x = 0$$

- 여러 nonlinear layer로 identity function을 만드는 것보다 **residual을 0으로 만드는 것이 더 쉬울 것으로 가정**
- 실제 상황에서 $H(x) \approx x$ 라면 $F(x)$ 는 작은 perturbation만 학습하면 됨

■ **핵심:** 새로운 mapping을 처음부터 학습 → Identity mapping을 기준으로 수정량 학습

3.2 Identity Mapping by Shortcuts

Residual Block

$$y = F(x, \{W_i\}) + x$$

- x : input
- y : output
- $F(x, \{W_i\})$: residual mapping
- W_i : weight

2-layer block 예시

$$F(x) = W_2 \sigma(W_1 x)$$

- σ : ReLU

Identity Shortcut

$$y = F(x) + x$$

- parameter 추가 ❌
- 계산량 증가 거의 없음
- Plain/Residual network 간 공정한 비교 가능
 - depth 동일
 - width 동일
 - parameter 동일
 - computational cost 거의 동일

Dimension이 다른 경우

- $F(x)$ 와 x 의 dimension이 같아야 addition 가능
- Dimension 불일치 시 **projection shortcut** 사용

$$y = F(x, \{W_i\}) + W_s x$$

- W_s : dimension matching
- CNN에서는 주로 **1×1 convolution**

원칙

- 동일 dimension → **Identity shortcut**
- 다른 dimension → **Projection shortcut**

3.3 Network Architectures

Figure 3 비교

1. VGG-19
2. 34-layer Plain Network
3. 34-layer Residual Network

Plain Network

- 대부분 **3×3 convolution**
- 동일 feature map size → 동일 filter 수
- feature map size 1/2 → filter 수 ×2
- Downsampling → stride 2 convolution

Feature map	Filters
56×56	64
28×28	128
14×14	256
7×7	512

- 마지막: **Global Average Pooling** → **FC 1000** → **Softmax**
- Complexity
 - 34-layer Plain: **3.6B FLOPs**
 - VGG-19: **19.6B FLOPs**

Residual Network

- Plain network에 **shortcut connection** 추가

Dimension 동일

- Identity shortcut

Dimension 증가

- **Option A**
 - Identity shortcut + zero padding
 - 추가 parameter 없음
- **Option B**
 - Projection shortcut
 - 1×1 convolution으로 dimension matching
- Feature map 크기 감소 시 shortcut에도 stride 2 적용

3.4 Implementation

Data Augmentation

- Scale augmentation
- Random 224×224 crop
- Horizontal flip
- Per-pixel mean subtraction
- Color augmentation

Network Setting

Convolution → Batch Normalization → Activation

- 각 convolution 뒤 BN 적용
- activation 이전에 적용

Training

Hyperparameter	설정
Optimizer	SGD
Mini-batch	256
Initial LR	0.1
LR schedule	plateau 시 ÷10
Weight decay	0.0001
Momentum	0.9
Dropout	사용 X

- Plain / Residual network 모두 **from scratch** 학습

4. Experiments

: Residual Learning이 실제로 깊은 network의 optimization을 쉽게 만드는지, 그리고 그 효과가 dataset과 task가 달라져도 유지되는지 검증 (아래 요약 표)

실험	바꾼 것	확인한 것	답
4.1.1	Depth	그냥 깊게 만들면 문제가 생기는가?	그렇다. Plain Network는 깊어지자 degradation 발생
4.1.2	Residual 유무	Residual이 degradation을 해결하는가?	그렇다. ResNet에서는 깊어질수록 성능 개선
4.1.3	Shortcut 방식	Projection shortcut이 꼭 필요한가?	아니다. Identity shortcut만으로도 큰 개선
4.1.4	Depth 대폭 증가	매우 깊어도 계속 성능이 좋아지는가?	그렇다. 152-layer까지 성능 지속 향상
4.2.1	Dataset 변경	다른 dataset에서도 같은 현상이 나타나는가?	그렇다. CIFAR-10에서도 동일 패턴 재현
4.2.2	110-layer 확장	100층 이상도 안정적으로 학습 가능한가?	그렇다. 110-layer에서도 성능 향상
4.2.3	1202-layer 확장	1000층 이상도 optimize 가능한가?	그렇다. 학습은 성공했지만 test 성능은 악화
4.2.4	내부 response 측정	실제로 작은 residual을 학습하는가?	그렇다. ResNet의 residual response가 더 작게 나타남
4.3.1	Task / Backbone 변경	다른 vision task에서도 효과가 있는가?	그렇다. Object Detection에서도 성능 향상

4.1 ImageNet Classification

▼ 4.1.1 Plain Network의 Depth 비교

- 배경
 - 앞에서 network가 깊어질수록 오히려 성능이 떨어지는 degradation problem을 제시함.
 - residual connection 없이 depth만 늘렸을 때 실제로 문제가 발생하는지 확인.
- 조건

조건	설정
Task	Image Classification
Dataset	ImageNet
Baseline	18-layer Plain Network

조건	설정
비교 모델	34-layer Plain Network
변경 변수	Depth: 18 → 34 layers
고정 조건	Plain 구조, 기본 architecture 및 training setting
평가 지표	Training error, validation error

- 결과
 - 34-layer Plain Network가 18-layer보다 training error와 validation error 모두 높게 나타남.
 - Top-1 error: Plain-18 27.94%, Plain-34 28.54%.
- 해석
 - 더 깊은 모델이 training data에서도 성능이 나빠므로 단순한 overfitting이 아님.
 - 깊은 Plain Network를 효과적으로 optimize하지 못하는 degradation problem이 실제로 존재함.
- 다음 실험: 같은 depth에 residual connection을 추가하면 degradation이 해결 되는지 확인.

▼ 4.1.2 Plain Network vs Residual Network

- 배경: Plain Network에서는 depth를 18 → 34 layer로 늘리자 오히려 성능이 악화됨.
- 조건

조건	설정
Task	Image Classification
Dataset	ImageNet
Baseline	Plain-18 / Plain-34
비교 모델	ResNet-18 / ResNet-34
변경 변수	Residual shortcut 유무
고정 조건	Depth, width, convolution 구조, training setting
평가 지표	Training error, validation Top-1 error

- 결과

- 18-layer에서는 Plain 27.94%, ResNet 27.88%로 큰 차이가 없음.
- 34-layer에서는 Plain 28.54% → ResNet 25.03%로 크게 개선됨.
- Plain은 18 → 34 layer에서 성능이 악화됐지만, ResNet은 오히려 향상됨.
- 해석
 - Residual connection은 단순히 test 성능만 높인 것이 아니라 training 자체를 쉽게 만든 것.
 - ResNet에서는 depth 증가를 실제 성능 향상으로 연결할 수 있음.
- 다음 실험: Residual connection을 어떤 방식으로 구성하는 것이 좋은지 비교.

▼ 4.1.3 Shortcut 방식 비교

- 배경
 - Residual Learning의 효과는 확인했지만, feature map dimension이 달라질 때는 $F(x)$ 와 x 를 그대로 더할 수 없음.
 - 따라서 dimension을 맞추는 shortcut 방식을 비교.

- 조건

조건	설정
Task	Image Classification
Dataset	ImageNet
Baseline	ResNet-34 Option A
비교 모델	Option A / B / C
변경 변수	Shortcut 방식
고정 조건	ResNet-34, residual block, training setting
평가 지표	Top-1 / Top-5 error

- 결과
 - Option A: identity shortcut + dimension 증가 시 zero-padding.
 - Option B: dimension 증가 시에만 projection shortcut 사용.
 - Option C: 모든 shortcut에 projection 사용.
 - Top-1 error: A 25.03%, B 24.52%, C 24.19%.
 - C가 가장 좋지만 세 방식의 차이는 크지 않음.

- 해석
 - 추가 parameter가 없는 Option A도 Plain-34보다 훨씬 좋은 성능을 보임.
 - ResNet의 성능 향상은 projection의 추가 parameter보다 residual learning과 identity shortcut 자체의 효과가 핵심임.
- 다음 실험: Residual 구조를 50, 101, 152 layer까지 더 깊게 확장했을 때도 성능이 좋아지는지 확인.

▼ 4.1.4 Deeper ResNet: 50 / 101 / 152-layer

- 배경
 - 34-layer에서 Residual Learning이 degradation을 해결함.
 - 더 깊은 network에서도 이 효과가 유지되는지 확인하기 위해 depth를 크게 증가시킴.

- 조건

조건	설정
Task	Image Classification
Dataset	ImageNet
Baseline	ResNet-34
비교 모델	ResNet-50 / 101 / 152
변경 변수	Depth
고정 조건	Residual Learning, 기본 training 방식
Block	50-layer 이상에서 Bottleneck block 사용
평가 지표	Top-1 / Top-5 error

- 결과
 - 50-layer 이상에서는 $(1 \times 1 \rightarrow 3 \times 3 \rightarrow 1 \times 1)$ bottleneck block을 사용해 계산량을 줄임.
 - Top-1 error: ResNet-34 24.52% → 50 22.85% → 101 21.75% → 152 21.43%.
 - Depth가 증가할수록 성능이 계속 향상됨.
 - ResNet ensemble은 3.57% top-5 error로 ILSVRC 2015 classification 1 위.
- 해석

- Plain Network와 달리 ResNet에서는 매우 깊은 network도 안정적으로 optimize 가능.
- Depth를 성능 향상을 위한 자원으로 실제 활용할 수 있게 됨.
- 다음 실험: ImageNet에서만 나타나는 현상인지 확인하기 위해 다른 dataset에서 재검증.

4.2 CIFAR-10 and Analysis

▼ 4.2.1 Plain vs ResNet 재검증

- 배경
 - ImageNet에서는 Plain은 깊어질수록 degradation이 발생했고, ResNet은 반대로 성능이 향상됨.
 - 이 현상이 특정 dataset이나 architecture에만 나타나는지 확인.
- 조건

조건	설정
Task	Image Classification
Dataset	CIFAR-10
Baseline	Plain Network
비교 모델	Plain Network / ResNet
변경 변수	Residual 유무, Depth
Depth	20 / 32 / 44 / 56
고정 조건	CIFAR용 architecture, training setting
Shortcut	ResNet은 Option A
평가 지표	Training / Test error

- 결과
 - Plain Network는 깊어질수록 training error가 증가함.
 - ResNet은 깊어질수록 training/test error가 감소함.
 - ResNet test error: 20-layer 8.75% → 32 7.51% → 44 7.17% → 56 6.97%.
- 해석

- ImageNet과 동일한 패턴이 CIFAR-10에서도 재현됨.
- Degradation problem과 Residual Learning의 효과가 특정 dataset에만 나타나는 현상이 아님.
- 다음 실험: 56-layer보다 훨씬 깊은 110-layer에서도 안정적으로 학습 가능한지 확인.

▼ 4.2.2 110-layer ResNet

- 배경: 56-layer까지 depth가 증가할수록 성능이 계속 향상되었기 때문에 100층 이상의 network로 확장.
- 조건

조건	설정
Task	Image Classification
Dataset	CIFAR-10
Baseline	ResNet-56
비교 모델	ResNet-110
변경 변수	Depth: 56 → 110
고정 조건	Residual 구조, Option A, CIFAR architecture
특이사항	초기 learning rate warm-up
평가 지표	Training / Test error

- 결과: ResNet-110의 test error는 6.43%로 ResNet-56의 6.97%보다 개선됨.
- 해석: 100층 이상의 network에서도 degradation 없이 학습할 수 있음을 보여줌.
- 다음 실험: Residual Learning의 한계를 확인하기 위해 1000층 이상으로 극단적으로 확장.

▼ 4.2.3 1202-layer ResNet

- 배경: 110-layer도 안정적으로 학습되었기 때문에 Residual Network가 얼마나 깊은 network까지 optimize 가능한지 확인.
- 조건

조건	설정
Task	Image Classification
Dataset	CIFAR-10

조건	설정
Baseline	ResNet-110
비교 모델	ResNet-1202
변경 변수	Depth: 110 → 1202
고정 조건	Residual 구조, CIFAR architecture
평가 지표	Training / Test error

- 결과
 - ResNet-110 test error: 6.43%.
 - ResNet-1202 test error: 7.93%.
 - ResNet-1202의 training error는 0.1% 미만까지 감소함.
- 해석
 - 1202-layer도 training 자체에는 성공했으므로 degradation problem은 아님.
 - Training 성능은 매우 좋지만 test 성능이 떨어졌기 때문에 overfitting으로 해석.
 - ResNet은 매우 깊은 network의 optimization은 가능하게 하지만, 깊이가 무조건 generalization 향상을 보장하지는 않음.
- 다음 실험: 실제 ResNet 내부에서 각 block이 작은 residual만 학습하는지 확인.

▼ 4.2.4 Residual Response 분석

- 배경
 - Residual Learning의 핵심 가정은 전체 mapping을 새로 학습하기보다 ($F(x)$)라는 작은 변화량을 학습하는 것이 쉽다는 것.
 - 실제 학습된 network에서도 residual response가 작은지 분석.
- 조건

조건	설정
Task	내부 representation 분석
Dataset	CIFAR-10
Baseline	Plain Network의 layer response
비교 모델	Plain vs ResNet, 서로 다른 depth의 ResNet

조건	설정
변경 변수	Architecture, Depth
고정 조건	Dataset 및 response 측정 방식
평가 지표	Layer response의 standard deviation

- 결과
 - ResNet의 residual response가 Plain Network의 response보다 전반적으로 작게 나타남.
 - 더 깊은 ResNet일수록 residual response가 작아지는 경향을 보임.
- 해석
 - 각 block이 representation을 완전히 새로 만드는 것이 아니라 기존 representation을 조금씩 수정하는 형태로 학습됨.
 - 논문에서 제안한 Residual Learning의 motivation을 실제 network 내부 분석이 뒷받침함.
- 다음 실험: Classification 외의 다른 vision task에서도 ResNet feature가 효과적인지 확인.

4.3 Object Detection on PASCAL and MS COCO

▼ 4.3.1 VGG-16 vs ResNet-101 Backbone

- 배경
 - 지금까지는 classification에서만 ResNet의 효과를 확인함.
 - ResNet이 classification에만 특화된 것이 아니라 더 좋은 visual representation 자체를 학습하는지 확인하기 위해 object detection에 적용.
- 조건

조건	설정
Task	Object Detection
Dataset	PASCAL VOC / MS COCO
Detection 모델	Faster R-CNN
Baseline	Faster R-CNN + VGG-16

조건	설정
비교 모델	Faster R-CNN + ResNet-101
변경 변수	Backbone
고정 조건	Faster R-CNN detection framework
평가 지표	mAP

- 결과
 - PASCAL VOC 2007: VGG-16 73.2 → ResNet-101 76.4 mAP.
 - PASCAL VOC 2012: 70.4 → 73.8.
 - COCO mAP@[.5:.95]: 21.2 → 27.2.
 - COCO에서는 약 28% relative improvement를 기록.
- 해석
 - Backbone만 ResNet으로 바뀌도 detection 성능이 크게 향상됨.
 - Residual Learning으로 얻은 feature가 classification에만 유효한 것이 아니라 다른 vision task에도 잘 transfer되는 범용적인 representation임을 보여 줌.