




2026-2 BASIC STUDY ML 3주차

Regression

SESSION LEADER: 22기 박서희

2026.07.23



과제 우수자 발표

송종은 님

화면 공유해주시고
5분 이내로 설명 부탁드립니다 :)

Table of Contents

회귀

선형 회귀

정규화 (Shrinkage)

회귀 진단



Regression

Keywords

회귀 vs 분류

Dimensions of a
Supervised Learner

Model, Loss Function, Optimization

Regression

SST, SSR, SSE

Regression vs Classification

Objective: Function Fitting

$$f : \mathcal{X} \rightarrow \mathcal{Y}$$

domain codomain

Output

Continuous

Regression

- House Price Prediction
- Temperature Forecasting
- Stock Price Prediction

Discrete

Classification

- Spam Email Filtering
- Fraud Detection
- Medical Diagnosis

Recap: Dimensions of a Supervised Learner

모델을 훈련한다 = 훈련 데이터셋에 가장 잘 맞도록 '모델 파라미터'를 찾는다

Model: $g(x|\theta), \quad g \in \mathcal{G}$

모델 선정

: 입력 x 와 파라미터 θ 를 기반으로 예측값 생성

Loss Function: $E(\theta|\mathcal{X}) = \sum_t L(y^t, g(x^t|\theta))$

정답을 통한 모델 성능 측정

: 데이터셋 X 에 대해 계산된 총 손실

Optimization Procedure: $\theta^* = \arg \min_{\theta} E(\theta|\mathcal{X})$

정답을 가장 잘 맞추는 모델 파라미터 탐색

: 파라미터 θ 를 조정하여 총 손실 E 최소화
'어떤 estimator를 써야 할까?'

Recap: Dimensions of a Supervised Learner

모델을 훈련한다 = 훈련 데이터셋에 가장 잘 맞도록 '모델 파라미터'를 찾는다

Model: $g(x|\theta), \quad g \in \mathcal{G}$

Linear Regression, Polynomial Regression,
Lasso, Ridge, Elastic Net, ...

Loss Function: $E(\theta|\mathcal{X}) = \sum_t L(y^t, g(x^t|\theta))$


MSE(Mean Squared Error)
: 대표적인 LossFunction !
무조건 MSE만 쓰는 것은 아님

Optimization Procedure: $\theta^* = \arg \min_{\theta} E(\theta|\mathcal{X})$

Least Squares Estimator (Closed Form)
Gradient Descent (Iterative Optimization)

Regression

Galton의 height 데이터 → 아버지의 키(X)가 클수록 아들의 키(Y)도 커질까?



두 변수 X, Y의 관계를

Model로 표현하려고 할 때,

Parameter를 어떻게 결정할 것인가?


(ex) $f(X) \rightarrow Y = aX + b$ 라는 모델에서 a와 b를 어떻게 결정할까?

즉, 데이터를 가장 잘 설명하는 직선은 무엇인가?

이를 위해서는 원칙이 필요! → **'Loss Function'**

$$* MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \text{최소화}$$

Regression



$$SST = SSR + SSE$$

Total Sum of Squares = Regression Sum of Squares + Error Sum of Squares


$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2 + \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **SST:** 전체 변동량 → 아무 모델도 안 쓰고 ‘평균으로 예측했을 때’의 오차 총합
- **SSR:** 회귀식으로 설명 가능한 변동 → 모델이 평균 대비 얼마나 많은 정보를 설명했는가
- **SSE:** 회귀식으로 설명되지 않은 변동 → 모델이 틀린 정도의 총합



Regression

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{\text{SSE}}{n}$$

MSE → ‘한 점당 평균적으로 얼마나 틀렸는가?’를 의미



**MSE를 최소화하는 직선,
즉 SSE를 최소화하는 직선을 찾아라 !**



최소제곱법 LSE (Least Squares Estimator)

: 정답을 가장 잘 맞추는 모델 파라미터 탐색에 사용되는 추정량



Linear Regression

Keywords

Linearity

Simple Linear Regression

Multiple Linear Regression

Polynomial Regression

Linearity & Linear Model

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_p X_{pi} + \epsilon_i$$

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 X_{1i} X_{2i} + \epsilon_i$$

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \cdots + \beta_p X_i^p + \epsilon_i$$

model이 모수(파라미터)들의 선형함수로 주어지는 모형

→ 모형식의 모든 회귀 계수 각각에 대해 편미분한 결과가 다른 회귀계수를 포함하지 않는다면 Linear Model !

* Non-Linear Transformation: squares, log, exp, ...

* Non Linear Model: $Y = \beta_0 + \beta_1 e^{-\beta_2 X} + \varepsilon$ $\frac{\partial f}{\partial \beta_1} = e^{-\beta_2 X}, \frac{\partial f}{\partial \beta_2} = -\beta_1 x e^{-\beta_2 X}$


Simple Linear Regression (SLR)

Model: $f(X) = \beta_1 + \beta_2 X$, $\hat{Y}_j = \beta_1 + \beta_2 X_j$

Loss Function: $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

Optimization: $\frac{\partial}{\partial \beta_1} MSE = 0$, $\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$

$$\frac{\partial}{\partial \beta_2} MSE = 0, \hat{\beta}_2 = r \frac{\sigma_y}{\sigma_x}$$



Simple Linear Regression (SLR)

Model: $f(X) = \beta_1 + \beta_2 X$, $\hat{Y}_j = \beta_1 + \beta_2 X_j$

Loss Function: $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

Optimization: $\frac{\partial}{\partial \beta_1} MSE = 0$, $\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}$
 $\frac{\partial}{\partial \beta_2} MSE = 0$, $\hat{\beta}_2 = r \frac{\sigma_y}{\sigma_x}$

$$\frac{\partial MSE}{\partial \beta_1} = -\frac{2}{n} \sum_{i=1}^n (y_i - \beta_1 - \beta_2 x_i) = 0$$

$$\sum_{i=1}^n y_i - n\beta_1 - \beta_2 \sum_{i=1}^n x_i = 0$$

$$\bar{y} - \beta_1 - \beta_2 \bar{x} = 0$$

$$\boxed{\hat{\beta}_1 = \bar{y} - \hat{\beta}_2 \bar{x}}$$

$$\frac{\partial MSE}{\partial \beta_2} = -\frac{2}{n} \sum_{i=1}^n x_i (y_i - \beta_1 - \beta_2 x_i) = 0$$

$$\sum_{i=1}^n x_i y_i - \beta_1 \sum_{i=1}^n x_i - \beta_2 \sum_{i=1}^n x_i^2 = 0$$

여기에 $\beta_1 = \bar{y} - \beta_2 \bar{x}$, $\sum_{i=1}^n x_i = n\bar{x}$ 대입

$$\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y} = \beta_2 (\sum_{i=1}^n x_i^2 - n\bar{x}^2)$$

$$\hat{\beta}_2 = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}$$

$$\sum x_i y_i - n\bar{x}\bar{y} = \sum (x_i - \bar{x})(y_i - \bar{y}) = S_{xy}$$

$$\sum x_i^2 - n\bar{x}^2 = \sum (x_i - \bar{x})^2 = S_{xx}$$

$$\boxed{\hat{\beta}_2 = \frac{S_{xy}}{S_{xx}} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\text{Cov}(x, y)}{\text{Var}(x)}}$$

표본상관계수: $r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$, 표준편차의 비율: $\frac{s_y}{s_x} = \sqrt{\frac{S_{yy}}{S_{xx}}}$

$$r \frac{s_y}{s_x} = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} \sqrt{\frac{S_{yy}}{S_{xx}}} = \frac{S_{xy}}{S_{xx}}$$

$$\boxed{\hat{\beta}_2 = r \frac{s_y}{s_x}}$$

★ true parameter β 는 unknown population parameter

→ 우리는 sample data를 통해 최적의 parameter β^* 을 얻고 싶다 !!

Multiple Linear Regression (MLR)

Single Linear Regression: 하나의 독립변수로 종속변수를 설명

↔ Multiple Linear Regression: 둘 이상의 독립변수로 종속변수를 설명

Model: $\hat{y}_i = \theta_0 + \theta_1 x_{i1} + \theta_2 x_{i2} + \cdots + \theta_p x_{ip}$ (x_{ij} 는 i번째 관측 샘플의 j번째 독립변수)

$$\begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \hat{y}_3 \\ \vdots \\ \hat{y}_n \end{bmatrix} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ 1 & x_{31} & x_{32} & \cdots & x_{3p} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \\ \vdots \\ \theta_p \end{bmatrix}$$

$$\boxed{\hat{\mathbf{Y}} = \mathbf{X}\boldsymbol{\theta}}$$

Prediction vector $\mathbb{R}^n$ Design matrix $\mathbb{R}^{n \times (p+1)}$ Parameter vector $\mathbb{R}^{(p+1)}$

★ **Goal:** 주어진 데이터 (X, y)를 가장 잘 설명하는 **최적의 Parameter Set** $\hat{\boldsymbol{\theta}} = [\hat{\theta}_0, \hat{\theta}_1, \dots, \hat{\theta}_p]$ 를 찾는 것!

Multiple Linear Regression (MLR)

* norm : vector's size, length → measure of distance between two vectors

$$\|\mathbf{x}\|_p := \left(\sum_{i=1}^n |x_i|^p \right)^{1/p}$$

$$\|\mathbf{x}\|_1 = \left(\sum_{i=1}^n |x_i| \right)$$

L1 norm

$$\|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^d |x_i|^2}$$

L2 norm

Loss Function: $R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n} (\|Y - \hat{Y}\|_2)^2$

‘실제값과 모델 예측값의 차이(MSE)를 가장 작게 만든다’

‘실제 정답 벡터와 모델 예측 벡터 사이의 거리(distance)를 최소화한다’

‘Residual vector $e = Y - \hat{Y} = \begin{bmatrix} y_1 - \hat{y}_1 \\ y_2 - \hat{y}_2 \\ \vdots \\ y_n - \hat{y}_n \end{bmatrix}$ 의 길이(length)를 최소화한다’

Optimization

: 오차(Loss)를 가장 작게 만드는 '최적의 파라미터 θ '를 찾기

1. Normal Equation

LSE

Minimize $S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$

$$S(\beta) = \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T \mathbf{X}\beta + \beta^T \mathbf{X}^T \mathbf{X}\beta$$

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X}\beta$$

Let $-2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X}\beta = 0 \rightarrow \mathbf{X}^T \mathbf{X}\beta = \mathbf{X}^T \mathbf{y}$

$$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Therefore $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$

Optimization

: 오차(Loss)를 가장 작게 만드는 '최적의 파라미터 θ '를 찾기

1. Normal Equation

LSE

Minimize $S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^T(\mathbf{y} - \mathbf{X}\beta)$

$$S(\beta) = \mathbf{y}^T \mathbf{y} - 2\mathbf{y}^T \mathbf{X}\beta + \beta^T \mathbf{X}^T \mathbf{X}\beta$$

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X}\beta$$

Let $-2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X}\beta = 0 \rightarrow \mathbf{X}^T \mathbf{X}\beta = \mathbf{X}^T \mathbf{y}$

$$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Therefore $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$

* Maximum Likelihood Estimator (MLE)

$$\mathbf{y} = \mathbf{X}\beta + \epsilon \quad \epsilon \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$$

MLE

$$L(\beta, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - \mathbf{x}_i^T \beta)^2}{2\sigma^2}\right)$$

$\hat{y}_i$

Maximize $\ell(\beta, \sigma^2) = -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2$

Minimize $-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mathbf{x}_i^T \beta)^2$

Equivalent to $S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^T(\mathbf{y} - \mathbf{X}\beta)$

★ LSE = MLE 이려면 오차항 분포에 특정한 가정이 필요
(정규성 / 독립성 / 등분산성)

Optimization

: 오차(Loss)를 가장 작게 만드는 '최적의 파라미터 θ '를 찾기

$$R(\theta) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{n} \sum_{i=1}^n (y_i - (\theta_0 + \theta_1 x_{i1} + \dots + \theta_p x_{ip}))^2$$


2. Gradient Descent (경사하강법)

한 번에 해를 구하는 Normal Equation과 달리, 조금씩 최적의 파라미터를 찾아가는 **[Iterative Method]**


Linear Regression + MSE Loss를 사용 $\rightarrow$ Loss Function이 파라미터에 대한 2차 함수 $\rightarrow$ **Convex** 형태

$\rightarrow$ 항상 **Global Minimum(최적해)이 존재함**이 수학적으로 보장되어 있음

Convex



Non-Convex



Optimization


: 오차(Loss)를 가장 작게 만드는 '최적의 파라미터 θ '를 찾기

2. Gradient Descent (경사하강법)

[알고리즘]

1. 초기화: 랜덤한 θ 값에서 시작
2. 기울기(Gradient) 계산 : 현재 위치에서 미분을 통해 가장 가파른 방향을 구함
3. 이동 (Update): 경사의 반대 방향으로 조금 이동
4. 반복: 기울기가 거의 0이 될 때까지(평평한 곳에 도착할 때까지) 반복

$$\theta_{j+1} \leftarrow \theta_j - \eta \frac{\partial R}{\partial \theta_j}$$





Polynomial Regression

핵심 아이디어: 데이터 자체를 변형하여 차수를 높인다. → ★ 여전히 선형 회귀 !

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_d x^d \quad (d: \text{degree})$$

파라미터 β 입장에서는 여전히 선형 결합이므로



can use Cross Validation to choose degree d

03

Regularization (Shrinkage Method)

Keywords

Limitation of
Linear Regression


Regularization

Ridge, Lasso, Elastic Net

Limitation of Linear Regression

When dimension of input **p** is large (e.g., larger than sample size **n**):

- **Multicollinearity**: Input variables are highly correlated
 - When **p** > **n**, least squares estimator is not unique
- **Overfitting**: Model with too many variables may be sub-optimal



Underfitting: Low Variance, but High Bias

→ 이 둘 사이의 균형점, 즉 **적당한 Complexity**를 찾고자 함

Overfitting: Low Bias, but High Variance

Regularization

오차만 줄이려다 보니 계수가 너무 커지거나 복잡해짐 → **Penalize complex models**

- Large estimate on parameters could increase model complexity
- **Shrink model's complexity** with additional loss term called "**regularization term**"
 - $E = \text{error on data} + \lambda * \text{model complexity}$ (회귀계수의 크기).
 - If λ increases → variance decreases, but bias increases
- Regularize(Penalize) with **N-norms** (L1 : LASSO, L2 : Ridge)

General regularization formulation

$$\mathcal{L}(\mathbf{w}) + \lambda R(\mathbf{w})$$

λ : Regularization strength → 패널티를 얼마나 세게 줄지 결정

$\mathbf{w}$: the model parameters or weights

$\mathcal{L}(\mathbf{w})$: Objective function or loss function

$R(\mathbf{w})$: Regularization term or regularizer or penalty

Ridge Regression (L2 Regularization)


- 방식: 계수의 제곱(β^2)을 합쳐서 패널티로 부여.

$$\text{Minimize } \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p \beta_j^2.$$

L2 norm

- 특징:

- 계수의 크기를 줄여서 0에 '가깝게' 만드는 방식
- 완전히 0으로 만들지는 않음 (변수를 아예 없애지는 않음)
- When to use? 변수들 간에 상관관계가 높거나 모든 변수가 골고루 중요한 경우



Ridge Regression(L2 norm)

$$\text{minimize}_{\beta} \sum_{i=1}^n \left(y_i - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \text{ subject to } \sum_{j=1}^p \beta_j^2 \leq s$$

Lasso Regression (L1 Regularization)


- 방식: 계수의 **절댓값**($|\beta|$)을 합쳐서 패널티로 부여.

$$\text{Minimize } \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

L1 norm

- 특징:

- 중요하지 않은 변수의 계수를 '**완전히 0**'으로 만들어버릴 수 있음
- 즉, 모델이 스스로 **변수 선택**(Feature Selection)을 함
- When to use? 변수가 너무 많은데 그중 소수만 중요할 것 같은 경우




Lasso (L1 norm)

$$\text{minimize}_{\beta} \sum_{i=1}^n \left(y_i - \sum_{j=1}^p \beta_j x_{ij} \right)^2 \text{ subject to } \sum_{j=1}^p |\beta_j| \leq s,$$

Elastic Net

Ridge + Lasso → L1과 L2 penalty를 둘 다 적용

Lasso가 변수를 너무 과감하게 지우는 것이 걱정될 때 사용



Hyperparameter (Tuning Parameter)
→ Cross Validation을 통해 결정

$$\text{Minimize } \sum_{i=1}^n \left(y_i - \beta_0 - \sum_{j=1}^p \beta_j x_{ij} \right)^2 + \lambda_1 \sum_{j=1}^p |\beta_j| + \lambda_2 \sum_{j=1}^p \beta_j^2$$



Regression Diagnostics & Model Selection

Keywords

Multicollinearity

Residual Analysis

Model Selection

Multicollinearity

종속변수 Y , 독립변수 X_1, X_2

Y 와 X_1 의 correlation이 높으면 (좋다 / 나쁘다)

X_1 과 X_2 의 correlation이 높으면 (좋다 / 나쁘다)

Multicollinearity

종속변수 Y , 독립변수 X_1, X_2

Y 와 X_1 의 correlation이 높으면 (✓) **좋다 / 나쁘다**)
 X_1 과 X_2 의 correlation이 높으면 (✓) **좋다 / 나쁘다**)


a high degree of correlation **between**
independent variables in a regression model

⚠ Model struggles to distinguish the effect of each variable

Multicollinearity

[다중공선성 판단 방법]

1. Scatterplot Matrix



2. VIF(Variance Inflation Factor)

$$VIF_j = \frac{1}{1 - R_j^2} \quad (R_j^2 : R^2 \text{ calculated by } j\text{-th predictor regressed on other predictors})$$

보통 **VIF가 10 이상**이면 다중공선성이 존재한다고 판단

```
> print(vif_values)
```

	X1	X2	X3
	89.523514	89.447291	1.017576

[다중공선성 처리 방법]


1. 변수 제거
2. Regularization(Ridge/Lasso 등)을 통해 변수의 영향력을 줄여줌
3. PCA 등의 차원 축소

Residual Analysis


: 좋은 모델이라면 오차(residual)에 아무런 패턴이 없고 random해야 함

1. 오차의 정규성 (Normality) 체크: ‘오차가 정규분포를 따르는가?’

잔차의 Q-Q Plot이 빨간 대각선을 따르면 정규성을 만족



정규 가정 만족




정규 가정 불만족

Residual Analysis


: 좋은 모델이라면 오차(residual)에 아무런 패턴이 없고 random해야 함

2. 오차의 독립성 (Independence) 체크: ‘오차들끼리 서로 아무런 관련이 없는가?’

Residual vs Predicted Values Plot에서 점들이 특정 패턴 없이 무작위하게 분포해야 함



독립성 가정 만족



독립성 가정 불만족
(quadratic term in X)


→ 모델이 데이터의 중요한 정보를 놓치고 있는 것 !

Residual Analysis

: 좋은 모델이라면 오차(residual)에 아무런 패턴이 없고 random해야 함

3. 오차의 등분산성 (Homoscedasticity) 체크: ‘오차의 크기가 일정한가?’

Residual vs Predicted Values Plot에서 점들이 퍼져 있는 정도가 일정해야 함



오른쪽으로 갈수록 점점 벌어지는 모양

→ Heteroscedasticity (데이터 값이 커질수록 오차도 커지고 있는 것)

해결 방법: Variance Stabilizing Transformation(VST)

ex. $Y \rightarrow \sqrt{Y}$, $\log Y$, $\arcsin Y$

등의 변수 변환을 통해 분산을 줄임

Model Selection

1. Analytical Methods (Information Criteria)

- **Idea:** Adjust the training error by adding a penalty for model complexity.
- **Examples:** Adjusted R2, Mallows' Cp, AIC, BIC.
- **Pros:** Very fast to compute (no re-fitting).
- **Cons:** Indirect estimate; makes assumptions about the model

$$AIC = 2k - 2 \ln(L)$$


$$BIC = \ln(n)k - 2 \ln(L)$$

- k = number of estimated parameters
- L = maximum likelihood of model
- n = sample size

2. Resampling Methods (Cross-Validation)

- **Idea:** Hold out a portion of data to use as a "pretend" test set.
- **Examples:** Validation Set, k-Fold CV, LOOCV.
- **Pros:** Direct estimate; more general (works for any model).
- **Cons:** Computationally more expensive (requires re-fitting)

Training Vs. Test Set Error



Model Selection – Metrics


Mean Absolute Error $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$

Mean Squared Error $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$

Root Mean Squared Error $RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$

$$R^2 = 1 - \frac{SS_{Residual}}{SS_{Total}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$Adjusted R^2 = 1 - \frac{(1 - R^2)(N - 1)}{N - p - 1}$$





Wrap-up & Announcement

Regression Pipeline

STEP 1. EDA & Preprocessing

- 상관관계 확인: Heatmap을 그려서 독립변수(X)들끼리 색이 너무 진하지 않은지(다중공선성 의심) 확인
- 전처리: 결측치 처리 / 범주형 변수 Encoding / 수치형 변수 Scaling 등
 - * 특히 Regularization(Ridge, Lasso 등)을 쓸 거라면 Scaling은 필수

Regression Pipeline

STEP 2. Baseline Model

- 가장 기본적인 setting의 모델 (ex. LinearRegression)을 학습시킴
- R-squared 또는 MSE 등을 확인해서 현재 성능 평가 → 기준으로 활용

Regression Pipeline

STEP 3. Regression Diagnostics

- 모델의 통계적 가정 만족 여부 검증
- VIF 확인 → 다중공선성 확인
- 잔차 분석(Residual Plot) → 적절한 처리 방식 고려

Regression Pipeline

STEP 4. Model Refinement

- if 과소적합/잔차 패턴 발견 → Polynomial Feature 추가 등의 방식 고려
- if 과적합/다중공선성 발견 → Ridge, Lasso, Elastic Net 등 규제를 고려

(Cross-Validation를 통해 최적의 파라미터 λ 결정)

Regression Pipeline

STEP 5. Model Selection & Final Evaluation

- 다양한 모델 시도 / 하이퍼파라미터 튜닝 → Cross-Validation으로 각 모델의 성능 평가
- Validation Error가 가장 작은 모델을 최적의 모델로 선정
- Test Set에 해당 모델을 활용해서 해당 모델의 최종 성능 Report



해당 자료는 Slack & KUBIG github에서 보실 수 있습니다 :)

7/30 (목)에는 Session 이후 회식이 예정되어 있습니다.

3주차 과제 : KUBIG_2026_FALL/Basic Study/ML/3주차
파일명 2026_2_ML_week3_{본인 이름}.ipynb 로 제출