

Main contributions

이 논문은 기존 GCN(Graph Convolutional Network)의 성능 향상이 실제로는 **그래프 전파(graph propagation)**와 **특징 변환(feature transformation)**이 결합되어 있기 때문인지, 아니면 각각의 역할이 독립적으로도 충분한지를 분석한다. 저자들은 이 두 과정을 분리한 **Decoupled Graph Convolution Network(DGCN)**를 제안하고, 특정 조건에서 DGCN이 **Label Propagation(LP)**과 본질적으로 동일한 예측 함수를 학습할 수 있음을 이론적으로 증명한다. 이를 통해 GCN의 성능은 복잡한 메시지 패싱 구조보다 적절한 그래프 전파 메커니즘에서 비롯된다는 점을 보여준다.

Strengths & weaknesses

Strengths

- **이론적 분석이 명확하다.** 기존 GCN을 단순히 개선하는 것이 아니라, GCN과 Label Propagation의 관계를 수학적으로 증명하여 GNN이 왜 동작하는지에 대한 이해를 높였다.
- **복잡한 모델의 필요성에 의문을 제기한다.** DGCN처럼 feature transformation과 propagation을 분리해도 유사한 성능을 얻을 수 있음을 보여주어, 이후 등장한 SGC, APPNP, SIGN 등의 경량 GNN 연구를 뒷받침하는 근거가 된다.
- **실험이 이론을 잘 뒷받침한다.** 여러 citation network와 benchmark에서 DGCN과 LP의 성능이 거의 동일함을 보여주어 제안한 등가성(equivalence)의 실용성을 검증했다.

Weaknesses

- **등가성은 특정 가정에서만 성립한다.** 논문의 이론은 선형 분류기와 특정 propagation 방식에 의존하므로, attention 기반 GNN이나 heterophily graph처럼 구조가 다른 환경에는 그대로 적용되기 어렵다.
- **실험 데이터셋이 제한적이다.** 대부분 homophily가 높은 citation graph(Cora, Citeseer, PubMed)에 집중되어 있어, 실제 대규모 그래프나 heterophily 환경에서도 동일한 결론이 유지되는지는 확인하기 어렵다.
- **표현력(expressiveness)에 대한 논의가 부족하다.** Label Propagation과 동등한 결과를 보인다고 해서 모든 GNN의 표현력을 설명할 수 있는 것은 아닌데, 이러한 한계에 대한 논의는 상대적으로 부족하다.

Questions / discussion items

1. 논문의 등가성은 **heterophily graph**(서로 다른 클래스가 많이 연결된 그래프)에서도 유지될까? 해당 환경에 대한 실험이 없어서 일반화 가능성이 궁금하다.
2. GAT(Graph Attention Network)처럼 **attention mechanism**을 사용하는 GNN에서도 propagation과 feature transformation을 분리하면 동일한 결론을 얻을 수 있을까?
3. Label Propagation과 동등한 성능을 보인다면, 실제 응용에서는 계산 비용이 더 적은 LP를 사용하는 것이 항상 유리한가? 복잡한 GNN이 필요한 문제의 경계가 어디인지 명확하지 않다.
4. 논문은 node classification에 초점을 맞추는데, **graph classification**이나 **link prediction**에서도 동일한 equivalence가 성립하는지 추가 검증이 필요해 보인다.