

논문: Graph convolutional neural networks for web-scale recommender systems (Ying, R., et al., KDD 2018)

**Main contributions:**

PinSage 는 기존 GCN 을 수십억 개 노드 규모인 추천 시스템에는 적용하기 어려운 문제를 다룬다. 저자들은 짧은 랜덤워크로 중요한 이웃만 선택하고 콘텐츠 특성과 그래프 관계를 함께 집계하는 확장 가능한 아이템 임베딩 모델을 제안한다. 또한 hard negative 기반 학습과 분산 추론을 결합해 핀터레스트에 실제 배포하고 오프라인, 사용자 평가, A/B 테스트에서 성능 향상을 보였다.

**Strengths & weaknesses:**

이 논문에서는 새로운 GCN 구조를 제안하면서 이웃 샘플링부터 CPU 와 GPU 작업 분리, MapReduce 추론, KNN 검색까지 실제 웹 규모에서 작동하는 전체 파이프라인을 제시했다.

랜덤워크 방문 빈도로 중요한 이웃을 가중합하는 importance pooling, 어느 정도 유사하지만 정답은 아닌 hard negative 를 학습하는 방식도 추천 후보 간 미세한 차이를 구분하는 문제에 잘 맞으며 이를 ablation study 로 효과를 확인했다.

다만 사용자가 연속해서 상호작용한 아이템을 관련 있는 정답으로 사용하기 때문에 실제 선호뿐 아니라 기존 추천 시스템이 어떤 아이템을 추천했는지 그 영향도 학습 데이터에 포함될 수 있다. 또한 핀터레스트 내부 데이터에 한정되고 비슷한 규모의 다른 모델(GCN)과의 직접 비교가 부족해 성능 향상이 모델 구조와 시스템 최적화 중 어디에서 비롯됐는지 분리해 판단하기는 어렵다.

**Questions / discussion items:**

PinSage 는 학습에 포함되지 않은 신규 아이템도 임베딩할 수 있다고 설명한다. 그러나 신규 아이템은 초기에는 그래프 연결이 거의 없어 콘텐츠 정보에 주로 의존하게 되므로 연결이 없는 시점과 연결이 축적된 이후의 임베딩 및 추천 성능을 비교할 필요가 있다. 이를 통해 콜드스타트 상황에서 콘텐츠 정보와 그래프 정보가 각각 얼마나 기여하는지 확인할 수 있을 것이다.