

NLP 1주차 과제 | Attention Is All You Need

논문: Attention Is All You Need (Vaswani et al., NeurIPS 2017)

안서영_23기

Main contributions

Transformer는 순환, 합성곱 구조를 완전히 배제하고 오직 attention만으로 인코더-디코더를 구성한 시퀀스 변환 모델이다. RNN의 순차적 계산은 학습 내 병렬화를 원천적으로 막고 긴 시퀀스에서 위치 간 의존성 학습을 어렵게 만드는데, self-attention은 임의의 두 위치를 상수 개의 연산으로 연결해 이 두 문제를 동시에 해결한다. WMT 2014 En-De에서 28.4 BLEU로 앙상블 포함 기존 최고 성능을 2 BLEU 이상 앞섰고, En-Fr에서는 8개 P100으로 3.5일 학습해 41.8 BLEU라는 단일 모델 sota를 훨씬 적은 학습 비용으로 달성했다.

Strengths & weaknesses

왜 self-attention이어야 하는지를 layer 단위 복잡도, 순차 연산 수, 최대 경로 길이라는 세 축으로 분해해 recurrent/convolutional layer와 나란히 비교해서 단순 성능 수치 비교보다 강한 것 같다. Self-attention이 $O(1)$ 순차 연산과 $O(1)$ 경로 길이를 갖는다는 표 하나가 "attention만으로 충분하다"는 주장의 근거를 아키텍처 선택 이전 수준에서 확보한다. 다만 설계 결정들의 근거는 대체로 사후적이다. Scaling factor $1/\sqrt{d_k}$ 는 dot product의 분산이 d_k 로 커진다는 논증으로 정당화되지만, $h=8$ 이나 $d_{ff}=2048$ 같은 선택은 ablation 표에서 좋았다는 것 이상의 설명이 없다.

Questions / discussion items

- Head 수를 늘리면 오히려 성능이 떨어진다($h=32$ 에서 25.4). 각 head의 d_k 가 16까지 줄어들기 때문이라면, 이는 head 수 자체의 문제가 아니라 d_k 축소 효과 (rows B)와 뒤섞여 있다. 두 요인이 분리되지 않은 실험이다.
- 논문 스스로 dot product 기반 compatibility function이 충분히 정교하지 않을 수 있다고 인정하면서도(rows B 해석), 대안은 탐색하지 않는다.
- Encoder self-attention은 $O(n^2 \cdot d)$ 라 긴 시퀀스에서 비용이 폭발하는데, 제안된 restricted attention은 실험 없이 future work로만 남겨져 있다.