

[NLP] Week1 Task

Kipf, T. N., & Welling, M. (2017). Semi-supervised classification with graph convolutional networks. ICLR.

<https://arxiv.org/abs/1609.02907>

1. Main contributions

본 논문은 그래프 구조 데이터를 위한 확장 가능한 반지도 학습(semi-supervised learning) 프레임워크인 Graph Convolutional Networks (GCN)를 제안한다. 핵심 아이디어는 spectral graph convolution의 1차 근사를 사용하여, 복잡한 고윳값분해 없이도 그래프의 로컬 구조와 노드 특징을 효과적으로 결합하는 층별 전파 규칙(layer-wise propagation rule)을 설계한 것이다. 이를 통해 기존 그래프 기반 정규화 방식보다 더 효율적으로 정보 전파를 수행하며, 대규모 그래프에서도 우수한 성능을 보인다.

2. Strengths & weaknesses

- **Strengths:**

- **이론적 정당성:** 복잡한 Chebyshev 다항식 근사에서 시작해, 실용적인 1차 근사 및 renormalization trick으로의 간결한 유도 과정이 논리적으로 매우 설득력 있음.
- **효율성:** 행렬 연산의 복잡도를 $O(|E|)$ 로 유지하여 대규모 데이터셋에 바로 적용 가능한 확장성을 확보함.

- **Weaknesses:**

- **풀 배치 학습의 한계:** 전체 그래프를 메모리에 올려야 하는 설계는 매우 큰 그래프(full-batch training 불가)를 다룰 때 제약이 됨.
- **고정된 그래프 구조:** 학습 과정에서 그래프의 인접 행렬(adjacency matrix)이 정적으로 유지되므로, 구조 자체가 변하는 동적 그래프 환경에서의 대응이 미흡함.

3. Questions / discussion items

- 모델이 깊어질수록 성능이 하락하는 현상을 저자들은 과적합으로 해석했으나, 이는 이후 밝혀진 'Over-smoothing(노드 특징 수렴)' 문제와 맞닿아 있음. 저자들이 깊은 모델 학습을 위해 도입한 Residual Connection이 이 현상을 어떻게 제어하려 했는지, 그리고 당시 실험 결과가 Over-smoothing의 징후를 어떻게 포착하고 있었는지에 대한 논의가 부족함.