

논문:

Semi-supervised classification with graph convolutional networks (Kipf, T. N., & Welling, M., 2017)

Main contributions

GCN은 그래프 위 준지도 노드 분류를 위해 스펙트럼 그래프 컨볼루션의 1차 근사에서 유도한 층별 전파 규칙을 제안한다. 기존 라플라시안 정규화 방식이 그래프를 손실 함수의 별점 항으로만 써서 "연결된 노드는 같은 라벨"이라는 가정에 묶여 있던 것과 달리, 구조를 신경망 $f(X, A)$ 에 직접 넣어 이 제약을 푼다. 최종 모델은 정규화 인접행렬 곱과 선형변환으로 이루어진 2층 구조이며, 인용 네트워크와 지식 그래프에서 기존 방법을 큰 폭으로 앞선다.

Strengths & weaknesses

Strengths: 스펙트럼 이론에서 출발했지만 $K=1$ 제한, 파라미터 결합, 재정규화 트릭을 거치며 최종 연산이 $\hat{A}X\Theta$ 한 줄로 떨어지는 단순화가 설득력 있다. 전파 모델 비교 실험은 이 단순화가 성능 손해가 아니라 이득임을 보여 근사 과정을 사후적으로 정당화한다.

Weaknesses: 모델 깊이에 대한 논의가 약하다. 논문은 층별 선형 정식화가 더 깊은 모델을 가능하게 한다는 점을 설계 동기로 내세우지만, 정작 깊이 실험은 부록에 두고 2~3층이 최적이며 7층부터 학습이 어려워진다고 보고한다. 저자들은 원인을 유효 컨텍스트 확대와 파라미터 증가에 따른 과적합 두 가지로 한 문장에 뭉뚱그리고 residual connection으로 증상만 덮는데, 두 설명은 처방이 다르다. 후자라면 은닉 차원 축소로 통제 가능하지만, 전자라면 전파 규칙 자체에서 따라 나오는 구조적 한계라 residual로 해결될 성질이 아니다. 논문은 두 가설을 분리하는 실험을 하지 않는다.

Questions / discussion items

층을 쌓는 것은 정규화 인접행렬을 반복 곱해 이웃 평균을 거듭하는 것인데, 이 반복이 노드 표현에 어떤 누적 효과를 남기는데 대한 분석이 없다. 전파 규칙 자체에서 곧바로 따라 나오는 문제임에도 다뤄지지 않는다. 또한 자기 연결과 이웃 엣지의 비중을 조절하는 트레이드오프 파라미터를 도입하면 유익할 수 있다고 언급하면서도 실험을 제시하지 않는데, 자기 정보와 이웃 정보의 균형은 깊이 문제와 직결되어 보인다.