




Training Compute-Optimal Large Language Models

저자	<u>Jordan Hoffmann</u> , <u>Sebastian Borgeaud</u> , <u>Arthur Mensch</u> , <u>Elena Buchatskaya</u> et al.
출판연도	2022
DOI	https://doi.org/10.48550/arXiv.2203.15556
상태	읽는중
Subjects	NLP
리뷰일	2026년 7월 23일

기존 연구의 한계:

1. 기존의 연구, Kaplan et al.에서는 연산량이 증가하면 데이터보다 모델 파라미터 수를 훨씬 빠르게 늘리는 것이 최적이라고 제안했음. 이 scaling law에 따라 Gopher, GPT-3 등이 학습되었음



→ 기존 LLM들이 상당히 과소적합되어 있다고 제기하며, 연산량이 증가함에 따라 파라미터 수와 학습 데이터의 크기를 모두 동등하게 증가하는 것이 최적임을 제안함

방법:

1. 모델 사이즈를 고정하고 학습 토큰 수를 변경
2. FLOPS를 고정하고 모델 사이즈를 변경
3. Loss 함수 fitting

Strengths:

1. 기존 연구가 모델 파라미터 수 증가에 집중했던 것과 달리 학습 데이터 양도 함께 증가시켜야 한다는 이의를 제기하고 실용적인 학습 지침을 제시하였다.
2. 다양한 실험 설계를 통해 가설을 검증했다. 모델 사이즈를 고정해봤고, FLOPS를 고정해봤고 등등 여러 관점에서 검증하였다.
3. 실제 모델 학습으로 검증했다. 실험을 통해 계산된 최적 조건에 따라 Chinchilla를 학습하여, 더 큰 모델인 Gopher보다 적은 파라미터와 동일한 연산량으로 더 높은 성능을 달성하였다.

Weaknesses:

1. 연산량에만 집중하고, 데이터 수집 비용은 고려하지 않았다. 실제 서비스 환경에서는 데이터 수집 난이도와 메모리 비용에 따라 최적 모델 크기가 달라질 수 있다.
2. Autoregressive model에 대해서만 검증이 되었고, BERT와도 같은 모델에서도 사용이 가능한지 여부가 검증되지 않았다.
3. 코드와 학습 데이터, 모델이 공개되지 않아 연구 결과를 재현하기 어렵다.

Questions:

1. LLM들이 under-training되었다고 실험을 통해 주장했지만, 실제로도 under-training 되었을지 검증할 방법이 있을까?