

논문:

Language models are unsupervised multitask learners (Radford, A., et al., 2019)

Main contributions

이 논문은 1.5B parameter의 autoregressive language model GPT-2를 제안하고, 파라미터나 아키텍처의 수정 없이 zero-shot 설정만으로 독해, 요약, 번역, 질의응답을 수행할 수 있음을 보였다. 저자들은 태스크 수행을 $p(\text{output}|\text{input}, \text{task})$ 로 보고 태스크 지시를 입력 텍스트 안에 넣는 방식을 택했으며, Reddit karma를 품질 기준으로 수집한 WebText로 학습해 8개 언어모델링 데이터셋 중 7개에서 zero-shot SOTA를 달성했다.

Strengths & weaknesses

이 논문의 강점은 태스크마다 별도 구조와 지도 데이터를 붙이던 관행을, 태스크를 자연어로 명세하는 하나의 틀로 통합한 점이다. 데이터 유출 검사를 직접 수행해 결과를 공개한 것도 자기 주장을 약화시킬 수 있는 검증이라는 점에서 평가할 만하다. 그러나 주장의 크기와 근거의 크기가 어긋난다. 제목은 언어모델이 멀티태스크 학습자라고 선언하지만, 요약은 기사에서 무작위로 3문장을 고르는 것보다 근소하게 나은 수준이고 영불번역은 사전 기반 단어 치환에도 못 미치며 질의응답 정답률은 4.1%다. 저자들 스스로도 사용 가능한 수준에 한참 못 미친다고 인정하는데, 그렇다면 논문이 실제로 보인 것은 태스크를 학습했다기보다 태스크 형식을 흉내낼 수 있다는 쪽에 가깝다.

Questions / discussion items

zero-shot이라는 주장은 학습 데이터에 정답이 없었다는 전제에 전적으로 의존하는데, 검증은 8-gram 중복이라는 표면적 일치에만 기반한다. 표현만 바꾼 동일 내용은 걸러지지 않으므로 논문의 핵심 주장이 검사 도구의 한계에 그대로 묶인다. 저자들도 퍼지 매칭 같은 더 나은 기법이 필요하다고 언급하지만 실행하지는 않았다. 또한 태스크 힌트를 제거하면 요약 성능이 6.4점 떨어진다고 보고하면서도 힌트 표현을 바꿨을 때의 민감도는 제시하지 않는데, 성능이 태스크 능력에서 오는지 특정 표현에 대한 반응에서 오는지 구별하려면 이 비교가 필요해 보인다.