

논문 제목 : Training Compute-Optimal Large Language Models
(Hoffmann et al., DeepMind, 2022)

Main contributions

학습에 쓸 수 있는 총계산량을 다루는 FLOPs 예산 아래서 모델 크기 N 과 학습 토큰 수 D 를 어떻게 배분해야 loss가 최소화되는지에 다루는 논문. 기존 LLM은 모델 크기만 키우고 학습 데이터 크기는 고정해온 탓에 과소학습이 된 상태를 지적하며, (1) 여러 학습 곡선 중 각 연산량에서 가장 낮은 손실만 이어서 만든 하한선으로 최소 손실을 쓰는 방법, (2) 연산량을 고정한 채 모델 크기만 바꿔서 손실이 최소가 되는 크기를 찾는 방법, (3) parametric loss function을 데이터에 맞춰서, 관측된 손실 값들에 잘 들어맞도록 수식의 계수를 추정하는 방법으로 크게 세 가지 방법으로 최적의 배분을 추정한다. 세 방법 모두 N 과 D 를 동일한 비율로 크기를 키워야 하며, Kaplan 논문 내용을 반증하기 위해 동일 예산에서 토큰을 키워 모델을 학습시키고 능가함을 보였다.

Strength & weaknesses

기존 Kaplan 논문을 반증하면서도, 학습률을 코사인 곡선 모양으로 줄여가는 cosine schedule 길이를 이용해 짧은 학습 구간의 loss를 과대 평가했고, 모델을 더 키워야한다는 식으로 진단하는 식이 설득력을 높인다. 그러나 대규모 기준 비교가능한 학습이 Chinchilla랑 Gopher 둘뿐이라 중간 규모는 없고, 중간에 저자들이 스스로 고연산 부분에서 관계가 단순 거듭제곱에서 벗어나는, $\log N$ 에서 concavity가 보인다고 인정하는 것을 보아 최적의 크기를 여전히 과대 추정하고 있을 가능성을 무시하지 못한다.

Questions / discussion items

approach 3만 $a=0.46$ 이라는 값을 보이며 작은 모델을 예측하는데 Huber loss가 저연산 point들을 이상치로 처리하진 않았을까라는 궁금증이 남아있고, 실제로 그렇다면 추정의 신뢰도에서 의문이 들 것 같다.