

NLP 2주차 과제 | 23기 안서영

논문: Language Models are Unsupervised Multitask Learners (Radford et al., 2019)

Main contributions:

GPT-2는 태스크별 지도학습 없이 언어모델링만으로 다양한 NLP 태스크를 수행할 수 있음을 보인 연구다. $p(\text{output}|\text{input})$ 대신 $p(\text{output}|\text{input}, \text{task})$ 를 모델링하되, 태스크 조건을 아키텍처가 아닌 자연어 시퀀스 자체로 표현한다. Reddit에서 3 카르마 이상 받은 외부 링크만 수집한 WebText(40GB)로 1.5B 파라미터 Transformer를 학습해, 파라미터나 구조 변경 없는 zero-shot 설정에서 8개 언어모델링 벤치마크 중 7개의 SOTA를 갱신했다. CoQA에서 12.7만 개의 학습 예제 없이 55 F1을 달성했고, 태스크 성능이 모델 크기에 따라 log-linear하게 향상됨을 보였다.

Strengths & weaknesses:

zero-shot 성능을 자랑하는 데서 멈추지 않고 그것이 암기의 산물일 가능성을 스스로 검증한 점이 강점이다. 8-gram Bloom filter로 평가셋과 WebText 학습셋의 중복률을 측정해 평균 3.2%임을 보였고, 이는 기존 데이터셋의 train-test 중복보다 오히려 낮았다. 저자들이 결론을 방어하는 대신 반증 가능한 형태로 노출시킨 셈이다. 다만 zero-shot 프롬프트 설계가 임의적이다.

Questions / discussion items:

번역 실험에서 WebText는 필터링 후 프랑수가 10MB만 남았음에도 WMT-14 Fr-En에서 11.5 BLEU가 나온다. 이 정도 데이터로 번역 능력이 생겼다는 것은 영어 모델링 능력의 전이인지, 아니면 10MB라는 양이 과소추정된 것인지 불분명하다.