




Chain-of-Thought Prompting Elicits Reasoning in Large Language Models

저자	Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Brian Ichter, Fei Xia, Ed Chi, Quoc Le, Denny Zhou
출판연도	2022
DOI	https://doi.org/10.48550/arXiv.2201.11903
상태	읽는중
Subjects	NLP
리뷰일	2026년 8월 10일

▼ I. Introduction

- Background that motivated the paper to address the problem
모델 크기를 키우는 것만으로는 복잡한 tasks에서 높은 성능을 달성하기에 충분하지 않았다. 또한 Fine-tuning 대신 몇 가지 input-output 예시들로 모델을 prompting하는 Few-shot Prompting이 제안되었었는데, 높은 퀄리티의 rationales 데이터셋을 갖추는 것은 일반적인 tasks들에 비해 훨씬 어렵고, 추론 능력이 필요한 tasks에서는 효과적이지 못했다.
- Prior studies presented to define the scope of the research
Program Induction by Rationale Generation: Learning to Solve and Explain Algebraic Word Problems
산술 문제를 풀기 위한 모델로, rationale이 포함된 데이터셋을 만들어 rationale를 생성하도록 훈련시켰다. 모델 자체가 rationale을 생성하도록 학습된 것이다.
- Suggestion: Chain-of-thought prompting

prompt에 rationale이 포함된 몇 개의 풀이 예시를 넣는 것만으로도 reasoning을 끌어낼 수 있다.



1. Chain-of-thought은 모델이 여러 단계 문제를 중간 단계로 분해할 수 있게 하며, 이는 더 많은 추론 단계가 필요한 문제에 추가 계산을 할당할 수 있다는 것을 의미한다.
2. Chain-of-thought은 모델의 행동에 대한 해석 가능한 창을 제공하여 특정 답에 도달한 방식을 제안하고 추론 경로가 잘못된 곳을 디버깅할 수 있는 기회를 제공한다.
3. Chain-of-thought 추론은 수학 문제, 상식적 추론, 기호 조작과 같은 task에 사용될 수 있으며, 이론적으로는 인간이 언어를 통해 해결할 수 있는 모든 task에 잠재적으로 적용될 수 있다.
4. 몇 개의 간단한 프롬프트 예시에 chain-of-thought 시퀀스를 포함시키는 것으로 학습이 끝난 LLM에서 chain-of-thought 추론을 쉽게 이끌어낼 수 있다

▼ II. Conclusion

- Strengths

1. 제안된 방법론이 심플하지만, 참신하고, 효과적이다.
2. 다양한 실험들로 연구 결과를 뒷받침했다.
 - a. 어려운 문제일 수록 few-shot prompting이 효과적이지 못하다
→ 그렇다면 어려운 문제일수록 CoT 효과가 더 클까?

그렇다. GSM8K처럼 여러 단계의 reasoning이 필요한 어려운 문제에서는 CoT 성능 향상이 매우 컸다. 반면 MAWPS처럼 한 번의 step만 거치는 문제에서는 성능이 오히려 안 좋아지거나 향상이 아주 적었다.

b. 작은 모델보다 LLM에서 더 CoT 효과가 더 클까?

c. CoT가 어떤 식으로 실패하는가?

사람이 직접 읽어보면서 확인했다.

d. Ablation study도 진행함

e. Exemplar에 따라 성능 변화가 달라지는 것 아닌가?

아니다. 다른 사람이 Exemplar들을 작성하여도, 일관적으로 CoT가 standard prompting보다 성능이 좋았다.

3. 기존 supervised SOTA보다 좋은 성능을 보였다.

- Weakness

1. 참신하긴 하지만, 엄청 참신하지는 않다.

2. 'The proposed approach is applicable in principle to any tasks that humans can solve via language'라고 되어 있지만, 주로 수학 문제 등 제한된 영역에서만 평가가 이루어졌다.

3. 대다수의 연구 그룹에게는 도움되지 않는 내용이다. 모델이 굉장히 커야만 그 효과를 드러내기 때문이다.

- Question

현대에서 쓰이는 CoT와 완전히 같은 맥락인가?

일반인들은 어떻게 CoT를 활용할 수 있는가?