

논문 제목 : Large Language Models are Zero-Shot Reasoners
(Kojima et al., NeurIPS 2022)

Main contributions

기존 Chain of Thought 프롬프팅은 복잡한 추론 능력을 끌어내기 위해 과제별로 풀이 예시를 작성해야하는 한계가 존재. 위 논문은 질문 뒤에 “Let’s think step by step”이라는 간단한 문장을 추가하는 zero shot CoT를 제안하며, 별도의 예시나 fine tuning 없이도 언어모델이 중간 추론 과정을 생성하도록 유도한다. 산술, 추론 등 여러 과제에서 일반적인 zero shot 프롬프팅보다 높은 성능을 보이며, 모델 규모와 성능이 정비례하는 것을 확인함.

Strength & weaknesses

text-davinci-002에서 MultiArith 정확도가 17.7%에서 78.7%로, GSM8K는 10.4%에서 40.7%로 상승했으며, PaLM에서도 유사한 개선이 나타나는 것으로 보아, 특정 모델에만 효과가 있는 것이 아니라 단순한 프롬프트 변화만으로도 추론 성능이 전반적으로 상승하는 것을 증명함. ‘단계적’으로 추론을 유도하는 표현이 중요하다는 점을 분석한 게 위 논문의 강점.

하지만 CommonsenseQA에서는 오히려 정확도가 하락하는 것으로 보아 모든 과제에 효과가 일관되는 것은 아니고, 단일 프롬프트만 쓰는 것처럼 포장해놨는데 실제로는 추론 생성과 정답 추출, 즉 두 단계 프롬프팅을 사용해서 정답 형식에 따른 별도의 후처리 규칙을 지정해야 한다.

Questions / discussion items

논문에서는 greedy decoding 결과를 중심으로 평가하는데, 프롬프트 표현이나 정답 추출 방식이 바뀌어도 성능 향상이 안정적으로 유지되는지 추가적인 검증이 필요하지 않을까 생각이 듦.