



Direct Preference Optimization: Your Language Model is Secretly a Reward Mode

👤 저자	<u>Rafael Rafailov</u> , <u>Archit Sharma</u> , <u>Eric Mitchell</u> , <u>Stefano Ermon</u> , <u>Christopher D. Manning</u> , <u>Chelsea Finn</u>
📅 출판연도	2023
🔗 DOI	https://doi.org/10.48550/arXiv.2305.18290
🌟 상태	읽는중
🏷️ Subjects	ML
📅 리뷰일	2026년 8월 10일

▼ I. Introduction

- Background that motivated the paper to address the problem

RLHF는 human preference를 학습하기 위해 별도의 reward model을 학습한 뒤 PPO와 같은 RL로 policy를 최적화해야 하므로 복잡하고 불안정하며 계산 비용이 크다.

- Suggestion: DPO

사람이 선호한 답변의 likelihood는 높이고, 선호하지 않은 답변의 likelihood는 낮추도록 함으로써 별개의 reward loss 없이 binary cross-entropy 형태로 학습 파이프라인을 simplify할 수 있다.

기존 RLHF의 KL-constrained objective를 reparameterization하여 reward를 policy에 대한 식으로 표현함으로써 가능했다.

▼ 기존 RLHF의 objective

$$\max_{\pi_{\theta}} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(y|x)} [r_{\phi}(x, y)] - \beta \mathbb{D}_{\text{KL}}[\pi_{\theta}(y | x) || \pi_{\text{ref}}(y | x)],$$

$$r(x, y) = \beta \log \frac{\pi_r(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x).$$

$$\mathcal{L}_{\text{DPO}}(\pi_{\theta}; \pi_{\text{ref}}) = -\mathbb{E}_{(x, y_w, y_l) \sim \mathcal{D}} \left[\log \sigma \left(\beta \log \frac{\pi_{\theta}(y_w | x)}{\pi_{\text{ref}}(y_w | x)} - \beta \log \frac{\pi_{\theta}(y_l | x)}{\pi_{\text{ref}}(y_l | x)} \right) \right].$$

▼ II. Conclusion

- Strength
 1. 제안된 방법이 심플하지만 참신하고, 효과적이다. 좋은 논문들 특인 것 같다.
novel and simple yet effective
 2. 이론적으로도 Bradley-Terry model을 통해 뒷받침되었다.
- Weakness
 1. 데이터셋의 크기가 얼마나 많아야 잘 작동하는지 제안되지 않았다.
- Question

강화학습을 실제로 해본 적이 없어 DPO를 해볼 기회가 있으면 정말 좋을 거 같다.