

안암·보문 전월세 시세 스크리닝 모델

- 청년 임차인의 정보비대칭 완화를 위한 실거래 기반 접근

KU해쥬, 집값 | ML_1조

24기 김유진 김하진 서지우 윤서영

CONTENTS

01

주제소개

- 1) 주제 선정 배경
- 2) 문제 정의

02

데이터 및 전처리

- 1) 데이터셋 구성
- 2) EDA
- 3) 전처리

03

모델링

- 1) MLR
- 2) LightGBM/XGBoost
- 3) GWR

04


결론 및 추후과제

- 1) 결론
- 2) 한계점
- 3) 기대효과 및 추후과제



01. 주제소개

01.1 주제 선정 배경





HOME > 뉴스 > 경제

전세 사라지는 요즘, 1인가구 '적정 월세'는 얼마일까

김다솜 | 승인 2026.04.14 17:05 | 댓글 0

서울 소형 주거 월세 평균 81만원 기록...전세 실종에 1인가구 부담 가중
 용산 오피스텔 월 100만원 돌파...강남·서초도 100만원 육박
 가계 재무 마지노선 '소득 20%' 붕괴...현실적인 주거비 상한선 확보 절실



청년층 월소득 대비 주거비 비율(RIR)은 **58.0%**로 과부담 기준을 초과하였다

01.1 주제 선정 배경



비교 가능한 시세정보 不在가 청년의 계약 여정에 비효율을 발생시킨다

HOME > 뉴스 > 경제

전세 사라지는 요즘, 1인가구 '적정 월세'는 얼마일까

김다솜 | 승인 2026.04.14 17:05 | 댓글 0

서울 소형 주거 월세 평균 81만원 기록...전세 실종에 1인가구 부담 가중
 용산 오피스텔 월 100만원 돌파...강남·서초도 100만원 육박
 가계 재무 마지노선 '소득 20%' 붕괴...현실적인 주거비 상한선 확보 절실





청년층 월소득 대비 주거비 비율(RIR)은 58.0%로 과부담 기준을 초과하였다

01.2 주제 및 문제 정의

비교 가능한 시세정보 **不在**가 청년의 계약 여정에 비효율을 발생시킨다

ML 기반 시세예측 모델로 **예측적평가**를 산출하고,
실제계약금과의 괴리율로 청년의 계약 의사결정을 보조할 수 있는가?



청년층 월소득 대비 주거비 비율(RIR)은 **58.0%**로 과부담 기준을 초과하였다

01.2 주제 및 문제 정의

용어정의:

환산보증금

$$\text{환산보증금} = \text{보증금} + \frac{\text{월세} \times 12}{\text{전월세전환율}}$$

- 전세는 보증금 원본값이 그대로 환산보증금
- 월세는 한국부동산원 「지역별 전월세전환율(연립·다세대)」 서울 동북권, 계약월별 실제값 적용(4.8~5.1% 범위)

과리율

$$\text{과리율(\%)} = \frac{(\text{실세계약가} - \text{예측적정가})}{\text{예측적정가} \times 100}$$

- 예측적정가는 모델이 학습한 예측시세를 이용
ex) 'lgb_pred'
- 추후 모델을 통하여 예측된 적정가가 실세계약금과 얼마나 과리되어 있는지 측정



02. 데이터 및 전처리

02.1 데이터셋 구성

1. 활용 데이터

◆ 데이터 출처

공공데이터포털

<https://www.data.go.kr/data/15126474/openapi.do>

(서비스명: RTMSDataSvcRHRent, 연립·다세대 전월세 실거래가 자료)

API Endpoint

<http://apis.data.go.kr/1613000/RTMSDataSvcRHRent/getRTMSDataSvcRHRent>

◆ 데이터 개요

제공 기관

국토교통부

자료 구분

연립·다세대 전월세
실거래가

원본 데이터 규모

28,207건

(전처리 후 최종 1,286건 · 02.3 참고)

02.1 데이터셋 구성

2. 수집 범위 및 조건

◆ 수집 조건

대상 지역

서울 성북구·동대문구 (법정동코드 11290, 11230)

대상 기간

2023년 1월 ~ 2026년 7월


주택 유형

연립·다세대주택

최종 분석 범위

안암동·보문동 (동그룹 기준 필터링)

◆ 위치 분포



빨간 점 = 수집된 계약 위치

02.1 데이터셋 구성

3. 최종 모델링 피쳐셋

◆ 기본 피쳐 (7개)

면적라벨

소형(20㎡ 이하)
중형(20㎡~33㎡)
대형(33㎡ 초과)

log_전용면적

전용면적(㎡) 로그변환
(면적-가격 비선형 관계 대응)

층

매물 층수

주택연령

계약연도 - 건축연도

is_basement

반지하 여부(0/1)

SK미래관거리

학교(SK미래관)까지 거리(m),
접근성 대리변수

보문역거리

지하철(보문역)까지 거리(m),
접근성 대리변수

◆ 타겟 변수

면적당가격_만원

전용면적 1㎡당 가격(만원), 전월세전환율로 환산 후 산출

◆ 구조 컬럼

data_split

train(2023~2024) / test(2025~2026) 구분자

◆ 선택적 피쳐 (3개)

전월세구분_*

전세/월세 구분

동그룹_*


안암동/보문동 구분

주택유형_*

다세대/연립 구분

02.2 EDA 핵심 발견


1) 표본구성



Train 표본은 월세(77.4%)·신규계약(87.2%) 중심으로 구성되어 있음을 확인하였다.


02.2 EDA 핵심 발견

2) 타겟변수 분포




면적당가격은 중위값 779만원/㎡, 평균값 803만원/㎡, 최빈구간 650~700만원대를 갖는다.

02.2 EDA 핵심 발견



3) 상관관계 개요


'전용면적': 타겟변수(면적당가격)와 -0.63의 강한 음의 상관관계를 갖는다.
'주택연령': 타겟변수(면적당가격)와 -0.54의 강한 음의 상관관계를 갖는다.



4) 전용면적-가격 비선형관계

전용면적이 커질수록 면적당가격이 급격히 하락하다 완만해지는 비선형 관계를 보이며, 로그 변환 시 상관이 -0.63에서 -0.74로 강화된다.


02.2 EDA 핵심 발견



5) 거리변수-가격

학교거리(SK미래관, $r = -0.33$)는 가격과 음(-)의 상관을, 지하철거리(보문역, $r = +0.40$)는 양(+)의 상관을 보인다.

*단, 두 거리변수 간 상관관계가 -0.76 로 높아, 이는 지하철 접근성 효과라기보다 안암동·보문동의 위치 차이를 반영한 결과로 해석됨




6) 면적라벨별 가격 차이

면적라벨(소형/중형/대형)에 따라 면적당가격 차이가 통계적으로 유의하며, 이 변수 하나가 가격 분산의 43.5%를 설명한다.

02.2 EDA 핵심 발견

7) 반지하여부



반지하는 지상 대비 면적당가격이 뚜렷하게 낮으며(Cohen's d=1.21), 통계적으로도 유의함을 확인하였다.

02.3 전처리

● 데이터 정제

API 원본 28,207건 → 중복 제거 → 안암·보문 서브셋 추출 → 최초 1,317건

● 이상치 제거

면적당가격 로그화 → 각 그룹별(면적라벨, 동그룹) Z-score 산출 후 $|Z| > 3$ 10건 이상치로 탐지

● 값 보정

계약구분 결측 → 신규로 대체 · 주택유형 "연립다세대" → "다세대" 통합 · 갱신계약 종전정보 결측 → 0 대체

※ 최종 1,286건

● 파생변수 및 인코딩

거리변수 재정의(SK미래관거리·보문역거리) · log_전용면적 추가 · 범주형 5개 더미 인코딩


● Train/Test 분리

data_split 기준 Train 694건(2023-24) / Test 592건(2025-26)



03. 모델링

03.0 모델링 로드맵




MLR을 기준모형으로 두고, 비선형 관계·상호작용은 Tree Ensemble로, 위치별 가격구조 차이는 GWR로 각각 확장하여 비교하였다.

03.0 데이터 분할

Model	Train	Validation	Test	Validation 역할
MLR	2023~2024	-	2025~2026	-
LightGBM	2023	2024	2025~2026	Early Stopping
XGBoost	2023	2024	2025~2026	Early Stopping·모델선택
GWR	2023	2024	2025~2026	진단용

부동산 가격의 시간적 변화를 고려하여, 미래 시점 예측성능 평가를 위한
 시간 순서 기반 Temporal Holdout을 적용하였다.

03.1 MLR



후진제거법을 통해 최종 9개 피처로 MLR을 구성했으며,
Test $R^2=0.649$, RMSE 204.2만원/㎡, MAE 159.3만원/㎡의 성능을 확인하였다.

03.2.1 피처 재설계

MLR 최종 피처 (9개)

log_전용면적
층
주택연령
SK미래관거리
보문역거리
면적라벨_중형
전월세구분_전세
동그룹_안암동
주택유형_연립




트리모델 피처 (11개)

log_전용면적
층
주택연령
SK미래관거리
보문역거리
면적라벨_중형
전월세구분_전세
동그룹_안암동
주택유형_연립
is_basement
면적라벨_소형

통계적 유의성 부족으로 제외했던 **is_basement**과 **면적라벨_소형**을
계수해석이 자유로운 트리모델에 재포함해 총 11개 피처로 재설계하였다.

03.2.2 LightGBM



※ Validation loss 기준으로 Early Stopping 적용

2024 Validation 성능

0.835	141.1	98.1
R^2	RMSE (만원/㎡)	MAE (만원/㎡)


Test(2025-26)

R^2 0.805 · RMSE 152.2 · MAE 110.2

— 일반화 참고 지표, 모델 선택엔 미반영

LightGBM은 Tree 기반 앙상블로 MLR 대비 비선형 관계를 반영해 예측 정확도를 크게 개선했으며, 2024 Validation 기준 $R^2=0.835$ 로 우수한 성능을 보였다.

03.2.3 XGBoost



2023 Train

2024 Validation

Early Stopping

※ Validation loss 기준으로 Early Stopping 적용

2024 Validation 성능

0.853 R^2 **133.1**

RMSE (만원/㎡)

97.2

MAE (만원/㎡)

Validation 3개 지표 모두 우세 → 최종 선정 모델


동일 피쳐셋

LightGBM과 동일 피쳐 사용

XGBoost는 LightGBM과 **동일한 피쳐셋**을 사용하여 2024 Validation 기준 최종 선정 모델로 확인되었다.

03.2.3 XGBoost- 변수 해석

■ 피처 중요도




- 면적 관련 변수군(log_전용면적·면적라벨)이 가장 높은 예측 기여도를 보였다.

- 접근성 대리변수(SK미래관거리·보문역거리)가 그다음으로 높은 기여도를 나타냈다.

- is_basement의 Feature Importance는 0으로 나타났으며, EDA에서 확인된 효과 크기(Cohen's $d \approx 1.2$)는 반지하 표본이 14건에 불과해 해석에 유의해야 한다.

- Feature Importance는 예측 기여도를 나타낼 뿐 인과적 영향력을 의미하지 않으므로 해석에 주의가 필요하다.

03.3 GWR




2025 ~ 2026 Test 성능

0.6817	194.6	141.4
R^2	RMSE (만원/㎡)	MAE (만원/㎡)

7개 피처 · adaptive bisquare · bandwidth 58
(중양값 반경 약 279m)

GWR은 위치별로 계수가 달라지는 공간회귀모형으로, Test 기준 $R^2=0.6817$ 의 성능을 보였다.

03.3 GWR



전용면적(log)·보문역거리의 지역계수가 위치에 따라 부호·크기가 달라지고 (금색=효과 강함, 적갈색=반전), Local R²도 지역별로 편차를 보인다.

공간 이질성 확인: 지역별로 계수의 크기·부호가 달라, 전역 회귀(MLR)가 포착하지 못하는 공간 패턴을 보인다.



04. 결론 및 추후과제

04.1 최종 모델 선정

Validation 비교	R^2	RMSE(만원/㎡)	MAE(만원/㎡)
LightGBM	0.835	141.1	98.1
XGBoost	0.853	133.1	97.2

Validation 기준 XGBoost가 3개 지표 (R^2 ·RMSE·MAE) 모두 근소하게 우세해 최종 모델로 선정되었다.

04.1 결론 - 모델 성능 비교

1. Test(2025-2026) 성능


Model	R ²	RMSE	MAE
MLR	0.6492	204.25	159.29
GWR	0.6817	194.57	141.40
XGBoost 최종 선정	0.7984	154.85	117.65
LightGBM	0.8051	152.25	110.22

단위: 면적당가격 만원/㎡ · Test 592건, 최종 평가 1회 · Train 2023 / Validation 2024 / Test 2025-2026 시간순 분할

2. 최종 모델 선정

- 최종 모델 XGBoost는 Test 결과로 재선정하지 않고 사전 설정한 2024 Validation 성능 기준으로 선정
- Test는 LightGBM이 소폭 우세하나 두 트리 모델 R² 격차 0.008로 사실상 동급
- Tree Ensemble이 더 높은 시점 외 예측성능을 보였으나, 모델별 학습·검증 구조가 일부 달라 성능 차이를 절대적인 모델 우열로 해석하지 않았다.


04.1 결론 - 모델 성능 (그래프 요약)



04.2 결론 - 괴리율 분석

1. 괴리율 분포 (Test 592건)

괴리율(%) = (실제 계약가 - 예측 적정가) ÷ 예측 적정가 × 100



예측 적정가와 실제 계약가의 괴리율은 중앙값 +3.5%로 체계적 편향 없이 계약가 수준을 재현하였으나, 고평가 구간(+10% 초과)이 31.8%로 나타나 점검이 필요하다.

04.3 한계점

- 안암·보문 단일 생활권 표본으로 타 지역 일반화 제약 (GWR도 동일 표본 제약)
- 반지하 등 소표본 변수의 효과 미반영
- 옥탑방 구분 불가·관리비 데이터 미반영, 거리변수 기준점 설정 방식(지하철·학교)에 따라 결과 변동 가능
- 이상치 기준 산출에 전체 기간 분포 사용으로 정보 누출 가능성
- 금리·시장추세 등 시간효과 미반영
- 괴리율 경고 임계값 미검증, 계약 안전성은 예측 대상 아님
- 단일 시간 분할 1회 평가로 성능 추정의 불확실성(신뢰구간)을 제시하지 못했으며, 모델 간 근소한 성능 차이의 통계적 유의성은 검증이 다소 미흡
- 평가 임계값(+10%)이 모델 평균오차(MAE 약 14.6%) 범위 내에 있어 매물 고평가와 예측오차 구분 불가

04.4 향후 과제 / 제언

향후 과제

- 1 호가 입력 → 괴리율 자동 산출 서비스 구현
- 2 신규 매물 입력값의 피쳐 자동 변환 파이프라인
- 3 Prediction Interval / Conformal Prediction 적용으로 점추정 한계 보완
- 4 금리·시점 변수 추가, 전처리 기준을 Train 단독으로 재산출
- 5 타 대학가·지역 확장 및 재학습

정책/실무 제언

- 청년 대상 계약 전 시세 점검 절차로 제도화하여 상담·중개 단계에 삽입
- 대학가 단위 공공 시세 스크리닝 지표 정기 공개
- 전월세전환율 기반 환산 기준 표준화로 전세·월세 동일 비교
- 괴리율 상위 구간 매물의 추가 확인 안내 등 소비자 보호 절차 연계

청년 임차인의 계약 전 가격 정보비대칭 완화를 위한 실거래 기반 **시세 스크리닝 모델**

04.5 활용 방향(가상안)

커버 범위
추가적인 데이터셋을 통한 범위 확장

호가 적정성 진단

매물 정보 입력

전용면적 (m²)

26.4

층

3

위치 (동)

안암동

중개인 제시 호가 (만원/월)

65

↓

진단 결과

모델 예측 시세

54.2만원

과리율

+19.9%

⚠ 시세 대비 호가가 높은 편이에요

상세 근거 보기

호가 입력
전용면적·층·위치·중개인 제시 호가 입력

과리율 자동 진단
예측 적정가 대비 실제 호가의 과리율(%)을 즉시 계산해 시세 대비 적정성을 안내



Thank You